

PROBABILITĂȚI ȘI STATISTICĂ

Eugen Păltănea

Universitatea Transilvania din Brașov
2021

Cuprins

0.1	Introducere	5
0.1.1	Date istorice	5
0.1.2	Descrierea cursului	5
0.1.3	Principiile de bază. Limbaj	6
1	Spații măsurabile. Câmpuri de probabilitate. Scheme clasice de probabilitate	7
1.1	Introducere	7
1.2	Corpuri	7
1.3	Spații măsurabile	9
1.4	Funcții măsurabile	10
1.5	Spații de probabilitate	12
1.6	Evenimente independente, evenimente condiționate	16
1.7	Scheme clasice de probabilitate	20
1.8	Rezumat	23
1.9	Test	27
2	Variabile aleatoare. Caracteristici numerice	29
2.1	Introducere	29
2.2	Variabile aleatoare	29
2.3	Funcția de repartiție	30
2.4	Variabile aleatoare independente	32
2.5	Variabile aleatoare discrete. Exemple clasice	33
2.6	Variabile aleatoare continue. Exemple clasice	35
2.7	Media. Medii de ordin superior	40
2.7.1	Definiție, proprietăți	40
2.7.2	Mediile unor distribuții clasice	43
2.8	Dispersia	45
2.8.1	Definiție, proprietăți	45
2.8.2	Dispersiile unor distribuții clasice	46
2.9	Corelația	48
2.10	Funcția caracteristică	49
2.10.1	Definiție, proprietăți	49
2.10.2	Funcțiile caracteristice ale unor distribuții clasice.	53
2.11	Rezumat	56
2.12	Test	59

3	Convergența șirurilor de variabile aleatoare	61
3.1	Introducere	61
3.2	Inegalități fundamentale în teoria probabilităților	61
3.3	Tipuri de convergență. Relații	64
3.4	Legile numerelor mari	67
3.5	Teorema limită centrală	68
3.6	Rezumat	77
3.7	Test	79
4	Elemente de statistică matematică	81
4.1	Introducere	81
4.2	Noțiuni de statistică descriptivă	81
4.2.1	Concepte de bază	81
4.2.2	Tipuri de distribuții statistice empirice. Tabele statistice. Reprezentări grafice.	84
4.2.3	Indicatori statistici	86
4.2.4	Calculul indicatorilor statistici ai distribuției variabilei X (Exemplul 1).	88
4.2.5	Calculul indicatorilor statistici ai distribuției variabilei Y (Exemplul 2).	89
4.2.6	Compararea a două distribuții empirice	90
4.2.7	Corelația și coeficientul de corelație	90
4.2.8	Metoda corelației rangurilor	91
4.3	Statistica eșantioanelor Bernoulli	91
4.3.1	Proprietățile estimatorului \bar{X}_n	93
4.3.2	Estimare bayesiană	96
4.4	Statistici, estimatori	96
4.5	Intervale de încredere	102
4.5.1	Exemplu: intervale de încredere pentru medie	102
4.6	Ipoteze statistice. Teste statistice	104
4.6.1	Descrierea tipurilor de ipoteze statistice	104
4.6.2	Testul Z	106
4.6.3	Testul χ^2	109
4.7	Test	117
4.8	Rezumat	118

0.1 Introducere

0.1.1 Date istorice

Teoria probabilităților¹ și statistica matematică studiază fenomenele aleatoare, în scopul predicției șanselor de realizare a unor rezultate așteptate. Studiul se bazează pe modelare matematică și raționamente deductive.

Bazele teoriei probabilităților și statisticii (studiului matematic al "hazardului") au fost puse în secolele XVI-XVII. Astfel, Gerolamo Cardano scria în 1526 prima carte dedicată unor concepte probabiliste: *Liber de ludo aleae* ("Cartea jocurilor de noroc"), publicată în 1663. Contribuții majore la punerea bazelor teoriei probabilităților au avut matematicienii francezi Blaise Pascal și Pierre de Fermat (începutul sec. al XVII-lea). În 1657, Cristiaan Huygens publica lucrarea *De ratiociniis in ludo aleae* ("Asupra raționamentelor în jocurile de noroc"). Doctrina probabilităților se conturează în sec. al XVIII-lea prin lucrările fundamentale *Ars conjectandi*, publicată în 1713 de Jacob Bernoulli și *The Doctrine of Chances*, publicată în 1718 de Abraham de Moivre. Un secol mai târziu, Pierre Simon Laplace publică lucrarea *Théorie analytique des probabilités*, în care evidențiază legea erorilor (convergența la legea normală). Teoria modernă a probabilităților (incluzând formalizarea axiomatică) este datorată în bună măsură matematicianului rus Andrei Nikolaevici Kolmogorov, autorul cărții *Foundation of the Theory of Probability*, publicată în 1950. Printre lucrările de referință în domeniu ale secolului XX trebuie amintite *The Theory of Stochastic Processes* (D.R. Cox, H.D. Miller, 1965), *An Introduction to Probability Theory* (W. Feller, 1968) și *Probability and Measure* (P. Billingsley, 1979). În ultimii 60 de ani, studiul proceselor aleatoare cunoaște o dezvoltare și diversificare teoretică exponențială, dar și un câmp foarte larg de aplicabilitate.

Școala românească de probabilități se remarcă prin numeroase contribuții originale. Bazele acestei școli se datorează în principal matematicienilor C. T. Ionescu-Tulcea, Gheorghe Mihoc, Octav Onicescu, Ion Cuculescu, Marius Iosifescu și Constantin Tudor.

0.1.2 Descrierea cursului

Prezentul curs reprezintă o introducere în teoria probabilităților și statisticii matematice. Sunt descrise și caracterizate concepte de bază ale domeniului: câmpuri de probabilitate, variabile aleatoare și convergența șirurilor de variabile aleatoare, eșantioane, estimatori statistici etc. Pentru studiul acestor noțiuni sunt necesare cunoștințe elementare de analiză matematică și teoria măsurii. Cunoștințele teoretice sunt exemplificate și aplicate în probleme și lucrări de laborator, menite să familiarizeze cursantul cu raționamentele specifice domeniului și cu utilizarea unor softuri informatice.

¹Etimologie: *probabilitas* (lat.) = credibilitate

0.1.3 Principiile de bază. Limbaj

Teoria probabilităților analizează șansele de realizare a unor *evenimente* în urma unei *experiențe* și este fundamentată pe următoarele trei principii:

1. Fiecărui *eveniment* rezultat în urma unei *experiențe* i se atribuie un număr real din intervalul $[0, 1]$ numit *probabilitatea evenimentului*.
2. Oricare două *evenimente contrare* au suma probabilităților egală cu 1.
3. Probabilitatea de realizare simultană a două evenimente este egală cu produsul dintre probabilitatea realizării unuia dintre evenimente și probabilitatea realizării celuilalt eveniment, condiționată de realizarea primului eveniment.

În formalizarea matematică, evenimentele care pot rezulta în urma efectuării unei experiențe reprezintă submulțimi ale unei mulțimi Ω (interpretată ca "evenimentul sigur"). Aceste evenimente au o probabilitate de apariție (șansă de realizare). Matematic, probabilitatea este o *măsură finită*, definită pe mulțimea evenimentelor. Astfel, limbajului probabilistic îi corespunde limbajul mulțimilor.

Următoarea schemă evidențiază dualitatea de limbaj (relativ la o anumită experiență):

- *evenimentul sigur* = mulțimea totală (de referință): Ω ;
- *evenimentul imposibil* = mulțimea vidă: \emptyset ;
- *eveniment* = submulțime a mulțimii totale: $A \subset \Omega$;
- *realizarea unui eveniment asigură realizarea unui alt eveniment (implicația evenimentelor)* = incluziunea mulțimilor: $A \subset B$;
- *evenimentul contrar (unui eveniment)* = complementara unei submulțimi a mulțimii totale: $A^c = \Omega \setminus A$;
- *evenimentul realizării a cel puțin unuia dintre două evenimente (disjuncția evenimentelor)* = reuniunea mulțimilor: $A \cup B$;
- *evenimentul realizării simultane a două evenimente (conjuncția evenimentelor)* = intersecția mulțimilor: $A \cap B$;

Capitolul 1

Spații măsurabile. Câmpuri de probabilitate. Scheme clasice de probabilitate

1.1 Introducere

Vom defini și caracteriza în continuare noțiunea de spațiu măsurabil (câmp de evenimente) și funcțiile măsurabile, definite între spații măsurabile. Noțiunile respective modelează matematic rezultatele posibile ale unei experiențe (evenimentele posibile) și corespondențele specifice asociate unor experiențe. Astfel, definim noțiunile: corp, σ -corp, borelianul unui spațiu topologic, spațiu măsurabil, funcție măsurabilă și evidențiem proprietățile lor de bază. Se introduce noțiunea de *spațiu (câmp) de probabilitate* și se pregătește definirea conceptului de *variabilă aleatoare*. Sunt evidențiate proprietățile probabilității, definită ca măsură finită pe spațiul evenimentelor (σ -corpul evenimentelor). Este discutată independența evenimentelor și noțiunea de probabilitate condiționată. Exemplele elementare de câmpuri de probabilitate discrete sunt particularizate în modelele clasice (scheme de probabilitate), adaptate studiului unor fenomene aleatoare.

1.2 Corpuri

Noțiunea de *corp* (de mulțimi) reprezintă cadrul minimal de modelare matematică a setului evenimentelor posibile rezultate în urma unei experiențe cu rezultate aleatoare.

Definiția 1.2.1. Fie Ω o mulțime nevidă. O familie nevidă \mathcal{C} de submulțimi ale lui Ω ($\mathcal{C} \subset \mathcal{P}(\Omega)$) se numește corp a lui Ω dacă satisface proprietățile:

$$C_1. A^c \in \mathcal{C}, \forall A \in \mathcal{C};$$

$$C_2. A \cup B \in \mathcal{C}, \forall A, B \in \mathcal{C}.$$

Proprietățile generale ale corpurilor deduse din definiția corpului de mulțimi sunt prezentate în propoziția următoare.

Propoziția 1.2.1. Fie \mathcal{C} un corp a lui Ω . Au loc proprietățile următoare:

$$C_3. \cup_{i=1}^n A_i \in \mathcal{C}, \forall A_i \in \mathcal{C}, i = \overline{1, n}, n \geq 2;$$

$$C_4. \cap_{i=1}^n A_i \in \mathcal{C}, \forall A_i \in \mathcal{C}, i = \overline{1, n}, n \geq 2;$$

$$C_5. \emptyset, \Omega \in \mathcal{C};$$

$$C_6. A \setminus B \in \mathcal{C}, \forall A, B \in \mathcal{C}.$$

Demonstrație. C_3 se verifică prin inducție. C_4 rezultă din următoarea relație (De Morgan): $\cap_{i=1}^n A_i = (\cup_{i=1}^n A_i^c)^c$ și proprietățile C_1 și C_3 . Pentru C_5 , considerăm $A \in \mathcal{C}$; avem $\Omega = A \cup A^c \in \mathcal{C}$ (cf. C_1 și C_2) și $\emptyset = A \cap A^c \in \mathcal{C}$ (cf. C_1 și C_4). C_6 se obține din relația: $A \setminus B = A \cap B^c$ (cf. C_1 și C_4). \square

Vom considera în continuare intersecții de corpuri ale unei mulțimi fixate.

Propoziția 1.2.2. O intersecție de corpuri ale unei mulțimi date este un corp al acelei mulțimi.

Demonstrație.

Fie $\{\mathcal{C}_i : i \in I\}$ o familie de corpuri ale mulțimii Ω . Notăm $\mathcal{C} = \cap_{i \in I} \mathcal{C}_i \subset \mathcal{P}(\Omega)$. Evident, $\Omega \in \mathcal{C}_i, \forall i \in I$ (cf. C_5), deci $\Omega \in \mathcal{C}$. Rezultă $\mathcal{C} \neq \emptyset$. Dacă $A \in \mathcal{C}$, atunci $A \in \mathcal{C}_i, \forall i \in I$, de unde $A^c \in \mathcal{C}_i, \forall i \in I$ (cf. C_1), deci $A^c \in \mathcal{C}$. Similar se verifică $A \cup B \in \mathcal{C}, \forall A, B \in \mathcal{C}$. Rezultă că \mathcal{C} este un corp a lui Ω . \square

Rezultatul de mai sus este util în studiul corpurilor generate de familii de părți ale mulțimii totale considerate.

Definiția 1.2.2. Fie $\Omega \neq \emptyset$ și $\mathcal{M} \subset \mathcal{P}(\Omega), \mathcal{M} \neq \emptyset$. Fie $\mathcal{P} = \{\mathcal{C} - \text{corp a lui } \Omega : \mathcal{M} \subset \mathcal{C}\}$. Atunci mulțimea

$$\mathcal{C}(\mathcal{M}) = \bigcap_{\mathcal{C} \in \mathcal{P}} \mathcal{C}$$

se numește corpul generat de \mathcal{M} .

Constatăm că $\mathcal{C}(\mathcal{M})$ este cel mai mic corp a lui Ω care include familia de părți \mathcal{M} a lui Ω . Ne vom referi acum la cazul corpurilor finite.

Propoziția 1.2.3. Fie $\Omega \neq \emptyset$.

1. Dacă $\mathcal{M} \subset \mathcal{P}(\Omega), \mathcal{M} \neq \emptyset$, este o mulțime finită, atunci corpul $\mathcal{C}(\mathcal{M})$ este finit.
2. Dacă \mathcal{C} este un corp finit a lui Ω , atunci există o partiție finită $\Delta = \{A_1, A_2, \dots, A_n\}$ a lui Ω astfel ca

$$\mathcal{C} = \{\cup_{i \in I} A_i : I \subset \{1, 2, \dots, n\}\}.$$

Demonstrație.

1. Fie mulțimile finite $\mathcal{M}^c = \{A^c : A \in \mathcal{M}\}$, $\mathcal{M}_1 = \mathcal{M} \cup \mathcal{M}^c$, $\mathcal{M}_2 = \{\cap_{A \in H} A : H \subset \mathcal{M}_1\}$ și $\mathcal{M}_3 = \{\cup_{A \in G} A : G \subset \mathcal{M}_2\}$. Se verifică faptul că $\mathcal{C}(\mathcal{M}) = \mathcal{M}_3$, deci corpul \mathcal{M} este finit.
2. Partiția Δ este formată din mulțimile nevide $A \in \mathcal{C}$, având proprietatea următoare $B \subset A \Rightarrow B = A$ sau $B = \emptyset, \forall B \in \mathcal{C}$. \square

1.3 Spații măsurabile

Noțiunea de corp (de mulțimi), definită în paragraful anterior, va fi extinsă în cele ce urmează la cea de σ -corp. Aceasta va permite introducerea noțiunii de *spațiu măsurabil* (câmp de evenimente).

Definiția 1.3.1. Fie Ω o mulțime nevidă. O mulțime nevidă $\mathcal{F} \subset \mathcal{P}(\Omega)$ se numește σ -corp a lui Ω dacă satisface următoarele condiții:

$$\sigma_1. A^c \in \mathcal{F}, \forall A \in \mathcal{F};$$

$$\sigma_2. \text{dacă } A_n \in \mathcal{F}, \forall n \in \mathbb{N}^* \text{ atunci } \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}.$$

Perechea (Ω, \mathcal{F}) se numește *spațiu măsurabil* sau *câmp de evenimente*.

Vom observa că orice σ -corp \mathcal{F} a lui Ω este un corp a lui Ω . Astfel, pentru $A, B \in \mathcal{F}$ considerăm șirul $(A_n)_{n \geq 1}$ definit prin $A_1 = A$ și $A_n = B$, $\forall n \geq 2$. Conform σ_2 , avem $A \cup B = \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}$. Deducem că σ -corpul \mathcal{F} este un corp. Ca urmare, proprietățile $C_3 - C_6$ rămân valabile pentru un σ -corp \mathcal{F} . Alte proprietăți specifice unui σ -corp sunt descrise în propoziția următoare.

Propoziția 1.3.1. Fie (Ω, \mathcal{F}) un spațiu măsurabil. Au loc următoarele proprietăți:

$$\sigma_3. A_n \in \mathcal{F}, \forall n \in \mathbb{N}^* \Rightarrow \bigcap_{n=1}^{\infty} A_n \in \mathcal{F};$$

$$\sigma_4. A_n \in \mathcal{F}, \forall n \in \mathbb{N}^* \Rightarrow \limsup_{n \rightarrow \infty} A_n \in \mathcal{F}, \liminf_{n \rightarrow \infty} A_n \in \mathcal{F},$$

unde $\limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k$ și $\liminf_{n \rightarrow \infty} A_n = \bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k$.

Demonstrație.

σ_3 . Conform relațiilor lui De Morgan și Definiției 1.3.1, avem: $\bigcap_{n=1}^{\infty} A_n = (\bigcup_{n=1}^{\infty} A_n^c)^c \in \mathcal{F}$.

σ_4 . Se aplică σ_2 și σ_3 . \square

Remarcăm că familiile $\mathcal{F}_1 = \mathcal{P}(\Omega)$ și $\mathcal{F}_2 = \{\emptyset, \Omega\}$ reprezintă σ -corpuri (deci și corpuri) elementare ale lui Ω .

Intersecția unor σ -corpuri ale unei mulțimi este de asemenea un σ -corp al mulțimii respective, demonstrația fiind similară celei din Propoziția 1.2.2.

Propoziția 1.3.2. Dacă \mathcal{F}_i , $i \in I$, reprezintă o familie oarecare de σ -corpuri ale mulțimii Ω , atunci $\bigcap_{i \in I} \mathcal{F}_i$ reprezintă de asemenea un corp al mulțimii Ω .

Proprietatea de mai sus permite definirea noțiunii de σ -corp generat de o mulțime de părți (submulțimi) ale unei mulțimi Ω .

Definiția 1.3.2. Fie Ω o mulțime nevidă și $\emptyset \neq \mathcal{M} \subset \mathcal{P}(\Omega)$. Intersecția σ -corpurilor lui Ω care includ mulțimea \mathcal{M} se numește σ -corpul generat de \mathcal{M} și se notează $\mathcal{B}(\mathcal{M})$.

Mulțimea $\mathcal{B}(\mathcal{M})$ este cel mai mic σ -corp a lui Ω care include pe \mathcal{M} . Un caz particular foarte important este cel în care mulțimea \mathcal{M} este o topologie pe spațiul Ω .

Definiția 1.3.3. Fie (Ω, \mathcal{T}) un spațiu topologic, unde \mathcal{T} reprezintă topologia lui Ω (familia mulțimilor deschise). Atunci σ – corpul generat de mulțimea \mathcal{T} se numește borelianul spațiului topologic (Ω, \mathcal{T}) și se notează (atunci când nu este pericol de confuzie) prin \mathcal{B}_Ω .

Topologia $\mathcal{T}_\mathbb{R}$ a mulțimii numerelor reale \mathbb{R} este **familia reuniunilor cel mult numărabile de intervale deschise disjuncte**. Are loc următorul rezultat fundamental.

Teorema 1.3.1. Borelianul $\mathcal{B}_\mathbb{R}$ al spațiului topologic $(\mathbb{R}, \mathcal{T}_\mathbb{R})$ conține toate tipurile de intervale și reuniunile cel mult numărabile ale acestora. În plus, $\mathcal{B}_\mathbb{R}$ este σ - corpul generat de mulțimea tuturor intervalelor reale de un anumit tip.

Demonstrăm teorema anterioară într-un caz particular.

Propoziția 1.3.3. Considerăm mulțimea de intervale reale $\mathcal{M} = \{(-\infty, a], a \in \mathbb{R}\}$. Are loc relația:

$$\mathcal{B}(\mathcal{M}) = \mathcal{B}_\mathbb{R}.$$

Demonstrație.

1. Pentru oricare $a \in \mathbb{R}$, avem $(-\infty, a] = \bigcap_{n=1}^{\infty} \left(-\infty, a + \frac{1}{n}\right) \in \mathcal{B}_\mathbb{R}$, de unde $\mathcal{M} \subset \mathcal{B}_\mathbb{R}$.

Rezultă $\mathcal{B}(\mathcal{M}) \subset \mathcal{B}_\mathbb{R}$.

2. Pentru oricare $a \in \mathbb{R}$, avem $(-\infty, a) = \bigcup_{n=1}^{\infty} \left(-\infty, a - \frac{1}{n}\right] \in \mathcal{B}(\mathcal{M})$. De asemenea,

$(a, \infty) = (-\infty, a]^c \in \mathcal{B}(\mathcal{M})$, $\forall a \in \mathbb{R}$. Atunci, pentru $a, b \in \mathbb{R}$, cu $a < b$, obținem

$(a, b) = (a, \infty) \cap (-\infty, b) \in \mathcal{B}(\mathcal{M})$. Rezultă $\mathcal{T}_\mathbb{R} \subset \mathcal{B}(\mathcal{M})$, de unde $\mathcal{B}_\mathbb{R} \subset \mathcal{B}(\mathcal{M})$.

Ca urmare, $\mathcal{B}(\mathcal{M}) = \mathcal{B}_\mathbb{R}$. \square

Pentru oricare $a \in \mathbb{R}$, avem $\{a\} = (-\infty, a] \cap [a, \infty) \in \mathcal{B}_\mathbb{R}$ (cf. Teoremei 1.3.1). Rezultă că $\mathcal{B}_\mathbb{R}$ conține mulțimile reale finite și mulțimile reale numărabile. Deducem $\mathbb{N}, \mathbb{Z}, \mathbb{Q} \in \mathcal{B}_\mathbb{R}$. De asemenea, avem $\mathbb{R} \setminus \mathbb{Q} = \mathbb{Q}^c \in \mathcal{B}_\mathbb{R}$.

1.4 Funcții măsurabile

Descriem în continuare funcțiile ”specifice” spațiilor măsurabile.

Definiția 1.4.1. Fie (Ω, \mathcal{F}) și (Ω', \mathcal{F}') o pereche de spații măsurabile (câmpuri de evenimente). O funcție $f : \Omega \rightarrow \Omega'$ se numește măsurabilă dacă

$$f^{-1}(A) \in \mathcal{F}, \quad \forall A \in \mathcal{F}',$$

unde $f^{-1}(A) = \{\omega \in \Omega \mid f(\omega) \in A\} \stackrel{\text{notat}}{=} \{f \in A\}$.

În particular, dacă $\Omega' = \mathbb{R}$ și $\mathcal{F}' = \mathcal{B}_\mathbb{R}$, f se va numi funcție reală măsurabilă.

Din caracterizarea borelianului $\mathcal{B}_\mathbb{R}$ (Teorema 1.3.1) și Definiția 1.4.1 rezultă că, pentru o funcție reală măsurabilă $f : \Omega \rightarrow \mathbb{R}$, avem:

- $\{f \leq a\} = \{f \in (-\infty, a]\} := f^{-1}((-\infty, a]) \in \mathcal{F}, \quad \forall a \in \mathbb{R}$
- $\{f > a\} = \{f \in (a, \infty)\} := f^{-1}((a, \infty)) \in \mathcal{F}, \quad \forall a \in \mathbb{R}$

- $\{a \leq f \leq b\} = \{f \in [a, b]\} := f^{-1}([a, b]) \in \mathcal{F}, \quad \forall a, b \in \mathbb{R}, a < b.$
- $\{a < f < b\} = \{f \in (a, b)\} := f^{-1}((a, b)) \in \mathcal{F}, \quad \forall a, b \in \mathbb{R}, a < b.$

Următoarea teoremă oferă o condiție necesară și suficientă de măsurabilitate a unei funcții reale definite pe un spațiu măsurabil.

Teorema 1.4.1. *Fie (Ω, \mathcal{F}) un spațiu măsurabil, \mathcal{M} mulțimea tuturor intervalelor de un anumit tip și $f : \Omega \rightarrow \mathbb{R}$ o funcție reală. Funcția f este măsurabilă dacă și numai dacă*

$$\{f \in A\} \in \mathcal{F}, \quad \forall A \in \mathcal{M}.$$

Demonstrație.

Presupunem că f este măsurabilă. Din Teorema 1.3.1 rezultă $\mathcal{M} \subset \mathcal{B}_{\mathbb{R}}$. Atunci, conform Definiției 1.4.1, deducem $\{f \in A\} \in \mathcal{F}, \quad \forall A \in \mathcal{M}$.

Presupunem $\{f \in A\} = f^{-1}(A) \in \mathcal{F}, \quad \forall A \in \mathcal{M}$. Pe baza relațiilor

$$f^{-1}(A^c) = (f^{-1}(A))^c, \quad f^{-1}(\cup_{i \in I} A_i) = \cup_{i \in I} f^{-1}(A_i) \quad \text{și} \quad f^{-1}(\cap_{i \in I} A_i) = \cap_{i \in I} f^{-1}(A_i),$$

unde $A, A_i \in \mathcal{M}, \quad \forall i \in I$, iar I este o mulțime de indici cel mult numărabilă, rezultă $\{f \in A\} \in \mathcal{F}, \quad \forall A \in \mathcal{B}(\mathcal{M})$. Dar, conform Teoremei 1.3.1, $\mathcal{B}(\mathcal{M}) = \mathcal{B}_{\mathbb{R}}$. Astfel, f este o funcție măsurabilă. \square

Teorema de mai sus permite demonstrarea unor proprietăți importante ale funcțiilor măsurabile.

Propoziția 1.4.1. *Fie (Ω, \mathcal{F}) un spațiu măsurabil și $f, g : \Omega \rightarrow \mathbb{R}$ două funcții măsurabile. Atunci*

1. $\{f < g\} \in \mathcal{F};$
2. $\{f \geq g\} \in \mathcal{F};$
3. $\{f = g\} \in \mathcal{F}.$

Demonstrație.

1. Pe baza densității mulțimii numărabile \mathbb{Q} în mulțimea \mathbb{R} , caracterizării σ -corpului \mathcal{F} și proprietăților funcțiilor măsurabile f și g , obținem

$$\{f < g\} = \bigcup_{r \in \mathbb{Q}} \{f < r < g\} = \bigcup_{r \in \mathbb{Q}} (\{f < r\} \cap \{g > r\}) \in \mathcal{F}.$$

2. Conform 1., obținem $\{f \geq g\} = \{f < g\}^c \in \mathcal{F}$. Analog, $\{f \leq g\} \in \mathcal{F}$.

3. Din 2. rezultă $\{f = g\} = \{f \geq g\} \cap \{f \leq g\} \in \mathcal{F}$. \square

Conservarea măsurabilității prin operații algebrice este stabilită de propoziția următoare.

Propoziția 1.4.2. *Fie (Ω, \mathcal{F}) un spațiu măsurabil. Dacă $f, g : \Omega \rightarrow \mathbb{R}$ sunt funcții măsurabile și $a \in \mathbb{R}$ următoarele funcții sunt măsurabile:*

- a) $f + a, a \in \mathbb{R};$ b) $af, a \in \mathbb{R};$ c) $f + g;$ d) $|f|;$ e) $f^2;$ f) $fg;$ g) $\min\{f, g\};$ h) $\max\{f, g\}.$

Demonstrație. Vom aplica caracterizarea funcțiilor măsurabile asigurată de Teorema 1.4.1, în cazul particular $\mathcal{M} = \{(-\infty, c), c \in \mathbb{R}\}$.

a) Fie $a \in \mathbb{R}$. Avem $\{f + a < c\} = \{f < c - a\} \in \mathcal{F}$, $\forall c \in \mathbb{R}$, deci $f + a$ este măsurabilă.

b) Dacă $a = 0$, atunci $af = 0$, iar funcția nulă este evident măsurabilă; dacă $a > 0$, atunci $\{af < c\} = \{f < c/a\} \in \mathcal{F}$, $\forall c \in \mathbb{R}$, deci af este măsurabilă; dacă $a < 0$, atunci $\{af < c\} = \{f > c/a\} \in \mathcal{F}$, $\forall c \in \mathbb{R}$, deci af este măsurabilă.

c) Fie $c \in \mathbb{R}$. Conform a) și b), funcția $c - g$ este măsurabilă. Atunci, pe baza Propoziției 1.4.1, subpunctul 1, obținem $\{f + g < c\} = \{f < c - g\} \in \mathcal{F}$. Deducem că funcția $f + g$ este măsurabilă.

d) $\{|f| < c\} = \emptyset \in \mathcal{F}$, pentru $c \leq 0$ și $\{|f| < c\} = \{-c < f < c\} \in \mathcal{F}$, pentru $c > 0$. Rezultă că funcția $|f|$ este măsurabilă.

e) $\{f^2 < c\} = \emptyset \in \mathcal{F}$, pentru $c \leq 0$ și $\{f^2 < c\} = \{-\sqrt{c} < f < \sqrt{c}\} \in \mathcal{F}$, pentru $c > 0$. Rezultă că funcția f^2 este măsurabilă.

f) Avem $fg = \frac{1}{4}[(f + g)^2 - (f - g)^2]$. Rezultă că fg este o funcție măsurabilă, conform a), b), c) și e).

g) Avem $\min\{f, g\} = \frac{1}{2}(f + g - |f - g|)$, deci funcția $\min\{f, g\}$ este măsurabilă, conform a), b), c), d).

h) Avem $\max\{f, g\} = \frac{1}{2}(f + g + |f - g|)$, deci funcția $\max\{f, g\}$ este măsurabilă, conform a), b), c), d). \square

Dacă (Ω, \mathcal{T}) este un spațiu topologic, atunci putem defini funcții continue $f : \Omega \rightarrow \mathbb{R}$. Continuitatea unei astfel de funcție implică măsurabilitatea sa în raport cu spațiul măsurabil $(\Omega, \mathcal{B}_\Omega)$, unde $\mathcal{B}_\Omega = \mathcal{B}(\mathcal{T})$.

Propoziția 1.4.3. *Dacă $(\Omega, \mathcal{B}_\Omega)$ este un spațiu măsurabil, cu \mathcal{B}_Ω reprezentând borelianul definit de o topologie pe Ω , iar $f : \Omega \rightarrow \mathbb{R}$ este o funcție continuă, atunci f este o funcție reală măsurabilă.*

Noțiunea de *funcție reală măsurabilă* servește definirii noțiunii de *variabilă aleatoare*.

1.5 Spații de probabilitate

Noțiunea de spațiu (sau câmp) de probabilitate este fundamentală în teoria probabilităților. Un spațiu de probabilitate este un spațiu măsurabil dotat cu un anumit tip de măsură finită, denumită "probabilitate".

Definiția 1.5.1. *Fie (Ω, \mathcal{F}) un spațiu măsurabil, cu σ – corpul \mathcal{F} denumit "mulțimea evenimentelor". O funcție $\mathbb{P} : \mathcal{F} \rightarrow \mathbb{R}$ se numește probabilitate dacă satisface următoarele axiome:*

P1. $\mathbb{P}(A) \geq 0$, $\forall A \in \mathcal{F}$;

P2. $\mathbb{P}(\Omega) = 1$;

P3. Pentru oricare șir de evenimente $(A_n)_{n \in \mathbb{N}^*}$, cu $A_n \cap A_m = \emptyset$, $\forall n \neq m$, are loc relația

$$\mathbb{P}(\cup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Tripletul $(\Omega, \mathcal{F}, \mathbb{P})$ se numește spațiu (câmp) de probabilitate.

Ultima proprietate a definiției de mai sus se referă la șiruri de evenimente. În continuare, ne vom referi la șirurile monotone de evenimente și limitele de șiruri de evenimente.

Definiția 1.5.2. Fie $(A_n)_{n \in \mathbb{N}^*}$ un șir de evenimente din spațiul de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$.

1. Șirul $(A_n)_{n \in \mathbb{N}^*}$ se numește monoton crescător dacă $A_n \subset A_{n+1}$, $\forall n \geq 1$. Fie $A = \cup_{n=1}^{\infty} A_n \in \mathcal{F}$. Notăm $\lim_{n \rightarrow \infty} A_n = A$ și $A_n \uparrow A$.
2. Șirul $(A_n)_{n \in \mathbb{N}^*}$ se numește monoton descrescător dacă $A_{n+1} \subset A_n$, $\forall n \geq 1$. Fie $A = \cap_{n=1}^{\infty} A_n \in \mathcal{F}$. Notăm $\lim_{n \rightarrow \infty} A_n = A$ și $A_n \downarrow A$.
3. Limita superioară a șirului $(A_n)_{n \in \mathbb{N}^*}$ se definește prin

$$\limsup_{n \rightarrow \infty} A_n = \cap_{n=1}^{\infty} \cup_{k=n}^{\infty} A_k \in \mathcal{F}.$$

4. Limita inferioară a șirului $(A_n)_{n \in \mathbb{N}^*}$ se definește prin

$$\liminf_{n \rightarrow \infty} A_n = \cup_{n=1}^{\infty} \cap_{k=n}^{\infty} A_k \in \mathcal{F}.$$

Probabilitatea are o serie de proprietăți fundamentale care decurg din Definiția 1.5.1. Aceste proprietăți caracterizează în fapt o măsură finită.

Propoziția 1.5.1. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate. Au loc următoarele proprietăți

P4. $\mathbb{P}(\emptyset) = 0$;

P5. $\mathbb{P}(A_1 \cup A_2 \cup \dots \cup A_n) = \mathbb{P}(A_1) + \mathbb{P}(A_2) + \dots + \mathbb{P}(A_n)$, $\forall A_1, A_2, \dots, A_n \in \mathcal{F}$, cu $A_i \cap A_j = \emptyset$ pentru $i \neq j$, unde $n \geq 2$;

P6. $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$, $\forall A \in \mathcal{F}$;

P7. $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$, $\forall A, B \in \mathcal{F}$, $A \subset B$;

P8. $\mathbb{P}(A) \leq \mathbb{P}(B)$, $\forall A, B \in \mathcal{F}$, $A \subset B$;

P9. $\mathbb{P}(A) \in [0, 1]$, $\forall A \in \mathcal{F}$;

P10. (Formula lui Poincaré)

$$\mathbb{P}(\cup_{i=1}^n A_i) = \sum_{k=1}^n (-1)^{k-1} \sum_{1 \leq i_1 < i_2 < \dots < i_k \leq n} \mathbb{P}(\cap_{j=1}^k A_{i_j}), \quad \forall A_1, \dots, A_n \in \mathcal{F}, \quad n \in \mathbb{N}, \quad n \geq 2;$$

P11. Dacă $(A_n)_{n \geq 1}$ este un șir monoton (crescător sau descrescător) de evenimente, cu $\lim_{n \rightarrow \infty} A_n = A$, atunci $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \mathbb{P}(A)$.

P12. Pentru oricare șir de evenimente $(A_n)_{n \in \mathbb{N}^*}$ avem

$$\mathbb{P}(\cup_{n=1}^{\infty} A_n) \leq \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

și

$$\mathbb{P}(\cup_{k=1}^n A_k) \leq \sum_{k=1}^n \mathbb{P}(A_k), \quad n \in \mathbb{N}^*.$$

Demonstrație.

P4. Presupunem că $\mathbb{P}(\emptyset) = p > 0$. Considerăm șirul $A_n = \emptyset$, $n \in \mathbb{N}^*$. Atunci, conform [P3], $p = \mathbb{P}(\emptyset) = \mathbb{P}(\cup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n) = \sum_{n=1}^{\infty} p = \infty$. Contradicție. Deci $\mathbb{P}(\emptyset) = 0$.

P5. Fie $A_1, A_2, \dots, A_n \in \mathcal{F}$, cu $A_i \cap A_j = \emptyset$ pentru $i \neq j$. Considerăm șirul de evenimente $A_k = \emptyset$, $k = n+1, n+2, \dots$. Atunci

$$\mathbb{P}\left(\bigcup_{k=1}^n A_k\right) = \mathbb{P}\left(\bigcup_{k=1}^{\infty} A_k\right) \stackrel{[P3]}{=} \sum_{k=1}^{\infty} \mathbb{P}(A_k) \stackrel{[P4]}{=} \sum_{k=1}^n \mathbb{P}(A_k).$$

P6. Din $\Omega = A^c \cup A$, cu $A \cap A^c = \emptyset$, rezultă $1 \stackrel{[P2]}{=} \mathbb{P}(\Omega) = \mathbb{P}(A^c \cup A) \stackrel{[P5]}{=} \mathbb{P}(A^c) + \mathbb{P}(A)$, de unde $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$.

P7. Dacă $A \subset B$, atunci $B = A \cup (B \setminus A)$, cu $A \cap (B \setminus A) = \emptyset$.

Rezultă $\mathbb{P}(B) \stackrel{[P5]}{=} \mathbb{P}(A) + \mathbb{P}(B \setminus A)$, deci $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A)$.

P8. Dacă $A \subset B$, atunci $\mathbb{P}(B) - \mathbb{P}(A) \stackrel{[P7]}{=} \mathbb{P}(B \setminus A) \geq 0$, deci $\mathbb{P}(A) \leq \mathbb{P}(B)$.

Observație. Proprietatea reflectă monotonia crescătoare a funcției probabilitate,

$$\mathbb{P} : (\mathcal{F}, \subset) \rightarrow (\mathbb{R}, \leq).$$

P9. Fie $A \in \mathcal{F}$. $\mathbb{P}(A) \geq 0$ (conform [P1]); cum $A \subset \Omega$, avem $\mathbb{P}(A) \stackrel{[P8]}{\leq} \mathbb{P}(\Omega) \stackrel{[P2]}{=} 1$.

P10. Demonstrăm formula lui Poincaré, notată $P(n)$, prin inducție matematică după numărul natural $n \geq 2$.

Fie $A_1, A_2 \in \mathcal{F}$. Avem

$$A_1 \cup A_2 = [A_1 \setminus (A_1 \cap A_2)] \cup [A_2 \setminus (A_1 \cap A_2)] \cup (A_1 \cap A_2),$$

unde termenii reuniunii sunt mulțimi mutual disjuncte. Atunci:

$$\mathbb{P}(A_1 \cup A_2) \stackrel{[P5]}{=} \mathbb{P}(A_1 \setminus (A_1 \cap A_2)) + \mathbb{P}(A_2 \setminus (A_1 \cap A_2)) + \mathbb{P}(A_1 \cap A_2)$$

$$\stackrel{[P7]}{=} [\mathbb{P}(A_1) - \mathbb{P}(A_1 \cap A_2)] + [\mathbb{P}(A_2) - \mathbb{P}(A_1 \cap A_2)] + \mathbb{P}(A_1 \cap A_2) = \mathbb{P}(A_1) + \mathbb{P}(A_2) - \mathbb{P}(A_1 \cap A_2).$$

Rezultă că formula este valabilă pentru $n = 2$, deci propoziția $P(2)$ este adevărată.

Demonstrăm implicația $P(n) \Rightarrow P(n+1)$, $\forall n \in \mathbb{N}$, $n \geq 2$. Presupunem că formula este adevărată pentru un număr natural $n \geq 2$ (deci propoziția $P(n)$ este presupusă adevărată) și o demonstrăm pentru $n+1$ (deci demonstrăm că propoziția $P(n+1)$ este adevărată).

Fie $A_1, A_2, \dots, A_n, A_{n+1} \in \mathcal{F}$. Avem

$$\begin{aligned}
\mathbb{P}(\cup_{k=1}^{n+1} A_k) &= \mathbb{P}((\cup_{k=1}^n A_k) \cup A_{n+1}) \stackrel{P(2)}{=} \mathbb{P}(\cup_{k=1}^n A_k) + \mathbb{P}(A_{n+1}) - \mathbb{P}((\cup_{k=1}^n A_k) \cap A_{n+1}) = \\
&= \mathbb{P}(\cup_{k=1}^n A_k) + \mathbb{P}(A_{n+1}) - \mathbb{P}(\cup_{k=1}^n (A_k \cap A_{n+1})) \stackrel{P(n)}{=} \sum_{k=1}^n (-1)^{k-1} \sum_{1 \leq i_1 < \dots < i_k \leq n} \mathbb{P}(\cap_{j=1}^k A_{i_j}) + \\
&\quad + \mathbb{P}(A_{n+1}) - \sum_{k=1}^n (-1)^{k-1} \sum_{1 \leq i_1 < \dots < i_k \leq n} \mathbb{P}((\cap_{j=1}^k A_{i_j}) \cap A_{n+1}) = \sum_{i=1}^{n+1} \mathbb{P}(A_i) + \\
&\quad + \sum_{k=2}^n (-1)^{k-1} \left[\sum_{1 \leq i_1 < \dots < i_k \leq n} \mathbb{P}(\cap_{j=1}^k A_{i_j}) + \sum_{1 \leq i_1 < \dots < i_{k-1} \leq n} \mathbb{P}((\cap_{j=1}^{k-1} A_{i_j}) \cap A_{n+1}) \right] + \\
&\quad + (-1)^n \mathbb{P}(\cap_{i=1}^{n+1} A_i) = \sum_{k=1}^{n+1} (-1)^{k-1} \sum_{1 \leq i_1 < \dots < i_k \leq n+1} \mathbb{P}(\cap_{j=1}^k A_{i_j}).
\end{aligned}$$

Rezultă că formula este adevărată pentru $n+1$ (deci propoziția $P(n+1)$ este adevărată). Formula lui Poincaré este o expresie a *principiului includerii-excluderii*.

P11. Fie $(A_n)_{n \geq 1}$ un șir monoton de evenimente.

a) Presupunem $A_n \downarrow \emptyset$.

Are loc reprezentarea $A_1 = \cup_{k=1}^{\infty} (A_k \setminus A_{k+1})$, unde $(A_i \setminus A_{i+1}) \cap (A_j \setminus A_{j+1}) = \emptyset$, $i \neq j$.

Atunci $\mathbb{P}(A_1) = \sum_{k=1}^{\infty} \mathbb{P}(A_k \setminus A_{k+1})$. Convergența seriei implică $\lim_{n \rightarrow \infty} \sum_{k=n}^{\infty} \mathbb{P}(A_k \setminus A_{k+1}) = 0$.

Dar $\sum_{k=n}^{\infty} \mathbb{P}(A_k \setminus A_{k+1}) = \mathbb{P}(\cup_{k=n}^{\infty} (A_k \setminus A_{k+1})) = \mathbb{P}(A_n)$. Rezultă $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = 0 = \mathbb{P}(\emptyset)$.

b) Presupunem $A_n \downarrow A$.

Atunci $(A_n \setminus A) \downarrow \emptyset$, de unde $\lim_{n \rightarrow \infty} \mathbb{P}(A_n \setminus A) = 0$ și obținem $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \mathbb{P}(A)$.

c) Presupunem $A_n \uparrow A$.

Atunci $A_n^c \downarrow A^c$. Rezultă $\lim_{n \rightarrow \infty} \mathbb{P}(A_n^c) = \mathbb{P}(A^c)$, de unde obținem $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \mathbb{P}(A)$.

P12. Fie șirul de evenimente $(A_n)_{n \geq 1}$. Definim șirul $(B_n)_{n \geq 1}$, $B_1 = A_1$, $B_n = A_n \setminus (\cup_{k=1}^{n-1} A_k)$ $\forall n > 1$. Avem $\cup_{n=1}^{\infty} B_n = \cup_{n=1}^{\infty} A_n$, iar $B_i \cap B_j = \emptyset$, $\forall i \neq j$. Conform proprietăților [P3] și [P8], obținem

$$\mathbb{P}(\cup_{n=1}^{\infty} A_n) = \mathbb{P}(\cup_{n=1}^{\infty} B_n) = \sum_{n=1}^{\infty} \mathbb{P}(B_n) \leq \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Cea de a doua relație se obține analog. Astfel, demonstrația propoziției este încheiată. \square

1.6 Evenimente independente, evenimente condiționate

Un fenomen important evidențiat de teoria probabilităților este cel al *independenței evenimentelor*.

Definiția 1.6.1. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate. Evenimentele A și B se numesc *independente* dacă $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$. Mai general, o mulțime cel mult numărabilă $\mathcal{G} \subset \mathcal{F}$ reprezintă o familie de evenimente independente dacă pentru oricare evenimente distincte $A_1, A_2, \dots, A_n \in \mathcal{G}$ avem

$$\mathbb{P}(\cap_{i=1}^n A_i) = \prod_{i=1}^n \mathbb{P}(A_i).$$

Din definiție rezultă că, pentru oricare eveniment A , A și \emptyset , respectiv A și Ω reprezintă perechi de evenimente independente. Are loc de asemenea următorul rezultat elementar.

Propoziția 1.6.1. Dacă A și B sunt evenimente independente, atunci A^c și B sunt de asemenea evenimente independente.

Demonstrație. Fie evenimentele independente A și B . Avem deci $\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B)$. Atunci

$$\mathbb{P}(A^c \cap B) = \mathbb{P}(B \setminus (A \cap B)) = \mathbb{P}(B) - \mathbb{P}(A \cap B) = \mathbb{P}(B) - \mathbb{P}(A) \cdot \mathbb{P}(B) = \mathbb{P}(B)(1 - \mathbb{P}(A)) = \mathbb{P}(A^c) \cdot \mathbb{P}(B).$$

Rezultă că evenimentele A^c și B sunt independente. \square

Vom defini în continuare *evenimentele condiționate*.

Definiția 1.6.2. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate. Considerăm $A \in \mathcal{F}$, cu $\mathbb{P}(A) > 0$ (A se numește eveniment neneglijabil). Pentru un eveniment $B \in \mathcal{F}$ numim probabilitatea lui B condiționată de (realizarea evenimentului) A mărimea:

$$\mathbb{P}(B|A) := \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)}.$$

Probabilitatea condiționată $\mathbb{P}(B|A)$ se mai notează $\mathbb{P}_A(B)$.

Probabilitatea condiționată $\mathbb{P}(B|A)$ reprezintă deci *probabilitatea realizării evenimentului B , știind că evenimentul A s-a realizat*. Formula

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B|A)$$

a fost menționată ca principiu de bază al teoriei probabilităților. Proprietățile elementare ale probabilității condiționate sunt evidențiate în propoziția următoare.

Propoziția 1.6.2. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate.

1. Dacă A și B sunt două evenimente neneglijabile, independente, atunci

$$\mathbb{P}(B|A) = \mathbb{P}(B) \text{ și } \mathbb{P}(A|B) = \mathbb{P}(A).$$

2. Dacă A și B sunt două evenimente neneglijabile atunci

$$\mathbb{P}(A|B) \cdot \mathbb{P}(B) = \mathbb{P}(B|A) \cdot \mathbb{P}(A).$$

3. Pentru evenimentele A_1, A_2, \dots, A_n ($n \geq 2$), cu $\mathbb{P}(\cap_{i=1}^{n-1} A_i) > 0$, are loc formula intersecției finite:

$$\mathbb{P}(\cap_{i=1}^n A_i) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2|A_1) \cdot \mathbb{P}(A_3|A_1 \cap A_2) \cdots \mathbb{P}(A_n|A_1 \cap A_2 \cap \cdots \cap A_{n-1}).$$

4. Dacă A este un eveniment neneglijabil, atunci funcția $\mathbb{P}_A : \mathcal{F} \rightarrow \mathbb{R}$, definită prin

$$\mathbb{P}_A(X) = \mathbb{P}(X|A), \quad \forall X \in \mathcal{F},$$

este o probabilitate pe spațiul măsurabil (Ω, \mathcal{F}) .

Demonstrație.

1. Conform definiției probabilității condiționate și definiției independenței evenimentelor, obținem

$$\mathbb{P}(B|A) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A) \cdot \mathbb{P}(B)}{\mathbb{P}(A)} = \mathbb{P}(B).$$

Similar deducem $\mathbb{P}(A|B) = \mathbb{P}(A)$. Se constată astfel că două evenimente sunt independente dacă probabilitatea realizării unuia dintre acestea nu este influențată de realizarea celuilalt.

2. Din definiția probabilității condiționate constatăm că are loc relația:

$$\mathbb{P}(A|B) \cdot \mathbb{P}(B) = \mathbb{P}(A \cap B) = \mathbb{P}(B|A) \cdot \mathbb{P}(A).$$

3. Fie evenimentele A_1, A_2, \dots, A_n ($n \geq 2$), cu $\mathbb{P}(\cap_{i=1}^{n-1} A_i) > 0$. Din ipoteză deducem $\mathbb{P}(\cap_{i=1}^k A_i) > 0$, $k = 1, \dots, n-1$ (conform monotoniei crescătoare a probabilității). Atunci

$$\begin{aligned} & \mathbb{P}(A_1) \cdot \mathbb{P}(A_2|A_1) \cdot \mathbb{P}(A_3|A_1 \cap A_2) \cdots \mathbb{P}(A_n|A_1 \cap A_2 \cap \cdots \cap A_{n-1}) \\ &= \mathbb{P}(A_1) \cdot \frac{\mathbb{P}(A_1 \cap A_2)}{\mathbb{P}(A_1)} \cdot \frac{\mathbb{P}(A_1 \cap A_2 \cap A_3)}{\mathbb{P}(A_1 \cap A_2)} \cdots \frac{\mathbb{P}(A_1 \cap A_2 \cap \cdots \cap A_n)}{\mathbb{P}(A_1 \cap A_2 \cap \cdots \cap A_{n-1})} = \mathbb{P}(\cap_{i=1}^n A_i). \end{aligned}$$

4. Verificăm axiomele probabilității.

P1. Evident, $\mathbb{P}_A(X) \geq 0$, $\forall X \in \mathcal{F}$.

P2. Avem $\mathbb{P}_A(\Omega) = \frac{\mathbb{P}(\Omega \cap A)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A)}{\mathbb{P}(A)} = 1$.

P3. Fie un șir $(X_n)_{n \geq 1}$ de evenimente incompatibile mutual. Atunci

$$\mathbb{P}_A(\cup_{n=1}^{\infty} X_n) = \frac{\mathbb{P}((\cup_{n=1}^{\infty} X_n) \cap A)}{\mathbb{P}(A)} = \frac{\mathbb{P}(\cup_{n=1}^{\infty} (X_n \cap A))}{\mathbb{P}(A)} = \frac{\sum_{n=1}^{\infty} \mathbb{P}(X_n \cap A)}{\mathbb{P}(A)} = \sum_{n=1}^{\infty} \mathbb{P}_A(X_n).$$

\mathbb{P}_A se numește probabilitatea condiționată de evenimentul A . \square

Pe de altă parte, conceptul de *evenimente condiționate* permite considerarea *sistemelor complete de evenimente*.

Definiția 1.6.3. O mulțime de evenimente $\mathcal{S} = \{A_i, i \in I\}$, unde I este o mulțime cel mult numărabilă de indici, se numește un sistem complet de evenimente în spațiul de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$ dacă:

1. $A_i \cap A_j = \emptyset, \forall i \neq j$;
2. $\cup_{i \in I} A_i = \Omega$;
3. $\mathbb{P}(A_i) > 0, \forall i \in I$.

Propoziția 1.6.3. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate, iar $\mathcal{S} = \{A_i, i \in I\}$, un sistem complet de evenimente. Au loc formulele:

1. Formula probabilității totale

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A|A_i)\mathbb{P}(A_i), \quad A \in \mathcal{F};$$

2. Formula lui Bayes

$$\mathbb{P}(A_k|A) = \frac{\mathbb{P}(A|A_k)\mathbb{P}(A_k)}{\sum_{i \in I} \mathbb{P}(A|A_i)\mathbb{P}(A_i)}, \quad \forall k \in I, \quad A \in \mathcal{F}, \quad \text{astfel ca } \mathbb{P}(A) > 0.$$

Demonstrație.

1. Avem

$$A = A \cap \Omega = A \cap (\cup_{i \in I} A_i) = \cup_{i \in I} (A \cap A_i).$$

Deoarece evenimentele $A \cap A_i, i \in I$ sunt incompatibile două câte două, obținem

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A \cap A_i) = \sum_{i \in I} \mathbb{P}(A|A_i) \mathbb{P}(A_i),$$

deci formula probabilității totale este demonstrată.

2. Fie $k \in I$. Conform Definiției 1.6.2 și formulei probabilității totale, obținem

$$\mathbb{P}(A_k|A) = \frac{\mathbb{P}(A \cap A_k)}{\mathbb{P}(A)} = \frac{\mathbb{P}(A|A_k)\mathbb{P}(A_k)}{\sum_{i \in I} \mathbb{P}(A|A_i)\mathbb{P}(A_i)},$$

deci formula lui Bayes este demonstrată. \square

În finalul secțiunii, prezentăm două rezultate clasice importante.

Propoziția 1.6.4. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate. Pentru evenimentele A_1, A_2, \dots, A_n are loc următoarea inegalitate:

$$\mathbb{P}(\cap_{i=1}^n A_i) \geq 1 - \sum_{i=1}^n \mathbb{P}(A_i^c).$$

Demonstrație. Fie evenimentele A_1, A_2, \dots, A_n . Avem

$$\mathbb{P}(\cap_{i=1}^n A_i) = 1 - \mathbb{P}((\cap_{i=1}^n A_i)^c) = 1 - \mathbb{P}(\cup_{i=1}^n A_i^c) \stackrel{P12}{\geq} 1 - \sum_{i=1}^n \mathbb{P}(A_i^c).$$

Rezultatul poartă denumirea de *inegalitatea lui Boole*. \square

Teorema 1.6.1 (Legea 0-1 (Borel-Cantelli)). *Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate. Considerăm un șir $(A_n)_{n \in \mathbb{N}^*}$ de evenimente. Notăm*

$$A = \limsup_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k$$

și $s = \sum_{n=1}^{\infty} \mathbb{P}(A_n)$. *Au loc proprietățile:*

a) *dacă $s < \infty$, atunci $\mathbb{P}(A) = 0$;*

b) *dacă $s = \infty$ și evenimentele șirului sunt mutual independente, atunci $\mathbb{P}(A) = 1$.*

Demonstrație.

a) Presupunem $s < \infty$. Atunci $\lim_{n \rightarrow \infty} \sum_{k=n}^{\infty} \mathbb{P}(A_k) = 0$. Are loc convergența $\bigcup_{k=n}^{\infty} A_k \downarrow A$.

Conform proprietăților P11 și P12, obținem

$$\mathbb{P}(A) = \lim_{n \rightarrow \infty} \mathbb{P}(\bigcup_{k=n}^{\infty} A_k) \leq \lim_{n \rightarrow \infty} \sum_{k=n}^{\infty} \mathbb{P}(A_k) = 0.$$

b) Presupunem $s = \infty$. Avem

$$\mathbb{P}(A) = 1 - \mathbb{P}(A^c) = 1 - \mathbb{P}((\bigcap_{n=1}^{\infty} \bigcup_{k=n}^{\infty} A_k)^c) = 1 - \mathbb{P}(\bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k^c).$$

Cum $\bigcap_{k=n}^{\infty} A_k^c \uparrow A^c$ și $\bigcap_{k=n}^{n+p} A_k^c \downarrow \bigcap_{k=n}^{\infty} A_k^c$, obținem

$$\mathbb{P}(\bigcup_{n=1}^{\infty} \bigcap_{k=n}^{\infty} A_k^c) = \lim_{n \rightarrow \infty} \mathbb{P}(\bigcap_{k=n}^{\infty} A_k^c) = \lim_{n \rightarrow \infty} \lim_{p \rightarrow \infty} \mathbb{P}(\bigcap_{k=n}^{n+p} A_k^c) \stackrel{\text{indep.}}{=} \lim_{n \rightarrow \infty} \lim_{p \rightarrow \infty} \prod_{k=n}^{n+p} \mathbb{P}(A_k^c).$$

Deoarece $s = \infty$, avem

$$\lim_{p \rightarrow \infty} \sum_{k=n}^{n+p} \mathbb{P}(A_k) = \sum_{k=n}^{\infty} \mathbb{P}(A_k) = \infty, \quad \forall n \geq 1. \quad (1.1)$$

Din inegalitatea binecunoscută $e^x \geq 1 + x$, $\forall x \in \mathbb{R}$, obținem

$$0 \leq \mathbb{P}(A_k^c) = 1 - \mathbb{P}(A_k) \leq e^{-\mathbb{P}(A_k)}, \quad \forall k \in \mathbb{N}.$$

Rezultă

$$\lim_{p \rightarrow \infty} \prod_{k=n}^{n+p} \mathbb{P}(A_k^c) \leq \lim_{p \rightarrow \infty} \prod_{k=n}^{n+p} e^{-\mathbb{P}(A_k)} = \lim_{p \rightarrow \infty} e^{-\sum_{k=n}^{n+p} \mathbb{P}(A_k)} = e^{-\sum_{k=n}^{\infty} \mathbb{P}(A_k)} \stackrel{(1.1)}{=} 0.$$

Ca urmare, $\mathbb{P}(A) = 1$. \square

1.7 Scheme clasice de probabilitate

Prezentăm în continuare modelele de bază de spații discrete de probabilitate.

1. Câmpul lui Laplace.

Spațiul Ω este considerat o mulțime finită, iar σ -corpul \mathcal{F} este considerat mulțimea $\mathcal{P}(\Omega)$ (mulțimea submulțimilor lui Ω). Probabilitatea unui eveniment $A \subset \Omega$ se definește prin:

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|},$$

unde $|M|$ reprezintă numărul elementelor unei mulțimi finite M . Elementele lui Ω determină evenimentele *elementare*, *echiprobabile*. Astfel, pentru $\omega \in \Omega$, avem

$$\mathbb{P}(\{\omega\}) = \frac{1}{n},$$

unde $n = |\Omega|$.

2. Spațiu discret de evenimente.

Considerăm $\Omega = \{\omega_i : i \in I\}$, unde mulțimea de indici I este cel mult numărabilă. Definim $\mathcal{F} = \mathcal{P}(\Omega)$. Considerăm o măsură de probabilitate $(p_i)_{i \in I}$ pe mulțimea Ω , unde $p_i \geq 0$, $\forall i \in I$ și $\sum_{i \in I} p_i = 1$. Definim $\mathbb{P}(\{\omega_i\}) = p_i$, $i \in I$. Atunci, probabilitatea unui eveniment $A = \{\omega_j : j \in J\}$, cu $J \subset I$, se definește prin

$$\mathbb{P}(A) = \sum_{j \in J} p_j.$$

Modelele de mai sus se materializează concret în *scheme de probabilitate*. Este vorba exemple cu un grad mare de generalitate și utilizare frecventă în *calculul probabilităților*. Prezentăm în continuare cele mai cunoscute scheme de probabilitate.

1. Schema lui Bernoulli.

Este un exemplu de câmp Laplace. Schema modelează următoarea experiență:

O urnă conține c bile, dintre care a sunt albe și b sunt negre ($a+b=c$). Se extrage o bilă, i se înregistrează culoarea, iar apoi se reintroduce în urnă. Se repetă această experiență de n ori. Se studiază probabilitatea evenimentului $A_{k|n}$ al apariției bilei albe de k ori în cele n extrageri (cu repunerea bilei în urnă).

Notăm $P_{k|n} = \mathbb{P}(A_{k|n})$ probabilitatea evenimentului menționat. Un raționament elementar ne conduce la formula de calcul

$$P_{k|n} = C_n^k p^k q^{n-k}, \quad k = 0, 1, \dots, n,$$

unde $p = a/c$ este probabilitatea apariției unei bile la o extragere, iar $q = b/c = 1 - p$ este probabilitatea evenimentului contrar (apariția unei bile negre).

Modelul este echivalent cu repetarea unei experiențe (în condiții identice) de n ori și studiul probabilității realizării unui anumit eveniment de k ori (din totalul de n experiențe).

Remarcăm

$$\sum_{k=0}^n \mathbb{P}(A_{k|n}) = \sum_{k=0}^n P_{k|n} = \sum_{k=0}^n C_n^k p^k q^{n-k} = (q + p)^n = 1,$$

deci evenimentele $A_{k|n}$, $k = 0, 1, \dots, n$, reprezintă un sistem complet.

2. Schema multinomială.

Se consideră o urnă conținând bile de s culori, câte a_i bile din culoarea $i \in \{1, 2, \dots, s\}$. Notăm

$$p_i = \frac{a_i}{\sum_{j=1}^s a_j}$$

probabilitatea extragerii unei bile de culoarea $i \in \{1, 2, \dots, s\}$. Se fac n extrageri, cu repunerea bilei în urnă după fiecare extragere. Fie $\bar{k} = (k_i)_{i=1, \dots, s}$ un vector de dimensiune s , cu componente naturale, având proprietatea $\sum_{i=1}^s k_i = n$. Notăm $A_{\bar{k}|n}$ evenimentul extragerii a n bile având compoziția \bar{k} , adică extragerea a exact k_i bile de culoarea i , unde $i = 1, 2, \dots, s$, din totalul de n bile extrase (cu repunere). Fie $P_{\bar{k}|n} = \mathbb{P}(A_{\bar{k}|n})$. Se constată că

$$P_{\bar{k}|n} = \binom{n}{k_1, k_2, \dots, k_s} p_1^{k_1} p_2^{k_2} \dots p_s^{k_s},$$

unde

$$\binom{n}{k_1, k_2, \dots, k_s} = \frac{n!}{k_1! k_2! \dots k_s!}$$

reprezintă combinările multinomiale de n luate câte k_1, k_2, \dots, k_s .

Avem

$$\begin{aligned} \sum_{\bar{k}=(k_i) \in \mathbb{N}^s, \sum_{i=1}^s k_i=n} P_{\bar{k}|n} &= \sum_{(k_i) \in \mathbb{N}^s; \sum_{i=1}^s k_i=n} \binom{n}{k_1, k_2, \dots, k_s} p_1^{k_1} p_2^{k_2} \dots p_s^{k_s} = \\ &= (p_1 + p_2 + \dots + p_s)^n = 1, \end{aligned}$$

deci $A_{\bar{k}|n}$, cu $\bar{k} = (k_i) \in \mathbb{N}^s$, astfel ca $\sum_{i=1}^s k_i = n$, formează un sistem complet de evenimente. *Schema multinomială*, denumită și *schema polinomială* este o extindere a schemei lui Bernoulli.

3. Schema lui Poisson.

Se consideră n urne cu bile albe și negre, dar în proporții diferite. Fie $p_i \in (0, 1)$ probabilitatea extragerii unei bile albe din urna i . Probabilitatea extragerii unei bile negre din urna i va fi $q_i = 1 - p_i$, $i = 1, 2, \dots, n$. Se extrage câte o bilă din fiecare urnă. Se analizează probabilitatea evenimentului $A_{k|n}$ de a obține exact k bile albe din cele n extrase. Notăm $\mathbb{N}_n = \{1, 2, \dots, n\}$. Avem

$$P_{k|n} = \mathbb{P}(A_{k|n}) = \sum_{I \subset \mathbb{N}_n; |I|=k} \prod_{i \in I} p_i \prod_{j \in \mathbb{N}_n \setminus I} q_j.$$

Observăm că $P_{k|n}$ reprezintă coeficientul lui X^k al polinomului

$$f(X) = (p_1 X + q_1)(p_2 X + q_2) \dots (p_n X + q_n).$$

Astfel, $f(X) = P_{n|n} X^n + P_{n-1|n} X^{n-1} + \dots + P_{1|n} X + P_{0|n}$. Rezultă

$$\sum_{k=0}^n P_{k|n} = f(1) = \prod_{i=1}^n (p_i + q_i) = 1,$$

deci evenimentele $A_{k|n}$, $k = 0, 1, \dots, n$, reprezintă un sistem complet. *Schema lui Poisson* reprezintă o generalizare a schemei lui Bernoulli.

4. *Schema geometrică.*

Schema este un exemplu de spațiu discret de evenimente. Astfel, se repetă continuu o experiență, în condiții identice, urmărindu-se de fiecare dată realizarea unui anumit eveniment A . Fie $\mathbb{P}(A) = p$. Considerăm momentul în care evenimentul A se realizează pentru prima dată. Fie $n \in \mathbb{N}^*$. Probabilitatea ca evenimentul A să se realizeze pentru prima dată în cea de a n -a experiență este

$$p_n = pq^{n-1},$$

unde $q = 1 - p$. Avem

$$\sum_{n=1}^{\infty} p_n = \sum_{n=1}^{\infty} pq^{n-1} = p \sum_{k=0}^{\infty} q^k = \frac{p}{1-q} = 1.$$

5. *Schema hipergeometrică.*

Se consideră o urnă cu N bile, dintre care a bile sunt albe iar restul de b bile sunt negre ($a+b = N$). Se extrag n bile (fără a le repune în urmă după fiecare extragere). Notăm $p_{k|n}$ probabilitatea evenimentului $A_{k|n}$ de a avea exact k bile albe între cele n bile extrase. Presupunem $n \leq N$, $k \leq a$ și $n-k \leq b$. Atunci

$$p_{k|n} = \frac{C_a^k C_b^{n-k}}{C_N^n}.$$

Conform unei formule combinatoriale binecunoscute, obținem

$$\sum_{k=\max\{0, n-b\}}^{\min\{a, n\}} p_{k|n} = \sum_{k=\max\{0, n-b\}}^{\min\{a, n\}} \frac{C_a^k C_b^{n-k}}{C_N^n} = 1,$$

deci $A_{k|n}$, $\max\{0, n-b\} \leq k \leq \min\{a, n\}$, formează un sistem complet de evenimente.

6. *Schema hipergeometrică generalizată.*

Se consideră o urnă cu N bile de s culori. Fie a_i numărul de bile de culoarea i , $i = 1, 2, \dots, s$. Avem deci $\sum_{i=1}^s a_i = N$. Se extrag, fără repunere, n bile. Considerăm vectorul $\bar{k} = (k_i) \in \mathbb{N}^s$, cu $\sum_{i=1}^s k_i = n$, astfel încât $k_i \leq a_i$, $i = 1, 2, \dots, s$. Atunci probabilitatea extragerii a k_i bile din culoarea i , pentru fiecare $i \in \{1, 2, \dots, s\}$, este

$$P_{\bar{k}} = \frac{C_{a_1}^{k_1} C_{a_2}^{k_2} \dots C_{a_s}^{k_s}}{C_N^n}.$$

1.8 Rezumat

În teoria probabilităților, evenimentele rezultate în urma unei experiențe sunt interpretate ca o familie de submulțimi ale evenimentului sigur, mulțimea Ω . Mulțimea evenimentelor formează un σ -corp (borelian).

O mulțime nevidă $\mathcal{F} \subset \Omega$ se numește σ -corp a lui Ω dacă satisface următoarele condiții:

$$\sigma_1. A^c \in \mathcal{F}, \forall A \in \mathcal{F};$$

$$\sigma_2. \text{ dacă } A_n \in \mathcal{F}, \forall n \in \mathbb{N}^* \text{ atunci } \bigcup_{n=1}^{\infty} A_n \in \mathcal{F}.$$

Perechea (Ω, \mathcal{F}) se numește spațiu măsurabil sau spațiu de evenimente.

Borelianul lui $\Omega = \mathbb{R}$, notat $\mathcal{B}_{\mathbb{R}}$ este σ -corpul generat de mulțimile deschise (topologia lui \mathbb{R}), adică cel mai mic σ -corp a lui \mathbb{R} care include mulțimile deschise. $\mathcal{B}_{\mathbb{R}}$ conține toate tipurile de intervale și este generat de oricare tip de intervale reale.

Fie (Ω, \mathcal{F}) și (Ω', \mathcal{F}') o pereche de spații măsurabile (câmpuri de evenimente). O funcție $f : \Omega \rightarrow \Omega'$ se numește *funcție măsurabilă* dacă

$$f^{-1}(A) \in \mathcal{F}, \forall A \in \mathcal{F}',$$

unde $f^{-1}(A) = \{\omega \in \Omega \mid f(\omega) \in A\}$.

În particular, dacă $\Omega' = \mathbb{R}$ și $\mathcal{F}' = \mathcal{B}_{\mathbb{R}}$, funcția f se va numi *funcție reală măsurabilă*. Pentru o funcție reală măsurabilă $f : \Omega \rightarrow \mathbb{R}$, avem:

- $\{f \leq a\} := f^{-1}((-\infty, a]) \in \mathcal{F}, \forall a \in \mathbb{R}$
- $\{f > a\} := f^{-1}((a, \infty)) \in \mathcal{F}, \forall a \in \mathbb{R}$
- $\{a \leq f \leq b\} := f^{-1}([a, b]) \in \mathcal{F}, \forall a, b \in \mathbb{R}, a < b.$

Dacă $f, g : \Omega \rightarrow \mathbb{R}$ sunt funcții reale măsurabile și $a \in \mathbb{R}$ atunci funcțiile reale $f + a$, af , $|f|$, $f + g$, fg , $\min\{f, g\}$ și $\max\{f, g\}$ sunt măsurabile.

Fie (Ω, \mathcal{F}) un spațiu măsurabil, cu σ -corpul \mathcal{F} denumit "mulțimea evenimentelor". O funcție $\mathbb{P} : \mathcal{F} \rightarrow \mathbb{R}$ se numește probabilitate dacă satisface următoarele axiome:

$$P1. \mathbb{P}(A) \geq 0, \forall A \in \mathcal{F};$$

$$P2. \mathbb{P}(\Omega) = 1;$$

P3. Pentru oricare șir de evenimente $(A_n)_{n \in \mathbb{N}^*}$, cu $A_n \cap A_m = \emptyset, \forall n \neq m$, are loc relația

$$\mathbb{P}(\bigcup_{n=1}^{\infty} A_n) = \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Tripletul $(\Omega, \mathcal{F}, \mathbb{P})$ se numește spațiu de probabilitate.

Probabilitatea are proprietățile:

$$P4. \mathbb{P}(\emptyset) = 0;$$

$$P5. \mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B), \forall A, B \in \mathcal{F}, A \cap B = \emptyset;$$

P6. $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$, $\forall A \in \mathcal{F}$;

P7. $\mathbb{P}(A \setminus B) = \mathbb{P}(A) - \mathbb{P}(B)$, $\forall A, B \in \mathcal{F}$, $B \subset A$;

P8. $\mathbb{P}(A) \leq \mathbb{P}(B)$, $\forall A, B \in \mathcal{F}$, $A \subset B$;

P9. $\mathbb{P}(A) \in [0, 1]$, $\forall A \in \mathcal{F}$;

P10. (Formula lui Poincaré)

$$\mathbb{P}(\cup_{i=1}^n A_i) = \sum_{k=1}^n (-1)^{k+1} \sum_{1 \leq i_1 < i_2 < \dots < i_k \leq n} \mathbb{P}(\cap_{j=1}^k A_{i_j});$$

P11. Dacă $(A_n)_{n \geq 1}$ este un şir monoton (crescător sau descrescător) de evenimente, cu $\lim_{n \rightarrow \infty} A_n = A$, atunci $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \mathbb{P}(A)$.

P12. Pentru oricare şir de evenimente $(A_n)_{n \in \mathbb{N}^*}$ avem

$$\mathbb{P}(\cup_{n=1}^{\infty} A_n) \leq \sum_{n=1}^{\infty} \mathbb{P}(A_n).$$

Considerăm un eveniment $A \in \mathcal{F}$, cu $\mathbb{P}(A) > 0$. Pentru oricare eveniment $B \in \mathcal{F}$, numim probabilitatea lui B condiționată de (realizarea evenimentului) A mărimea:

$$\mathbb{P}(B|A) := \frac{\mathbb{P}(B \cap A)}{\mathbb{P}(A)}.$$

Evenimentele A și B se numesc independente dacă $\mathbb{P}(B|A) = \mathbb{P}(B)$, adică $\mathbb{P}(A \cap B) = \mathbb{P}(A)\mathbb{P}(B)$.

Mai general, $\mathcal{G} \subset \mathcal{F}$ se numește familie de evenimente independente dacă pentru oricare evenimente distincte $A_1, A_2, \dots, A_n \in \mathcal{G}$ avem

$$\mathbb{P}(\cap_{i=1}^n A_i) = \prod_{i=1}^n \mathbb{P}(A_i).$$

Astfel, două evenimente sunt independente dacă probabilitatea realizării unuia dintre acestea nu este influențată de realizarea celuilalt.

Evenimentele A_i , $i \in I$, unde I este o mulțime cel mult numărabilă de indici, formează un sistem complet de evenimente în spațiul de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$ dacă:

1. $A_i \cap A_j = \emptyset$, $\forall i \neq j$
2. $\cup_{i \in I} A_i = \Omega$
3. $\mathbb{P}(A_i) > 0$, $\forall i \in I$

Dacă A este un eveniment cu probabilitate nenulă (neneglijabil), atunci loc:

1. Formula probabilității totale

$$\mathbb{P}(A) = \sum_{i \in I} \mathbb{P}(A|A_i)\mathbb{P}(A_i)$$

2. Formula lui Bayes

$$\mathbb{P}(A_k|A) = \frac{\mathbb{P}(A|A_k)\mathbb{P}(A_k)}{\sum_{i \in I} \mathbb{P}(A|A_i)\mathbb{P}(A_i)}, \quad \forall k \in I.$$

Modelele de bază de câmpuri de probabilitate discrete:

1. Câmpul lui Laplace.

Spațiul Ω este considerat o mulțime finită, iar σ -corpul \mathcal{F} este considerat mulțimea $\mathcal{P}(\Omega)$ (mulțimea submulțimilor lui Ω). Probabilitatea unui eveniment $A \subset \Omega$ se definește prin:

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|},$$

unde $|M|$ reprezintă numărul elementelor unei mulțimi finite M . Elementele lui Ω determină evenimentele *elementare*, *echiprobabile*. Astfel, pentru $\omega \in \Omega$, avem

$$\mathbb{P}(\{\omega\}) = \frac{1}{n},$$

unde $n = |\Omega|$.

2. Spațiu discret de evenimente.

Considerăm $\Omega = \{\omega_i : i \in I\}$, unde mulțimea de indici I este cel mult numărabilă. Definim $\mathcal{F} = \mathcal{P}(\Omega)$. Considerăm o măsură de probabilitate $(p_i)_{i \in I}$ pe mulțimea Ω , unde $p_i \geq 0$, $\forall i \in I$ și $\sum_{i \in I} p_i = 1$. Probabilitatea unui eveniment $A = \{\omega_j : j \in J\}$, cu $J \subset I$, se definește prin

$$\mathbb{P}(A) = \sum_{j \in J} p_j.$$

Schemele de probabilitate reprezintă modele/exemple cu un grad mare de generalitate în calculul probabilităților.

1. Schema lui Bernoulli.

Este un exemplu de câmp Laplace. Schema modelează următoarea experiență:

O urnă conține c bile, dintre care a sunt albe și b sunt negre ($a+b=c$). Se extrage o bilă, i se înregistrează culoarea, iar apoi se reintroduce în urnă. Se repetă această experiență de n ori. Se studiază probabilitatea evenimentului $A_{k|n}$ al apariției bilei albe de k ori din cele n extrageri (cu repunerea bilei în urnă).

Notăm $\mathbb{P}_{k|n} = \mathbb{P}(A_{k|n})$ probabilitatea evenimentului menționat. Avem

$$\mathbb{P}_{k|n} = C_n^k p^k q^{n-k}, \quad k = 0, 1, \dots, n,$$

unde $p = a/c$ este probabilitatea apariției unei bile la o extragere, iar $q = b/c = 1 - p$ este probabilitatea evenimentului contrar (apariția unei bile negre).

2. Schema multinomială.

Este o extindere a schemei lui Bernoulli.

Se consideră o urnă conținând bile de s culori, câte a_i bile din culoarea $i \in \{1, 2, \dots, s\}$.

Notăm

$$p_i = \frac{a_i}{\sum_{j=1}^s a_j}$$

probabilitatea extragerii unei bile de culoarea $i \in \{1, 2, \dots, s\}$. Se fac n extrageri, cu repunerea bilei în urnă după fiecare extragere. Fie $(k_i)_{i=\overline{1,s}}$ un vector de dimensiune s , cu componente naturale, având proprietatea $\sum_{i=1}^s k_i = n$. Notăm

$$\mathbb{P}_{(k_i)_{i=\overline{1,s}}|n}$$

probabilitatea evenimentului $A_{(k_i)_{i=\overline{1,s}}|n}$ de extragere a exact k_i bile de culoarea i , unde $i = 1, 2, \dots, s$, din totalul de n bile extrase. Avem

$$\mathbb{P}_{(k_i)_{i=\overline{1,s}}|n} = \binom{n}{k_1, k_2, \dots, k_s} p_1^{k_1} p_2^{k_2} \dots p_s^{k_s},$$

unde

$$\binom{n}{k_1, k_2, \dots, k_s} = \frac{n!}{k_1! k_2! \dots k_s!}$$

reprezintă combinările multinomiale de n luate câte k_1, k_2, \dots, k_s .

3. Schema lui Poisson.

Reprezintă o generalizare a schemei lui Bernoulli. Se consideră n urne cu bile albe și negre, dar în proporții diferite. Fie p_i probabilitatea extragerii unei bile albe din urna i . Probabilitatea extragerii unei bile negre din urna i va fi $q_i = 1 - p_i$, $i = 1, 2, \dots, n$. Se extrage câte o bilă din fiecare urnă. Se analizează probabilitatea evenimentului $A_{k|n}$ de a obține exact k bile albe din cele n extrase. Notăm $\mathbb{N}_n = \{1, 2, \dots, n\}$. Avem

$$\mathbb{P}_{k|n} = \mathbb{P}(A_{k|n}) = \sum_{I \subset \mathbb{N}_n; |I|=k} \prod_{i \in I} p_i \prod_{j \in \mathbb{N}_n \setminus I} q_j.$$

Observăm că $\mathbb{P}_{k|n}$ reprezintă coeficientul lui x^k al polinomului

$$f(x) = (p_1 x + q_1)(p_2 x + q_2) \dots (p_n x + q_n).$$

4. Schema geometrică.

Schema este un exemplu de câmp discret de evenimente. Astfel, se repetă continuu o experiență, în condiții identice, urmărindu-se de fiecare dată realizarea unui anumit eveniment A . Fie $\mathbb{P}(A) = p$. Considerăm momentul în care evenimentul A se realizează pentru prima dată. Fie $n \in \mathbb{N}^*$. Probabilitatea ca evenimentul A să se realizeze pentru prima dată în cea de a n -a experiență este

$$p_n = pq^{n-1},$$

unde $q = 1 - p$.

5. Schema hipergeometrică.

Se consideră o urnă cu N bile, dintre care a bile sunt albe iar restul de b bile sunt negre ($a + b = N$). Se extrag n bile (fără a le repune în urmă după fiecare extragere). Notăm $p_{k|n}$ probabilitatea evenimentului $A_{k|n}$ de a avea exact k bile albe între cele n bile extrase. Presupunem $n \leq N$, $k \leq a$ și $n - k \leq b$. Atunci

$$p_{k|n} = \frac{C_a^k C_b^{n-k}}{C_N^n}.$$

1.9 Test

1. Definiți noțiunea de evenimente condiționate. Enunțați și demonstrați formula probabilității totale.
2. Aplicați formula lui Poincaré pentru n evenimente independente, echiprobabile, de probabilitate $p \in (0, 1)$.
3. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate și evenimentele $A, B \in \mathcal{F}$. Știind că $\mathbb{P}(A) = 1/5$, $\mathbb{P}(B) = 3/5$ și $\mathbb{P}(A \cap B) = 1/10$, să se calculeze probabilitățile:
 - (a) $\mathbb{P}(A \cup B)$;
 - (b) $\mathbb{P}(A \cap \overline{B})$;
 - (c) $\mathbb{P}(A|B) = \mathbb{P}_B(A)$.
4. Un sportiv trage la o țintă cu 5 puști diferite, cu probabilitățile respective de ochire: $p_1 = 0,8$, $p_2 = 0,7$, $p_3 = 0,4$, $p_4 = 0,9$ și $p_5 = 0,5$. Să se calculeze:
 - (a) probabilitatea ca ținta să fie nimerită de exact 3 ori;
 - (b) probabilitatea ca ținta să nimerită cel puțin o dată.
5. Un portar apără o lovitură de la 11 metri cu probabilitatea $p = 0,3$. La finalul unui meci, se execută 5 lovituri de la 11 metri.
 - (a) Care este probabilitatea ca portarul respectiv să apere exact 2 lovituri?
 - (b) Care este cel mai probabil număr de goluri primite?
6. Care este probabilitatea de a nimeri exact doua numere la jocul *Loto 6 din 49*, dacă se joacă o singură variantă?
7. Un baschetbalist execută aruncări de la distanță la un panou de baschet, până la prima reușită. Știind că șansa de reușită a fiecărei aruncări este de 20%, să se determine probabilitatea ca sportivul să înscrie primul coș din a patra aruncare. Care este cel mai probabil număr de aruncări până la prima reușită?

Capitolul 2

Variabile aleatoare. Caracteristici numerice

2.1 Introducere

2.2 Variabile aleatoare

Variabilele aleatoare se interpretează ca o ”enumerare” a rezultatelor posibile, exprimabile prin numere reale, ale unui anumit experiment. Fiecare dintre aceste rezultate posibile are o probabilitate de realizare. Definiția de mai jos formalizează matematic un experiment cu rezultate aleatoare, predictibile.

Definiția 2.2.1. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate. O funcție reală măsurabilă $X : \Omega \rightarrow \mathbb{R}$ se numește variabilă aleatoare.

Conform definiției, pentru o variabilă aleatoare X definită pe spațiul de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$, avem

$$X^{-1}(I) = \{\omega \in \Omega : X(\omega) \in I\} \stackrel{\text{notat}}{=} \{X \in I\} \in \mathcal{F},$$

pentru orice interval real I . În particular,

$$\{X \in (-\infty, a]\} = \{X \leq a\} \in \mathcal{F}, \quad \forall a \in \mathbb{R}. \quad (2.1)$$

Probabilitățile evenimentelor descrise în relația (2.1) oferă informații importante despre repartiția valorilor variabilei aleatoare X . În secțiunea următoare, va fi introdusă și caracterizată funcția de repartiție a unei variabile aleatoare, construită pe baza probabilităților evenimentelor menționate mai sus.

O mulțime finită de variabile aleatoare definite pe același spațiu de probabilitate va determina un vector aleator. Mai precis, avem următoarea definiție.

Definiția 2.2.2. Fie $d > 1$ un număr întreg și $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate. Considerăm borelianul $\mathcal{B}_{\mathbb{R}^d}$ spațiului \mathbb{R}^d (σ – corpul generat de topologia lui \mathbb{R}^d). O funcție $(\mathcal{F}, \mathcal{B}_{\mathbb{R}^d})$ măsurabilă $X : \Omega \rightarrow \mathbb{R}^d$ se numește vector aleator.

Fie X_i , $i = 1, 2, \dots, d$, componentele scalare ale vectorului aleator $X : \Omega \rightarrow \mathbb{R}^d$, deci $X = (X_1, X_2, \dots, X_d)$. Deoarece σ -corpul $\mathcal{B}_{\mathbb{R}^d}$ conține toate tipurile de intervale

d -dimensionale din spațiul \mathbb{R}^d , avem

$$(-\infty, a_1] \times (-\infty, a_2] \times \cdots \times (-\infty, a_d] \in \mathcal{B}_{\mathbb{R}^d}, \quad \forall a_1, a_2, \dots, a_d \in \mathbb{R}.$$

Ca urmare, din Definiția 2.2.2, rezultă

$$\{X_1 \leq a_1, X_2 \leq a_2, \dots, X_d \leq a_d\} = \left\{ X \in \prod_{i=1}^d (-\infty, a_i] \right\} \in \mathcal{F}, \quad \forall (a_1, a_2, \dots, a_d) \in \mathbb{R}^d.$$

2.3 Funcția de repartiție

Distribuția valorilor unei variabile aleatoare reale este caracterizată prin noțiunea de funcție de repartiție. De regulă, spațiul de probabilitate pe care este definită variabila aleatoare nu este menționat în mod explicit.

Definiția 2.3.1. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate și $X : \Omega \rightarrow \mathbb{R}$ o variabilă aleatoare. Funcția reală $F : \mathbb{R} \rightarrow [0, 1]$, definită prin

$$F(x) = \mathbb{P}\{X \leq x\} = \mathbb{P}(\{\omega \in \Omega : X(\omega) \leq x\}), \quad x \in \mathbb{R},$$

se numește funcția de repartiție a variabilei aleatoare X .

Propoziția următoare grupează proprietățile de bază ale unei funcții de repartiție.

Propoziția 2.3.1. Funcția de repartiție $F : \mathbb{R} \rightarrow [0, 1]$ a unei variabile aleatoare X are următoarele proprietăți:

1. F este monoton crescătoare pe \mathbb{R} ;
2. F este continuă la dreapta în orice număr real, deci $F(x) = F(x+0)$, $\forall x \in \mathbb{R}$;
3. $\lim_{x \rightarrow -\infty} F(x) = 0$; $\lim_{x \rightarrow \infty} F(x) = 1$;
4. $F(x-0) := \lim_{t \uparrow x} F(t) = \mathbb{P}\{X < x\}$, $\forall x \in \mathbb{R}$;
5. $\mathbb{P}\{X = x\} = F(x) - F(x-0)$, $\forall x \in \mathbb{R}$;
6. $\mathbb{P}\{a < X \leq b\} = F(b) - F(a)$, $\forall a, b \in \mathbb{R}$, cu $a < b$;
7. $\mathbb{P}\{X > x\} = 1 - F(x)$, $\forall x \in \mathbb{R}$.

Demonstrație.

Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate și $X : \Omega \rightarrow \mathbb{R}$ o variabilă aleatoare.

1. Fie $x_1, x_2 \in \mathbb{R}$, cu $x_1 < x_2$. Atunci $\{X \leq x_1\} \subset \{X \leq x_2\}$. Cum funcția \mathbb{P} este monoton crescătoare, deducem $\mathbb{P}\{X \leq x_1\} \leq \mathbb{P}\{X \leq x_2\}$, sau $F(x_1) \leq F(x_2)$. Prin urmare, F este monoton crescătoare pe \mathbb{R} .

2. Orice funcție monotonă pe un interval admite limite laterale finite în fiecare punct al intervalului. Dacă intervalul este deschis, atunci funcția admite limite în extremitățile intervalului. Mai mult, mulțimea punctelor de discontinuitate ale unei astfel de funcții este cel mult numărabilă. Funcția F este monoton crescătoare pe \mathbb{R} , deci admite limite

laterale finite în toate numerele reale. Mai precis, pentru oricare $x \in \mathbb{R}$, limita la stânga a funcției F în punctul x este $F(x-0) = \sup_{t < x} F(t)$, iar limita la dreapta a funcției F în punctul x este $F(x+0) = \inf_{t > x} F(t)$. În plus, au loc inegalitățile:

$$F(x-0) \leq F(x) \leq F(x+0), \quad \forall x \in \mathbb{R}.$$

Fixăm $x \in \mathbb{R}$, arbitrar. Notăm $A = \{X \leq x\}$ și $A_n = \{X \leq x + \frac{1}{n}\} \in \mathcal{F}$, $\forall n \in \mathbb{N}^*$. Șirul $(A_n)_{n \in \mathbb{N}^*}$ este monoton descrescător ($A_{n+1} \subset A_n$, $\forall n \in \mathbb{N}^*$) și $\lim_{n \rightarrow \infty} A_n = \bigcap_{n=1}^{\infty} A_n = A$ (notăm $A_n \downarrow A$). Conform Propoziției 1.5.1, avem $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \mathbb{P}(A)$. Dar $\mathbb{P}(A) = F(x)$

și $\lim_{n \rightarrow \infty} \mathbb{P}(A_n) = \lim_{n \rightarrow \infty} F\left(x + \frac{1}{n}\right) = F(x+0)$. Obținem $F(x+0) = F(x)$, deci F este continuă la dreapta în punctul x .

3. Conform monotoniei, F admite limite la ∞ și $-\infty$. Deoarece $F(\mathbb{R}) \subset [0, 1]$, aceste limite sunt finite. Mai precis,

$$\lim_{x \rightarrow -\infty} F(x) = \inf_{x \in \mathbb{R}} F(x) \geq 0$$

și

$$\lim_{x \rightarrow \infty} F(x) = \sup_{x \in \mathbb{R}} F(x) \leq 1.$$

Definim șirurile de evenimente

$$B_n = \{X \leq -n\} \text{ și } C_n = \{X \leq n\}, \quad n \in \mathbb{N}^*.$$

Avem $B_n \downarrow \bigcap_{n=1}^{\infty} B_n = \emptyset$, respectiv $C_n \uparrow \bigcup_{n=1}^{\infty} C_n = \Omega$. Ca urmare,

$$\lim_{x \rightarrow -\infty} F(x) = \lim_{n \rightarrow \infty} F(-n) = \lim_{n \rightarrow \infty} \mathbb{P}(B_n) = \mathbb{P}(\emptyset) = 0,$$

respectiv

$$\lim_{x \rightarrow \infty} F(x) = \lim_{n \rightarrow \infty} F(n) = \lim_{n \rightarrow \infty} \mathbb{P}(C_n) = \mathbb{P}(\Omega) = 1.$$

4. Fie $x \in \mathbb{R}$, arbitrar, fixat. Conform proprietăților unei funcții monoton crescătoare și Propoziției 1.5.1, avem

$$\begin{aligned} F(x-0) &= \lim_{t \uparrow x} F(t) = \lim_{n \rightarrow \infty} F\left(x - \frac{1}{n}\right) = \lim_{n \rightarrow \infty} \mathbb{P}\left\{X \leq x - \frac{1}{n}\right\} = \\ &= \mathbb{P}\left(\lim_{n \rightarrow \infty} \left\{X \leq x - \frac{1}{n}\right\}\right) = \mathbb{P}\left(\bigcup_{n=1}^{\infty} \left\{X \leq x - \frac{1}{n}\right\}\right) = \mathbb{P}\{X < x\}. \end{aligned}$$

5. Pentru $x \in \mathbb{R}$, avem

$$\mathbb{P}\{X = x\} = \mathbb{P}(\{X \leq x\} \setminus \{X < x\}) = \mathbb{P}\{X \leq x\} - \mathbb{P}\{X < x\} = F(x) - F(x-0).$$

6. Fie $a, b \in \mathbb{R}$, $a < b$. Avem $\{a < X \leq b\} = \{X \leq b\} \setminus \{X \leq a\}$ și $\{X \leq a\} \subset \{X \leq b\}$. Atunci, conform Propoziției 1.5.1,

$$\mathbb{P}\{a < X \leq b\} = \mathbb{P}\{X \leq b\} - \mathbb{P}\{X \leq a\} = F(b) - F(a).$$

7. Fie $x \in \mathbb{R}$. Avem $\mathbb{P}\{X > x\} = \mathbb{P}\{X \leq x\}^c = 1 - \mathbb{P}\{X \leq x\} = 1 - F(x)$. \square

Din Propoziția 2.3.1, punctul 5, rezultă următoarea proprietate: dacă F este continuă în $x_0 \in \mathbb{R}$, atunci $\mathbb{P}\{X = x_0\} = 0$.

Menționăm următorul rezultat fundamental: pentru orice funcție $F : \mathbb{R} \rightarrow [0, 1]$ care satisface proprietățile 1-3 din Propoziția 2.3.1, există un spațiu de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$ și o variabilă aleatoare $X : \Omega \rightarrow \mathbb{R}$ astfel încât F să reprezinte funcția de repartiție a variabilei aleatoare X .

Două variabile aleatoare X și Y care admit o funcție de repartiție comună vor fi denumite *identic distribuite*. Notăm $X \stackrel{d}{=} Y$.

Definim funcția de repartiție a unui vector aleator, care prezintă proprietăți generale apropiate de cele ale funcției de repartiție a unei variabile aleatoare.

Definiția 2.3.2. Fie $X = (X_1, X_2, \dots, X_d)$ un vector aleator. Definim funcția sa de repartiție prin $F : \mathbb{R}^d \rightarrow [0, 1]$,

$$F(x_1, x_2, \dots, x_d) = \mathbb{P}\{X_1 \leq x_1, X_2 \leq x_2, \dots, X_d \leq x_d\}, \quad (x_1, x_2, \dots, x_d) \in \mathbb{R}^d.$$

2.4 Variabile aleatoare independente

O noțiune importantă este *independența variabilelor aleatoare*, definită mai jos.

Definiția 2.4.1. Variabilele aleatoare X_i , $i \in I$, definite pe un spațiu de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$, se numesc *independente* dacă, pentru oricare oricare indici distincți i_1, i_2, \dots, i_n din mulțimea I și oricare $A_1, A_2, \dots, A_n \in \mathcal{B}_{\mathbb{R}}$ are loc

$$\mathbb{P}\{X_{i_1} \in A_1, X_{i_2} \in A_2, \dots, X_{i_n} \in A_n\} = \mathbb{P}\{X_{i_1} \in A_1\} \mathbb{P}\{X_{i_2} \in A_2\} \cdots \mathbb{P}\{X_{i_n} \in A_n\}.$$

În particular, dacă variabilele aleatoare X_1, X_2, \dots, X_n , având, respectiv, funcțiile de repartiție F_1, F_2, \dots, F_n , sunt independente, atunci

$$\mathbb{P}\{X_1 \leq a_1, X_2 \leq a_2, \dots, X_n \leq a_n\} = F_1(a_1)F_2(a_2) \cdots F_n(a_n), \quad \forall a_1, a_2, \dots, a_n \in \mathbb{R}.$$

Are loc următorul rezultat de bază privind suma a două variabile aleatoare independente.

Propoziția 2.4.1. Fie variabilele aleatoare independente X și Y , având funcțiile de repartiție F și respectiv G . Atunci funcția de repartiție a variabilei aleatoare $Z = X + Y$ este funcția $F * G$ (convoluția funcțiilor de repartiție F și G), definită prin:

$$(F * G)(x) = \int_{-\infty}^{\infty} F(x - t) dG(t), \quad \forall x \in \mathbb{R}.$$

Variabilele aleatoare cu valori într-o mulțime cel mult numărabilă se numesc *discrete*. Variabilele aleatoare cu funcția de repartiție derivabilă, cu derivata continuă, se numesc *continue*. Vom ilustra prin exemple semnificative cele două tipuri de variabile aleatoare.

2.5 Variabile aleatoare discrete. Exemple clasice

În cele ce urmează, definim și caracterizăm variabilele aleatoare de tip discret.

Definiția 2.5.1. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate și $X : \Omega \rightarrow \mathbb{R}$ o variabilă aleatoare. X se numește variabilă aleatoare discretă dacă mulțimea $X(\Omega)$ este cel mult numărabilă.

Fie $X(\Omega) = \{x_i, i \in I\} \subset \mathbb{R}$, unde I este o mulțime de indici cel mult numărabilă. Notăm $A_i = \{X = x_i\} \in \mathcal{F}$, $i \in I$. Vom presupune $\mathbb{P}(A_i) > 0$, $\forall i \in I$. Atunci familia de evenimente $\{A_i, i \in I\}$ reprezintă un sistem complet de evenimente al spațiului de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$.

Pentru $A \in \mathcal{F}$, notăm prin $c_A : \Omega \rightarrow \mathbb{R}$ funcția caracteristică a mulțimii A , definită prin

$$c_A(\omega) = \begin{cases} 1, & \omega \in A \\ 0, & \omega \in \Omega \setminus A = A^c \end{cases}.$$

Este elementar de verificat faptul că funcția caracteristică a unui eveniment este o variabilă aleatoare. Are loc următoarea reprezentare a variabilei aleatoare discrete X :

$$X = \sum_{i \in I} x_i c_{A_i}.$$

Notăm $p_i = \mathbb{P}(A_i)$, $i \in I$. Avem $p_i > 0$, $\forall i \in I$ și

$$\sum_{i \in I} p_i = \sum_{i \in I} \mathbb{P}(A_i) = \mathbb{P}(\cup_{i \in I} A_i) = \mathbb{P}(\Omega) = 1.$$

Distribuția variabilei aleatoare X se reprezintă convențional prin:

$$X : \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}.$$

Fie variabilele aleatoare discrete, independente, X și Y , cu distribuțiile

$$X : \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}, \quad Y : \begin{pmatrix} y_j \\ p'_j \end{pmatrix}_{j \in J}.$$

Variabila aleatoare $X + Y$ are distribuția

$$X + Y : \begin{pmatrix} x_i + y_j \\ p_i p'_j \end{pmatrix}_{(i,j) \in I \times J},$$

iar variabila aleatoare XY are distribuția

$$XY : \begin{pmatrix} x_i y_j \\ p_i p'_j \end{pmatrix}_{(i,j) \in I \times J}.$$

Exemplul 2.5.1. Variabile aleatoare Bernoulli.

O variabilă aleatoare Bernoulli X ia doar două valori: valoarea 1 cu probabilitatea $p \in (0, 1)$ și valoarea 0 cu probabilitatea $q = 1 - p$. Distribuția lui X se reprezintă astfel:

$$X : \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}.$$

Notăm $X \sim B(1, p)$. Semnificația unei variabile aleatoare Bernoulli de parametru $p \in (0, 1)$ este următoarea: în cadrul unei experiențe, urmărim producerea unui anumit eveniment A care are probabilitatea de apariție $\mathbb{P}(A) = p$; variabila aleatoare Bernoulli indică prin valoarea 1 realizarea evenimentului A , iar prin valoarea 0 nerealizarea evenimentului respectiv. Constatăm că X este funcția caracteristică c_A a evenimentului A .

Exemplul 2.5.2. *Variabile aleatoare binomiale.*

O variabilă aleatoare binomială X de parametri $n \in \mathbb{N}^*$ și $p \in (0, 1)$ ia toate valorile $k \in \{0, 1, \dots, n\}$, cu probabilitățile $p_k = \mathbb{P}\{X = k\} = C_n^k p^k q^{n-k}$, unde $q = 1 - p \in (0, 1)$. Variabila aleatoare X are deci distribuția:

$$X : \begin{pmatrix} 0 & 1 & 2 & \dots & n \\ C_n^0 q^n & C_n^1 p q^{n-1} & C_n^2 p^2 q^{n-2} & \dots & C_n^n p^n \end{pmatrix}.$$

Avem

$$\sum_{k=0}^n p_k = \sum_{k=0}^n C_n^k p^k q^{n-k} = (q + p)^n = 1.$$

Notăm $X \sim B(n, p)$. O variabilă aleatoare binomială indică numărul de realizări ale unui eveniment A , având probabilitatea $p = \mathbb{P}(A)$, în n experiențe identice și independente. Astfel, variabilele binomiale modelează schema binomială (Bernoulli).

Este important de remarcat că o variabilă aleatoare binomială de parametri (n, p) este suma a n variabile aleatoare Bernoulli de parametru p , independente.

Propoziția 2.5.1. *Fie n variabile aleatoare independente și identic distribuite X_1, \dots, X_n , cu $X_i \sim B(1, p)$, pentru $i = 1, \dots, n$. Dacă $X = \sum_{i=1}^n X_i$, atunci $X \sim B(n, p)$.*

Demonstrație. Deoarece $X_i \in \{0, 1\}$, $i = 1, \dots, n$, avem $X \in \{0, 1, \dots, n\}$. Notăm $p_k = \mathbb{P}\{X = k\}$, $k = 0, 1, \dots, n$. Atunci:

$$p_0 = \mathbb{P}\{X_1 = 0, \dots, X_n = 0\} = \mathbb{P}(\cap_{i=0}^n \{X_i = 0\}) \stackrel{\text{indep.}}{=} \prod_{i=1}^n \mathbb{P}\{X_i = 0\} = q^n;$$

$$p_n = \mathbb{P}\{X_1 = 1, \dots, X_n = 1\} = \mathbb{P}(\cap_{i=0}^n \{X_i = 1\}) \stackrel{\text{indep.}}{=} \prod_{i=1}^n \mathbb{P}\{X_i = 1\} = p^n;$$

pentru $1 < k < n$,

$$\begin{aligned} p_k &= \sum_{I \subset \{1, \dots, n\}, |I|=k} \mathbb{P}\{X_i = 1, \forall i \in I; X_j = 0, \forall j \in \{1, \dots, n\} \setminus I\} = \\ &= \sum_{I \subset \{1, \dots, n\}, |I|=k} \mathbb{P}[(\cap_{i \in I} \{X_i = 1\}) \cap (\cap_{j \in \{1, \dots, n\} \setminus I} \{X_j = 0\})] = \\ &\stackrel{\text{indep.}}{=} \sum_{I \subset \{1, \dots, n\}, |I|=k} \left(\prod_{i \in I} \mathbb{P}\{X_i = 1\} \right) \cdot \left(\prod_{j \in I^c} \mathbb{P}\{X_j = 0\} \right) = C_n^k p^k q^{n-k}. \end{aligned}$$

Rezultă $X \sim B(n, p)$. \square

Exemplul 2.5.3. *Variabile aleatoare Poisson.*

O variabilă aleatoare X este de tip Poisson de parametru λ dacă ia toate valorile naturale, cu probabilitățile:

$$p_n = \mathbb{P}\{X = n\} = \frac{\lambda^n}{n!} e^{-\lambda}, \quad n \in \mathbb{N}.$$

Astfel, X are distribuția:

$$X : \left(\frac{\lambda^n}{n!} e^{-\lambda} \right)_{n \in \mathbb{N}}.$$

Notăm $X \sim P(\lambda)$. Avem

$$\sum_{n=0}^{\infty} p_n = \sum_{n=0}^{\infty} \frac{\lambda^n}{n!} e^{-\lambda} = e^{-\lambda} \sum_{n=0}^{\infty} \frac{\lambda^n}{n!} = e^{-\lambda} e^{\lambda} = 1.$$

Exemplul 2.5.4. *Variabile aleatoare geometrice.*

O variabilă aleatoare geometrică X de parametru $p \in (0, 1)$ ia valoarea $n \in \mathbb{N}^*$ cu probabilitatea $p_n = \mathbb{P}\{X = n\} = pq^{n-1}$, unde $q = 1 - p \in (0, 1)$. Astfel, X are distribuția:

$$X : \left(pq^{n-1} \right)_{n \in \mathbb{N}^*}.$$

Notăm $X \sim G(p)$. Avem

$$\sum_{n=1}^{\infty} p_n = \sum_{n=1}^{\infty} pq^{n-1} = p \sum_{n=1}^{\infty} q^{n-1} = p \cdot \frac{1}{1-q} = 1.$$

Variabila aleatoare geometrică de parametru p indică numărul de experiențe, identice și independente, efectuate până la realizarea (aparitia), pentru prima dată, a unui eveniment A a cărui probabilitate de realizare (în cadrul fiecărei experiențe) este egală cu p . Variabilele aleatoare geometrice modelează schema geometrică.

2.6 Variabile aleatoare continue. Exemple clasice

O clasă importantă de variabile aleatoare o constituie variabilele de *tip continuu*. O variabilă aleatoare continuă admite *funcție de densitate* (*densitate de probabilitate*).

Definiția 2.6.1. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate și $X : \Omega \rightarrow \mathbb{R}$ o variabilă aleatoare. X se numește *variabilă aleatoare continuă* dacă există o funcție $f : \mathbb{R} \rightarrow [0, \infty)$, continuă pe \mathbb{R} , eventual cu excepția a unui număr finit de puncte, astfel încât funcția de repartiție F a variabilei aleatoare X să fie determinată prin:

$$F(x) = \int_{-\infty}^x f(t) dt, \quad \forall x \in \mathbb{R}.$$

Funcția f se numește *densitatea de probabilitate* a variabilei aleatoare X (sau *funcția de densitate* a variabilei aleatoare X).

Proprietățile funcției de densitate a unei variabile aleatoare de tip continuu sunt evidențiate în propoziția de mai jos.

Propoziția 2.6.1. Fie $f : \mathbb{R} \rightarrow [0, \infty)$ funcția de densitate asociată unei variabile aleatoare de tip continuu $X : \Omega \rightarrow \mathbb{R}$, iar $F : \mathbb{R} \rightarrow [0, 1]$ funcția sa de repartiție, definită prin:

$$F(x) = \int_{-\infty}^x f(t) dt, \quad \forall x \in \mathbb{R}.$$

Atunci:

1. F este continuă pe \mathbb{R} ;
2. F este derivabilă în toate punctele $x \in \mathbb{R}$ de continuitate ale lui f , cu $F'(x) = f(x)$; dacă, în particular, f este continuă pe \mathbb{R} , atunci F este de clasă \mathcal{C}^1 pe \mathbb{R} , cu $F' = f$.
3. $\int_{-\infty}^{\infty} f(t) dt = 1$;
4. $\mathbb{P}\{X = x\} = 0, \quad \forall x \in \mathbb{R}$;
5. $\mathbb{P}\{a \leq X \leq b\} = \int_a^b f(t) dt, \quad \forall [a, b] \subset \mathbb{R}.$

Demonstrație.

1. Vom analiza doar cazul când f este mărginită pe \mathbb{R} . Presupunem că există $M > 0$ astfel ca $f(t) \in [0, M], \quad \forall t \in \mathbb{R}$. Fie $x \in \mathbb{R}$, arbitrar. Atunci, pentru $h \in \mathbb{R}^*$, avem

$$|F(x+h) - F(x)| = \left| \int_{-\infty}^{x+h} f(t) dt - \int_{-\infty}^x f(t) dt \right| = \left| \int_x^{x+h} f(t) dt \right| \leq \left| \int_x^{x+h} |f(t)| dt \right| \leq M|h|.$$

Aplicând criteriul majorării, obținem $\lim_{h \rightarrow 0} |F(x+h) - F(x)| = 0$, deci $\lim_{h \rightarrow 0} F(x+h) = F(x)$. Rezultă că F este continuă în x .

2. Fie $x \in \mathbb{R}$ un punct de continuitate a lui f . Considerăm $\varepsilon > 0$, arbitrar. Din continuitatea lui f în x , rezultă că există $\delta > 0$ astfel ca $|f(t) - f(x)| < \varepsilon, \quad \forall t \in (x - \delta, x + \delta)$. Atunci, pentru $h \in (-\delta, \delta) \setminus \{0\}$, avem

$$\begin{aligned} \left| \frac{F(x+h) - F(x)}{h} - f(x) \right| &= \frac{\left| \int_x^{x+h} f(t) dt - hf(x) \right|}{|h|} = \frac{\left| \int_x^{x+h} [f(t) - f(x)] dt \right|}{|h|} \leq \\ &\leq \frac{\left| \int_x^{x+h} |f(t) - f(x)| dt \right|}{|h|} \leq \frac{\varepsilon|h|}{|h|} = \varepsilon. \end{aligned}$$

Rezultă $\lim_{h \rightarrow 0} \frac{F(x+h) - F(x)}{h} = f(x)$, deci F este derivabilă în x , cu $F'(x) = f(x)$.

$$3. \int_{-\infty}^{\infty} f(t) dt = \lim_{x \rightarrow \infty} \int_{-\infty}^x f(t) dt = \lim_{x \rightarrow \infty} F(x) = 1.$$

4. F este continuă pe \mathbb{R} , deci $\mathbb{P}\{X = x\} = F(x) - F(x-0) = 0, \quad \forall x \in \mathbb{R}.$

5. Fie $a, b \in \mathbb{R}$, cu $a < b$. Atunci

$$\begin{aligned}\mathbb{P}\{a \leq X \leq b\} &= \mathbb{P}(\{X \leq b\} \setminus \{X < a\}) = \mathbb{P}\{X \leq b\} - \mathbb{P}\{X < a\} = \\ &= \mathbb{P}\{X \leq b\} - \mathbb{P}\{X \leq a\} = F(b) - F(a) = \int_a^b f(t) dt. \quad \square\end{aligned}$$

Teorema 2.6.1. Fie X și Y două variabile aleatoare continue și independente, cu densitățile f și respectiv g , $f, g : \mathbb{R} \rightarrow [0, \infty)$. Atunci variabila aleatoare $X + Y$ are densitatea $f * g$, unde

$$f * g : \mathbb{R} \rightarrow [0, \infty), \quad (f * g)(x) = \int_{-\infty}^{\infty} f(x - t)g(t) dt, \quad \forall x \in \mathbb{R},$$

reprezintă convoluția densităților f și g .

Reținem următorul rezultat fundamental.

Teorema 2.6.2. Dacă o funcție $f : \mathbb{R} \rightarrow [0, \infty)$, continuă pe \mathbb{R} , eventual cu excepția unui număr finit de puncte, are proprietatea

$$\int_{-\infty}^{\infty} f(t) dt = 1,$$

atunci există un spațiu de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$ și o variabilă aleatoare $X : \Omega \rightarrow \mathbb{R}$ astfel încât f să reprezinte funcția de densitate a lui X .

Vom prezenta în continuare câteva exemple clasice de repartiții continue.

Exemplul 2.6.1. Distribuția normală.

Este cel mai important exemplu de distribuție de tip continuu. Astfel, spunem că o variabilă aleatoare reală X are o *repartiție normală (gaussiană)* de parametrii 0 și 1 dacă are funcția de densitate:

$$\varphi(t) = \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}}, \quad \forall t \in \mathbb{R}.$$

Verificăm condiția $\int_{-\infty}^{\infty} \varphi(t) dt = 1$, utilizând funcția Γ a lui Euler, definită prin

$$\Gamma(\alpha) = \int_0^{\infty} x^{\alpha-1} e^{-x} dx, \quad \alpha > 0.$$

Este cunoscut faptul că $\Gamma(1/2) = \int_0^{\infty} x^{-1/2} e^{-x} dx = \sqrt{\pi}$. Astfel, avem

$$\begin{aligned}\int_{-\infty}^{\infty} \varphi(t) dt &= \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{t^2}{2}} dt = \frac{2}{\sqrt{2\pi}} \int_0^{\infty} e^{-\frac{t^2}{2}} dt \stackrel{x=t^2/2}{=} \sqrt{\frac{2}{\pi}} \int_0^{\infty} e^{-x} (\sqrt{2x})' dx = \\ &= \frac{1}{\sqrt{\pi}} \int_0^{\infty} \frac{e^{-x}}{\sqrt{x}} dx = \frac{1}{\sqrt{\pi}} \Gamma(1/2) = 1.\end{aligned}$$

Variabila normală (standard) X admite funcție de repartiție:

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{t^2}{2}} dt, \quad \forall x \in \mathbb{R}.$$

Notăm $X \sim N(0, 1)$. Distribuția normală standard este *legea limită universală*, conform *Teoremei limită centrală*.

Generalizare. $X \sim N(\mu, \sigma^2)$, unde $\mu \in \mathbb{R}$, $\sigma > 0$, dacă admite densitatea de probabilitate

$$\varphi(t) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(t-\mu)^2}{2\sigma^2}}, \quad \forall t \in \mathbb{R}.$$

Exemplul 2.6.2. *Distribuția exponențială.*

Variabila aleatoare X are o distribuție exponențială de parametru $a > 0$, notat prin $X \sim \text{Exp}(a)$, dacă ia valori în intervalul $[0, \infty)$ (deci este o *variabilă aleatoare pozitivă*) și admite funcția de repartiție

$$F(x) = 1 - e^{-ax}, \quad \forall x \geq 0.$$

Funcția de densitate exponențială de parametru a este

$$f(x) = F'(x) = ae^{-ax}, \quad \forall x \geq 0.$$

Distribuția exponențială este fundamentală în teoria fiabilității, caracterizând procesele stocastice de tip Markov.

Exemplul 2.6.3. *Distribuția Γ .*

Variabila aleatoare X are o distribuție Γ de parametri $n, a > 0$, notat prin $X \sim \Gamma(n, a)$, dacă ia valori în intervalul $(0, \infty)$ și admite funcția de densitate

$$f(x) = \frac{a^n x^{n-1} e^{-ax}}{\Gamma(n)}, \quad \forall x > 0.$$

Pentru $n = 1$ se obține distribuția exponențială de parametru a , deci $\Gamma(1, a) = \text{Exp}(a)$. Mai general, pentru $n \in \mathbb{N}^*$, funcția de repartiție a unei variabile aleatoare $X \sim \Gamma(n, a)$ poate fi explicitată. Astfel, $\Gamma(n) = (n-1)!$, deci funcția de densitate devine

$$f(x) = \frac{a^n x^{n-1} e^{-ax}}{(n-1)!}, \quad \forall x > 0.$$

Se obține funcția de repartiție:

$$F(x) = \int_0^x f(t) dt = 1 - e^{-ax} \sum_{k=0}^{n-1} \frac{(ax)^k}{k!}, \quad x \geq 0.$$

În statistică, este importantă distribuția χ_n^2 , definită ca $\Gamma(n/2, 1/2)$, cu $n \in \mathbb{N}^*$.

Exemplul 2.6.4. *Distribuția β .*

Variabila aleatoare X are o distribuție β de parametri $a, b > 0$, notat prin $X \sim \beta(a, b)$, dacă ia valori în intervalul $(0, 1)$ și admite funcția de densitate

$$f(x) = \frac{x^{a-1}(1-x)^{b-1}}{\beta(a, b)}, \quad \forall x \in (0, 1),$$

unde

$$\beta(a, b) = \int_0^1 x^{a-1}(1-x)^{b-1} dx = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$$

este funcția lui Euler de a doua speță.

2.7 Media. Medii de ordin superior

2.7.1 Definiție, proprietăți

Pentru o variabilă aleatoare reală, **media** și **dispersia** reprezintă cele mai elementare și în același timp cele mai semnificative caracteristici numerice.

Media unei variabile aleatoare (dacă există) indică "valoarea așteptată" a variabilei aleatoare.

Definiția 2.7.1. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate și $X : \Omega \rightarrow \mathbb{R}$ o variabilă aleatoare având funcția de repartiție $F : \mathbb{R} \rightarrow [0, 1]$. Mărimea:

$$\mathbb{E}(X) := \int_{-\infty}^{\infty} x dF(x)$$

se numește media lui X . Media este definită în ipoteza că integrala de tip Stieltjes-Riemann de mai sus este convergentă.

Calculul mediei se explicitează după cum urmează.

1. Pentru o variabilă aleatoare X de tip discret, care ia valorile x_i cu probabilitățile p_i , pentru $i \in I$, media devine

$$\mathbb{E}(X) = \sum_{i \in I} x_i p_i.$$

Dacă I este o mulțime numărabilă, atunci media există în ipoteza că seria numerică $\sum_{i \in I} x_i p_i$ este convergentă.

2. Pentru o variabilă aleatoare X de tip continuu, care admite funcția de densitate (densitatea de probabilitate) $f : \mathbb{R} \rightarrow [0, \infty)$, media devine

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x f(x) dx,$$

în ipoteza că integrala improprie este convergentă.

Următoarea propoziție stabilește proprietățile de bază ale mediei variabilelor aleatoare.

Propoziția 2.7.1. Fie X și Y două variabile aleatoare cu medie finită. Au loc proprietățile:

1. $\mathbb{E}(aX) = a\mathbb{E}(X)$, $\forall a \in \mathbb{R}$;
2. $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$;
3. dacă X și Y sunt independente, atunci $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$.

Demonstrație. Vom trata doar cazul variabilelor aleatoare discrete. Rezultatele pentru variabilele aleatoare de tip continuu se pot deduce prin aproximarea acestora cu termenii unui șir de variabile aleatoare de tip discret și trecerea la limită în șirul mediilor acestora.

Presupunem că variabilele aleatoare discrete X și Y au distribuțiile

$$X : \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}, \quad Y : \begin{pmatrix} y_j \\ p'_j \end{pmatrix}_{j \in J},$$

unde I și J sunt mulțimi de indici cel mult numărabile.

1. Pentru $a \in \mathbb{R}$, avem:

$$\mathbb{E}(aX) = \sum_{i \in I} (ax_i)p_i = a \sum_{i \in I} x_i p_i = a\mathbb{E}(X).$$

2. Pentru a demonstra relația $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$, considerăm evenimentele

$$A_{ij} = \{X = x_i, Y = y_j\}, \quad (i, j) \in I \times J.$$

Notăm $p_{ij} = \mathbb{P}(A_{ij})$, $(i, j) \in I \times J$. Atunci

$$\sum_{j \in J} p_{ij} = \sum_{j \in J} \mathbb{P}(A_{ij}) = \mathbb{P}(\cup_{j \in J} A_{ij}) = \mathbb{P}\{X = x_i\} = p_i, \quad \forall i \in I,$$

respectiv

$$\sum_{i \in I} p_{ij} = \sum_{i \in I} \mathbb{P}(A_{ij}) = \mathbb{P}(\cup_{i \in I} A_{ij}) = \mathbb{P}\{Y = y_j\} = p'_j, \quad \forall j \in J.$$

Deoarece $X + Y$ are distribuția

$$X + Y : \left(\begin{array}{c} x_i + y_j \\ p_{ij} \end{array} \right)_{(i,j) \in I \times J},$$

obținem

$$\begin{aligned} \mathbb{E}(X + Y) &= \sum_{(i,j) \in I \times J} (x_i + y_j)p_{ij} = \sum_{i \in I} \sum_{j \in J} x_i p_{ij} + \sum_{j \in J} \sum_{i \in I} y_j p_{ij} = \\ &= \sum_{i \in I} \left(x_i \sum_{j \in J} p_{ij} \right) + \sum_{j \in J} \left(y_j \sum_{i \in I} p_{ij} \right) = \sum_{i \in I} x_i p_i + \sum_{j \in J} y_j p'_j = \mathbb{E}(X) + \mathbb{E}(Y). \end{aligned}$$

3. Variabila aleatoare XY are distribuția

$$XY : \left(\begin{array}{c} x_i y_j \\ p_{ij} \end{array} \right)_{(i,j) \in I \times J}.$$

Dacă X și Y sunt independente, atunci $p_{ij} = p_i p'_j$, $\forall (i, j) \in I \times J$. Rezultă

$$\begin{aligned} \mathbb{E}(XY) &= \sum_{(i,j) \in I \times J} (x_i y_j) p_{ij} = \sum_{(i,j) \in I \times J} (x_i p_i) (y_j p'_j) = \\ &= \left(\sum_{i \in I} x_i p_i \right) \left(\sum_{j \in J} y_j p'_j \right) = \mathbb{E}(X) \mathbb{E}(Y). \end{aligned}$$

Astfel, proprietățile mediei sunt demonstrate în cazul discret. \square

Fie $X : \Omega \rightarrow \mathbb{R}$ o variabilă aleatoare iar $\varphi : \mathbb{R} \rightarrow \mathbb{R}$ o funcție reală măsurabilă (în particular, o funcție continuă). Funcția compusă $\varphi(X) := \varphi \circ X : \Omega \rightarrow \mathbb{R}$ este de asemenea o variabilă aleatoare definită pe Ω . Dacă X admite funcția de repartiție F , atunci

$$\mathbb{E}(\varphi(X)) = \int_{-\infty}^{\infty} \varphi(x) dF(x),$$

în ipoteza că integrala este convergentă. În particular, în cazul când φ este o funcție putere sau modului unei funcții putere, obținem mediile de ordin superior, respectiv mediile absolute de ordin superior.

Definiția 2.7.2. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate și $X : \Omega \rightarrow \mathbb{R}$ o variabilă aleatoare, având funcția de repartiție F .

1. Media de ordin $k \in \mathbb{N}^*$ a variabilei aleatoare X se definește prin

$$\mathbb{E}(X^k) = \int_{-\infty}^{\infty} x^k dF(x),$$

în ipoteza că integrala este convergentă.

2. Media absolută de ordin $k \in \mathbb{N}^*$ a variabilei aleatoare X se definește prin

$$\mathbb{E}(|X|^k) = \int_{-\infty}^{\infty} |x|^k dF(x),$$

în ipoteza că integrala este convergentă.

Notăm $L^k(\Omega)$ mulțimea variabilelor aleatoare definite pe spațiul de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$ cu medie absolută finită de ordinul k :

$$L^k(\Omega) = \{X : \Omega \rightarrow \mathbb{R} - \text{variabilă aleatoare} : \mathbb{E}(|X|^k) < \infty\}.$$

Definim $L^\infty(\Omega) = \cap_{k=1}^{\infty} L^k(\Omega)$ mulțimea variabilelor aleatoare cu medie absolută finită de orice ordin.

Pentru oricare $k \in \mathbb{N}^*$, $L^k(\Omega)$ este un spațiu vectorial real normat. Norma în $L^k(\Omega)$ se definește prin:

$$\|X\|_k = [\mathbb{E}(|X|^k)]^{1/k}, \quad X \in L^k(\Omega).$$

Vom demonstra ulterior incluziunile

$$L^{k+1}(\Omega) \subset L^k(\Omega), \quad k \in \mathbb{N}^*.$$

În plus, dacă $X \in L^k(\Omega)$, atunci X are medie finită de ordinele $i = 1, \dots, k$.

Vom explicita în continuare Definiția 2.7.2 pentru variabile aleatoare discrete și respectiv pentru variabile aleatoare de tip continuu.

I. Variabile aleatoare discrete.

Fie X o variabilă aleatoare discretă, cu distribuția $X : \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}$. Atunci:

$$(a) \quad \mathbb{E}(X^k) = \sum_{i \in I} x_i^k p_i;$$

dacă I este numărabilă, se presupune că seria $\sum_{i \in I} x_i^k p_i$ este convergentă;

$$(b) \quad \mathbb{E}(|X|^k) = \sum_{i \in I} |x_i|^k p_i;$$

dacă I este numărabilă, se presupune că seria $\sum_{i \in I} |x_i|^k p_i$ este convergentă;

II. Variabile aleatoare continue.

Fie X o variabilă aleatoare de tip continuu, cu funcția de densitate $f : \mathbb{R} \rightarrow [0, \infty)$. Atunci:

$$(a) \mathbb{E}(X^k) = \int_{-\infty}^{\infty} x^k f(x) dx, \text{ în ipoteza că integrala improprie este convergentă;}$$

$$(b) \mathbb{E}(|X|^k) = \int_{-\infty}^{\infty} |x|^k f(x) dx, \text{ în ipoteza că integrala improprie este convergentă.}$$

2.7.2 Mediile unor distribuții clasice

Prezentăm în continuare mediile unor variabile aleatoare având distribuții importante, discrete (Bernoulli, binomială, Poisson, geometrică) sau continue (normală, exponențială, Gama).

1. Distribuția Bernoulli: $X \sim B(1, p) \Rightarrow \mathbb{E}(X) = p$.

Demonstrație. O variabilă aleatoare $X \sim B(1, p)$, cu $p \in (0, 1)$ și $q = 1 - p$, are distribuția $X : \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}$. Atunci:

$$\mathbb{E}(X) = 0 \cdot q + 1 \cdot p = p. \quad \square$$

2. Distribuția binomială: $X \sim B(n, p) \Rightarrow \mathbb{E}(X) = np$.

Demonstrație. O variabilă aleatoare $X \sim B(n, p)$, cu $n \in \mathbb{N}^*$, $p \in (0, 1)$ și $q = 1 - p$, are distribuția $X : \left(C_n^k p^k q^{n-k} \right)_{k \in \{0, 1, \dots, n\}}$. Atunci:

$$\mathbb{E}(X) = \sum_{k=0}^n k C_n^k p^k q^{n-k} = \sum_{k=1}^n n C_{n-1}^{k-1} p^k q^{n-k} \stackrel{i=k-1}{=} np \sum_{i=0}^{n-1} C_{n-1}^i p^i q^{(n-1)-i} = np(p+q)^{n-1} = np.$$

O metodă instructivă de calcul a mediei unei variabile aleatoare binomiale $X \sim B(n, p)$ se bazează pe faptul că X se poate reprezenta ca suma a n variabile aleatoare Bernoulli independente $X_i \sim B(1, p)$, $i = 1, \dots, n$. Astfel, avem

$$\mathbb{E}(X) = \mathbb{E}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \mathbb{E}(X_i) = np. \quad \square$$

3. Distribuția Poisson: $X \sim P(\lambda) \Rightarrow \mathbb{E}(X) = \lambda$.

Demonstrație. O variabilă aleatoare $X \sim P(\lambda)$, cu $\lambda > 0$, are distribuția următoare $X : \left(\frac{\lambda^n e^{-\lambda}}{n!} \right)_{n \in \mathbb{N}}$. Avem:

$$\mathbb{E}(X) = \sum_{n=0}^{\infty} n \cdot \frac{\lambda^n e^{-\lambda}}{n!} = \lambda e^{-\lambda} \sum_{n=1}^{\infty} \frac{\lambda^{n-1}}{(n-1)!} \stackrel{i=n-1}{=} \lambda e^{-\lambda} \sum_{i=0}^{\infty} \frac{\lambda^i}{i!} = \lambda e^{-\lambda} e^{\lambda} = \lambda. \quad \square$$

4. **Distribuția geometrică:** $X \sim G(p) \Rightarrow \mathbb{E}(X) = \frac{1}{p}$.

Demonstrație. O variabilă aleatoare $X \sim G(p)$, cu $p \in (0, 1)$ și $q = 1 - p$, are distribuția $X : \left(\begin{matrix} n \\ pq^{n-1} \end{matrix} \right)_{n \in \mathbb{N}^*}$. Avem:

$$\begin{aligned} \mathbb{E}(X) &= \sum_{n=1}^{\infty} npq^{n-1} = p \sum_{n=1}^{\infty} nq^{n-1} = \\ &= p \sum_{n=0}^{\infty} (q^n)'_q = p \left(\sum_{n=0}^{\infty} q^n \right)'_q = p \left(\frac{1}{1-q} \right)'_q = \frac{p}{(1-q)^2} = \frac{1}{p}. \quad \square \end{aligned}$$

5. **Distribuția normală:** $X \sim N(\mu, \sigma^2) \Rightarrow \mathbb{E}(X) = \mu$.

Demonstrație. O variabilă aleatoare $X \sim N(\mu, \sigma^2)$ are funcția de densitate

$$\varphi(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad \forall x \in \mathbb{R}.$$

Avem:

$$\begin{aligned} \mathbb{E}(X) &= \int_{-\infty}^{\infty} x\varphi(x)dx = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} xe^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \stackrel{y=x-\mu}{=} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} (y+\mu)e^{-\frac{y^2}{2\sigma^2}} dy = \\ &= \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} ye^{-\frac{y^2}{2\sigma^2}} dy + \frac{\mu}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{y^2}{2\sigma^2}} dy \stackrel{\text{impar./par.}}{=} 0 + \frac{2\mu}{\sigma\sqrt{2\pi}} \int_0^{\infty} e^{-\frac{y^2}{2\sigma^2}} dy = \\ &\stackrel{z=y^2/(2\sigma^2)}{=} \frac{2\mu}{\sigma\sqrt{2\pi}} \int_0^{\infty} \frac{\sigma\sqrt{2}}{2\sqrt{z}} e^{-z} dz = \frac{\mu}{\sqrt{\pi}} \int_0^{\infty} z^{1/2-1} e^{-z} dz = \frac{\mu}{\sqrt{\pi}} \Gamma(1/2) = \mu. \end{aligned}$$

6. **Distribuția exponențială:** $X \sim \text{Exp}(a) \Rightarrow \mathbb{E}(X) = \frac{1}{a}$.

Demonstrație. O variabilă aleatoare pozitivă $X \sim \text{Exp}(a)$ are funcția de densitate $f(x) = ae^{-ax}$, $x \geq 0$. Obținem

$$\mathbb{E}(X) = \int_0^{\infty} axe^{-ax} dx = - \int_0^{\infty} x (e^{-ax})' dx = -xe^{-ax} \Big|_0^{\infty} + \int_0^{\infty} x' e^{-ax} dx = 0 - \frac{e^{-ax}}{a} \Big|_0^{\infty} = \frac{1}{a}.$$

7. **Distribuția Gama:** $X \in \Gamma(n, a) \Rightarrow \mathbb{E}(X) = \frac{n}{a}$.

Demonstrație. O variabilă aleatoare pozitivă $X \in \Gamma(n, a)$, cu $n, a > 0$, are funcția de densitate $f(x) = \frac{a^n}{\Gamma(n)} x^{n-1} e^{-ax}$, $x \geq 0$. Avem:

$$\begin{aligned} \mathbb{E}(X) &= \int_0^{\infty} xf(x)dx = \frac{a^n}{\Gamma(n)} \int_0^{\infty} x^n e^{-ax} dx \stackrel{y=ax}{=} \frac{a^n}{\Gamma(n)} \int_0^{\infty} \frac{y^n e^{-y}}{a^{n+1}} dy = \\ &= \frac{1}{a\Gamma(n)} \int_0^{\infty} y^{(n+1)-1} e^{-y} dy = \frac{\Gamma(n+1)}{a\Gamma(n)} = \frac{n\Gamma(n)}{a\Gamma(n)} = \frac{n}{a}. \end{aligned}$$

2.8 Dispersia

2.8.1 Definiție, proprietăți

Dispersia unei variabile aleatoare (din spațiul L^2) este un indicator al gradului de împrăștiere a valorilor sale în jurul mediei.

Definiția 2.8.1. Fie $X \in L^2(\Omega)$, cu $\mathbb{E}(X) = \mu$. Mărima:

$$V(X) = \int_{-\infty}^{\infty} (x - \mu)^2 dF(x) = \mathbb{E}[(X - \mu)^2]$$

se numește dispersia lui X . Mărima

$$\sigma(X) = \sqrt{V(X)}$$

se numește abaterea medie pătratică a variabilei aleatoare X .

Dispersia unei variabile aleatoare constante este egală cu 0. În mod explicit, pentru a variabilă aleatoare X , cu media $\mathbb{E}(X) = \mu$, dispersia se calculează astfel:

- dacă X este o variabilă aleatoare discretă cu valorile x_i , luate cu probabilitățile p_i , $i \in I$,

$$V(X) = \sum_{i \in I} (x_i - \mu)^2 p_i;$$

- dacă X este o variabilă aleatoare de tip continuu, cu funcția de densitate f ,

$$V(X) = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx.$$

Dispersia are următoarele proprietăți elementare.

Propoziția 2.8.1. Fie $X, Y \in L^2(\Omega)$, cu $\mathbb{E}(X) = \mu$ și $\mathbb{E}(Y) = \eta$. Atunci:

1. $V(X) \geq 0$;
2. $V(aX) = a^2 V(X)$, $\forall a \in \mathbb{R}$;
3. $V(X + a) = V(X)$, $\forall a \in \mathbb{R}$;
4. $V(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$ (formula de calcul a dispersiei);
5. dacă X și Y sunt variabile aleatoare independente, atunci $V(X + Y) = V(X) + V(Y)$.

Demonstrație.

1. Variabila aleatoare $(X - \mu)^2$ ia doar valori pozitive, deci $V(X) = \mathbb{E}[(X - \mu)^2] \geq 0$.
2. Fie $a \in \mathbb{R}$. Avem $\mathbb{E}(aX) = a\mu$. Atunci

$$V(aX) = \mathbb{E}[(aX - a\mu)^2] = \mathbb{E}[a^2(X - \mu)^2] = a^2 \mathbb{E}[(X - \mu)^2] = a^2 V(X).$$

3. Fie $a \in \mathbb{R}$. Avem $\mathbb{E}(X + a) = \mu + a$. Rezultă

$$V(X + a) = \mathbb{E}[(X + a - (\mu + a))^2] = \mathbb{E}[(X - \mu)^2] = V(X).$$

4. Conform definiției:

$$\begin{aligned} V(X) &= \mathbb{E}[(X - \mu)^2] = \mathbb{E}(X^2 - 2\mu X + \mu^2) = \\ &= \mathbb{E}(X^2) - 2\mu\mathbb{E}(X) + \mu^2 = \mathbb{E}(X^2) - \mu^2 = \mathbb{E}(X^2) - \mathbb{E}^2(X). \end{aligned}$$

5. Avem $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y) = \mu + \eta$. Deoarece variabilele aleatoare X și Y sunt independente, media produsului XY este egală cu produsul mediilor: $\mathbb{E}(XY) = \mathbb{E}(X) \cdot \mathbb{E}(Y) = \mu\eta$. Rezultă

$$\begin{aligned} V(X+Y) &= \mathbb{E}[(X+Y - (\mu + \eta))^2] = \mathbb{E}(X^2 + 2XY + Y^2 - 2(\mu + \eta)(X + Y) + (\mu + \eta)^2) = \\ &= \mathbb{E}(X^2) + 2\mathbb{E}(XY) + \mathbb{E}(Y^2) - 2(\mu + \eta)\mathbb{E}(X + Y) + (\mu + \eta)^2 = \\ &= \mathbb{E}(X^2) + 2\mu\eta + \mathbb{E}(Y^2) - (\mu + \eta)^2 = [\mathbb{E}(X^2) - \mu^2] + [\mathbb{E}(Y^2) - \eta^2] \stackrel{4.}{=} V(X) + V(Y). \quad \square \end{aligned}$$

2.8.2 Dispersiile unor distribuții clasice

Prezentăm dispersiile asociate unor distribuții clasice, pentru care a fost evidențiată anterior media. Vom utiliza, de regulă, formula $V(X) = \mathbb{E}(X^2) - \mathbb{E}^2(X)$.

1. **Distribuția Bernoulli:** $X \sim B(1, p) \Rightarrow V(X) = pq$.

Demonstrație. O variabila aleatoare $X \sim B(1, p)$, având distribuția $X : \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}$, cu $p \in (0, 1)$, $q = 1 - p$, are media $\mathbb{E}(X) = p$. Calculăm $\mathbb{E}(X^2)$, unde $X^2 : \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}$. Avem $\mathbb{E}(X^2) = 0 \cdot q + 1 \cdot p = p$. Atunci $V(X) = \mathbb{E}(X^2) - \mathbb{E}^2(X) = p - p^2 = pq$. \square

2. **Distribuția binomială:** $X \sim B(n, p) \Rightarrow V(X) = npq$.

Demonstrație. O variabila aleatoare $X \sim B(n, p)$, cu $n \in \mathbb{N}^*$, $p \in (0, 1)$ și $q = 1 - p$, are distribuția $X : \left(C_n^k p^k q^{n-k} \right)_{k \in \{0, 1, \dots, n\}}$. Apelăm la reprezentarea variabilei aleatoare X ca suma a n variabile aleatoare Bernoulli independente $X_i \sim B(1, p)$, $i = 1, \dots, n$. Atunci

$$V(X) = V\left(\sum_{i=1}^n X_i\right) \stackrel{indep.}{=} \sum_{i=1}^n V(X_i) = npq. \quad \square$$

3. **Distribuția Poisson:** $X \sim P(\lambda) \Rightarrow V(X) = \lambda$.

Demonstrație. O variabila aleatoare $X \sim P(\lambda)$, cu $\lambda > 0$, având distribuția

$$X : \left(\frac{\lambda^n e^{-\lambda}}{n!} \right)_{n \in \mathbb{N}},$$

are media $\mathbb{E}(X) = \lambda$. Calculăm $\mathbb{E}(X^2)$:

$$\mathbb{E}(X^2) = \sum_{n=0}^{\infty} n^2 \frac{\lambda^n e^{-\lambda}}{n!} = \sum_{n=2}^{\infty} n(n-1) \frac{\lambda^n e^{-\lambda}}{n!} + \sum_{n=1}^{\infty} n \frac{\lambda^n e^{-\lambda}}{n!} =$$

$$= \lambda^2 e^{-\lambda} \sum_{n=2}^{\infty} \frac{\lambda^{n-2}}{(n-2)!} + \mathbb{E}(X) \stackrel{i=n-2}{=} \lambda^2 e^{-\lambda} \sum_{i=0}^{\infty} \frac{\lambda^i}{i!} + \lambda = \lambda^2 e^{-\lambda} e^{\lambda} + \lambda = \lambda^2 + \lambda.$$

Atunci

$$V(X) = \mathbb{E}(X^2) - \mathbb{E}^2(X) = (\lambda^2 + \lambda) - \lambda^2 = \lambda. \quad \square$$

4. Distribuția geometrică: $X \sim G(p) \Rightarrow V(X) = \frac{q}{p^2}.$

Demonstrație. O variabilă aleatoare $X \sim G(p)$, cu $p \in (0, 1)$ și $q = 1 - p$, având distribuția $X : \left(\begin{matrix} n \\ pq^{n-1} \end{matrix} \right)_{n \in \mathbb{N}^*}$, are media $\mathbb{E}(X) = \frac{1}{p}$. Avem

$$\begin{aligned} \mathbb{E}(X^2) &= \sum_{n=1}^{\infty} n^2 pq^{n-1} = \sum_{n=2}^{\infty} n(n-1) pq^{n-1} + \sum_{n=1}^{\infty} npq^{n-1} = \\ &= pq \sum_{n=2}^{\infty} (q^n)'' + \mathbb{E}(X) = pq \left(\sum_{n=0}^{\infty} q^n \right)''_q + \frac{1}{p} = \\ &= pq \left(\frac{1}{1-q} \right)''_q + \frac{1}{p} = \frac{2pq}{(1-q)^3} + \frac{1}{p} = \frac{2q+p}{p^2} = \frac{q+1}{p^2}. \end{aligned}$$

Atunci $V(X) = \mathbb{E}(X^2) - \mathbb{E}^2(X) = \frac{q+1}{p^2} - \frac{1}{p^2} = \frac{q}{p^2}. \quad \square$

5. Distribuția normală: $X \sim N(\mu, \sigma^2) \Rightarrow V(X) = \sigma^2.$

Demonstrație. O variabilă aleatoare $X \sim N(\mu, \sigma^2)$ are funcția de densitate $\varphi(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$, $\forall x \in \mathbb{R}$, unde $\mu = \mathbb{E}(X) \in \mathbb{R}$ și $\sigma > 0$. Calculăm $\mathbb{E}(X^2)$:

$$\begin{aligned} \mathbb{E}(X^2) &= \int_{-\infty}^{\infty} x^2 \varphi(x) dx = \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} x^2 e^{-\frac{(x-\mu)^2}{2\sigma^2}} dx \stackrel{y=x-\mu}{=} \frac{1}{\sigma\sqrt{2\pi}} \int_{-\infty}^{\infty} (y+\mu)^2 e^{-\frac{y^2}{2\sigma^2}} dy = \\ &= \frac{1}{\sigma\sqrt{2\pi}} \left(\int_{-\infty}^{\infty} y^2 e^{-\frac{y^2}{2\sigma^2}} dy + 2\mu \int_{-\infty}^{\infty} y e^{-\frac{y^2}{2\sigma^2}} dy + \int_{-\infty}^{\infty} \mu^2 e^{-\frac{y^2}{2\sigma^2}} dy \right) = \\ &\stackrel{par./impar.}{=} \frac{1}{\sigma\sqrt{2\pi}} \left(2 \int_0^{\infty} y^2 e^{-\frac{y^2}{2\sigma^2}} dy + 0 + 2\mu^2 \int_0^{\infty} e^{-\frac{y^2}{2\sigma^2}} dy \right) = \\ &\stackrel{z=y^2/(2\sigma^2)}{=} \frac{2}{\sigma\sqrt{2\pi}} \left(\int_0^{\infty} \frac{\sigma^3 \sqrt{2} z}{\sqrt{z}} e^{-z} dz + \mu^2 \int_0^{\infty} \frac{\sigma}{\sqrt{2} z} e^{-z} dz \right) = \\ &= \frac{2\sigma^2}{\sqrt{\pi}} \int_0^{\infty} z^{3/2-1} e^{-z} dz + \frac{\mu^2}{\sqrt{\pi}} \int_0^{\infty} z^{1/2-1} e^{-z} dz = \frac{2\sigma^2}{\sqrt{\pi}} \cdot \Gamma(3/2) + \frac{\mu^2}{\sqrt{\pi}} \cdot \Gamma(1/2). \end{aligned}$$

Avem $\Gamma(1/2) = \sqrt{\pi}$ și $\Gamma(3/2) = 1/2 \Gamma(1/2) = \sqrt{\pi}/2$. Rezultă

$$\mathbb{E}(X^2) = \frac{2\sigma^2}{\sqrt{\pi}} \cdot \frac{\sqrt{\pi}}{2} + \frac{\mu^2}{\sqrt{\pi}} \cdot \sqrt{\pi} = \sigma^2 + \mu^2.$$

Atunci

$$V(X) = \mathbb{E}(X^2) - \mathbb{E}^2(X) = (\sigma^2 + \mu^2) - \mu^2 = \sigma^2.$$

În particular, dacă X are o distribuție normală standard, deci $X \sim N(0, 1)$, atunci avem $\mathbb{E}(X) = 0$ și $V(X) = 1$. \square

6. Distribuția exponențială: $X \sim \text{Exp}(a) \Rightarrow V(X) = \frac{1}{a^2}$.

Demonstrație. O variabilă aleatoare pozitivă $X \sim \text{Exp}(a)$, cu $a > 0$, având funcția de densitate $f(x) = ae^{-ax}$, $x \geq 0$, are media $\mathbb{E}(X) = \frac{1}{a}$. Obținem

$$\mathbb{E}(X^2) = \int_0^\infty ax^2e^{-ax}dx = - \int_0^\infty x^2(e^{-ax})'dx = -x^2e^{-ax}|_0^\infty + \int_0^\infty (x^2)'e^{-ax}dx = \frac{2}{a}\mathbb{E}(X) = \frac{2}{a^2}.$$

Rezultă

$$V(X) = \mathbb{E}(X^2) - \mathbb{E}^2(X) = \frac{2}{a^2} - \frac{1}{a^2} = \frac{1}{a^2}. \square$$

7. Distribuția Gama: $X \in \Gamma(n, a) \Rightarrow V(X) = \frac{n}{a^2}$.

Demonstrație. O variabilă aleatoare pozitivă $X \in \Gamma(n, a)$, cu $n, a > 0$, are funcția de densitate $f(x) = \frac{a^n}{\Gamma(n)}x^{n-1}e^{-ax}$, $x \geq 0$ și media $\mathbb{E}(X) = \frac{n}{a}$. Avem:

$$\begin{aligned} \mathbb{E}(X^2) &= \int_0^\infty x^2 f(x) dx = \frac{a^n}{\Gamma(n)} \int_0^\infty x^{n+1} e^{-ax} dx \stackrel{y=ax}{=} \frac{a^n}{\Gamma(n)} \int_0^\infty \frac{y^{n+1} e^{-y}}{a^{n+2}} dy = \\ &= \frac{1}{a^2 \Gamma(n)} \int_0^\infty y^{(n+2)-1} e^{-y} dy = \frac{\Gamma(n+2)}{a^2 \Gamma(n)} = \frac{n(n+1)\Gamma(n)}{a^2 \Gamma(n)} = \frac{n(n+1)}{a^2}. \end{aligned}$$

Atunci

$$V(X) = \mathbb{E}(X^2) - \mathbb{E}^2(X) = \frac{n(n+1)}{a^2} - \left(\frac{n}{a}\right)^2 = \frac{n}{a^2}. \square$$

2.9 Corelația

Corelația este un indicator al gradului de dependență dintre două variabile aleatoare.

Definiția 2.9.1. Fie $X, Y \in L^2(\Omega)$. Corelația variabilelor aleatoare X și Y se definește prin:

$$\lambda(X, Y) = \mathbb{E}\{[X - \mathbb{E}(X)] \cdot [Y - \mathbb{E}(Y)]\}.$$

Presupunem $\sigma(X), \sigma(Y) > 0$. Mărima

$$\rho(X, Y) = \frac{\lambda(X, Y)}{\sigma(X)\sigma(Y)}$$

se numește coeficientul de corelație al variabilelor aleatoare X și Y .

Propoziția următoare stabilește formula de calcul a corelației și alte proprietăți ale corelației.

Propoziția 2.9.1. Fie $X, Y \in L^2(\Omega)$, cu mediile $\mathbb{E}(X) = \mu$ și $\mathbb{E}(Y) = \eta$. Atunci:

1. $\lambda(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y) = \mathbb{E}(XY) - \mu\eta$;
2. dacă X și Y sunt independente, atunci $\lambda(X, Y) = 0$;
3. $\rho(X, Y) \in [-1, 1]$;
4. $\lambda(X, X) = V(X)$; $\rho(X, X) = 1$;
5. $\lambda(X, -X) = -V(X)$; $\rho(X, -X) = -1$.

Demonstrație.

1. Conform definiției,

$$\lambda(X, Y) = \mathbb{E}(XY - \mu Y - \eta X + \mu\eta) = \mathbb{E}(XY) - \mu\mathbb{E}(Y) - \eta\mathbb{E}(X) + \mu\eta = \mathbb{E}(XY) - \mu\eta.$$

2. Dacă X și Y sunt independente, atunci $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y) = \mu\eta$, deci $\lambda(X, Y) = 0$.
3. Din inegalitatea

$$\mathbb{E} \{ [t(X - \mu) + (Y - \eta)]^2 \} \geq 0, \quad \forall t \in \mathbb{R},$$

sau

$$V(X)t^2 + 2\lambda(X, Y)t + V(Y) \geq 0, \quad \forall t \in \mathbb{R},$$

obținem

$$\Delta = 4 [\lambda^2(X, Y) - V(X)V(Y)] \leq 0.$$

Atunci $\lambda^2(X, Y) \leq V(X)V(Y) = \sigma^2(X)\sigma^2(Y)$, de unde $|\lambda(X, Y)| \leq \sigma(X)\sigma(Y)$. Rezultă

$$|\rho(X, Y)| = \frac{|\lambda(X, Y)|}{\sigma(X)\sigma(Y)} \leq 1,$$

deci $\rho(X, Y) \in [-1, 1]$.

4. Avem $\lambda(X, X) = \mathbb{E}(X^2) - \mathbb{E}^2(X) = V(X)$. Atunci $\rho(X, X) = \frac{V(X)}{\sigma^2(X)} = 1$.
5. Constatăm că $\lambda(X, -X) = \mathbb{E}(-X^2) - \mathbb{E}(X)\mathbb{E}(-X) = -\mathbb{E}(X^2) + \mathbb{E}^2(X) = -V(X)$ și $V(X) = V(-X) = \sigma^2(X)$, de unde $\rho(X, -X) = \frac{-V(X)}{\sigma^2(X)} = -1$. \square

Coeficientul de corelație normalizează corelația a două variabile aleatoare.

Dacă $\rho(X, Y) > 0$, atunci variabilele aleatoare X și Y sunt *direct corelate*. Dacă $\rho(X, Y)$ este apropiat de 1, atunci între variabilele aleatoare X și Y există o puternică dependență de tip direct. Dacă $\rho(X, Y) < 0$, atunci variabilele aleatoare X și Y sunt *invers corelate*. Dacă $\rho(X, Y)$ este apropiat de -1, atunci între variabilele aleatoare X și Y există o puternică dependență de tip invers.

2.10 Funcția caracteristică

2.10.1 Definiție, proprietăți

Funcția caracteristică asociată unei variabile aleatoare reprezintă un instrument matematic important. Pentru variabilele aleatoare de tip continuu, funcția caracteristică reprezintă transformata Fourier a funcției de densitate. Transformarea integrală Fourier este importantă în *calculul operațional*.

Definiția 2.10.1. Fie X o variabilă aleatoare având funcția de repartiție F . Funcția $\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$, definită prin

$$\varphi_X(t) = \mathbb{E}(e^{itX}) = \int_{-\infty}^{\infty} e^{itx} dF(x), \quad t \in \mathbb{R},$$

se numește funcția caracteristică a variabilei aleatoare X .

Fie X o variabilă aleatoare de tip continuu, cu densitatea de probabilitate f . În acest caz, funcția sa caracteristică se reprezintă astfel

$$\varphi_X(t) = \int_{-\infty}^{\infty} e^{itx} f(x) dx, \quad t \in \mathbb{R},$$

adică φ_X reprezintă transformata Fourier a funcției f .

Dacă X este o variabilă aleatoare discretă, cu distribuția

$$X : \left(\begin{array}{c} x_k \\ p_k \end{array} \right)_{k \in I},$$

atunci funcția sa caracteristică se calculează astfel

$$\varphi_X(t) = \sum_{k \in I} e^{itx_k} p_k, \quad t \in \mathbb{R}.$$

Prezentăm în continuare principalele proprietăți ale funcției caracteristice.

Teorema 2.10.1. Fie X o variabilă aleatoare, cu funcția de repartiție F . Funcția caracteristică $\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$ a variabilei aleatoare X are următoarele proprietăți:

1. $\varphi_X(0) = 1$;
2. $\varphi_X(-t) = \overline{\varphi_X(t)}$, $\forall t \in \mathbb{R}$;
3. $|\varphi_X(t)| \leq 1$, $\forall t \in \mathbb{R}$;
4. $\varphi_{aX+b}(t) = e^{ibt} \varphi_X(at)$, $\forall t \in \mathbb{R}$, $\forall a, b \in \mathbb{R}$;
5. φ_X este uniform continuă (deci și continuă) pe \mathbb{R} ;
6. dacă $X \in L^n(\Omega)$, atunci φ_X este derivabilă de ordinul n , cu

$$\varphi_X^{(n)}(t) = i^n \int_{-\infty}^{\infty} x^n e^{itx} dF(x), \quad t \in \mathbb{R};$$

7. dacă $X \in L^\infty(\Omega)$, atunci φ_X este dezvoltabilă în serie Taylor în jurul originii:

$$\varphi_X(t) = \sum_{n=0}^{\infty} \frac{t^n}{n!} \varphi_X^{(n)}(0), \quad t \in \mathbb{R},$$

cu $\varphi_X^{(n)}(0) = i^n \mathbb{E}(X^n)$, $n \in \mathbb{N}$. Astfel, are loc formula:

$$\varphi_X(t) = \sum_{n=0}^{\infty} \frac{(it)^n}{n!} \mathbb{E}(X^n), \quad t \in \mathbb{R}. \quad (2.2)$$

Demonstrație.

1. $\varphi_X(0) = \mathbb{E}(e^0) = \mathbb{E}(1) = 1.$
2. $\varphi_X(-t) = \mathbb{E}(e^{-itX}) = \mathbb{E}(\overline{e^{itX}}) = \overline{\varphi_X(t)}, \forall t \in \mathbb{R}.$
3. $|\varphi_X(t)| = \left| \int_{-\infty}^{\infty} e^{itx} dF(x) \right| \leq \int_{-\infty}^{\infty} |e^{itx}| dF(x) = \int_{-\infty}^{\infty} 1 dF(x) = 1, \forall t \in \mathbb{R}.$
4. Fie $a, b \in \mathbb{R}$. Atunci:

$$\varphi_{aX+b}(t) = \int_{-\infty}^{\infty} e^{it(ax+b)} dF(x) = e^{ibt} \int_{-\infty}^{\infty} e^{i(at)x} dF(x) = e^{ibt} \varphi_X(at).$$

5. Fie $t \in \mathbb{R}$ și $h > 0$. Pentru $x \in \mathbb{R}$, avem:

$$e^{ihx} - 1 = \cos(hx) + i \sin(hx) - 1 = -2 \sin^2 \frac{hx}{2} + 2i \sin \frac{hx}{2} \cos \frac{hx}{2} = 2i \sin \frac{hx}{2} \left(\cos \frac{hx}{2} + i \sin \frac{hx}{2} \right),$$

de unde

$$|e^{ihx} - 1| = \left| 2i \sin \frac{hx}{2} \left(\cos \frac{hx}{2} + i \sin \frac{hx}{2} \right) \right| = 2 \left| \sin \frac{hx}{2} \right| \leq 2 \left| \frac{hx}{2} \right| = h|x|.$$

Rezultă

$$\begin{aligned} |\varphi_X(t+h) - \varphi_X(t)| &= \left| \int_{-\infty}^{\infty} e^{itx} (e^{ihx} - 1) dF(x) \right| \leq \\ &\leq \int_{-\infty}^{\infty} |e^{itx}| |e^{ihx} - 1| dF(x) = 2 \int_{-\infty}^{\infty} \left| \sin \frac{hx}{2} \right| dF(x). \end{aligned}$$

Fie $\varepsilon > 0$. Deoarece $\int_{-\infty}^{\infty} dF(x) = 1$, există $a > 0$ astfel ca $\int_{(-\infty, -a] \cup [a, \infty)} dF(x) < \frac{\varepsilon}{4}$.

Rezultă

$$2 \int_{(-\infty, -a] \cup [a, \infty)} \left| \sin \frac{hx}{2} \right| dF(x) \leq 2 \int_{(-\infty, -a] \cup [a, \infty)} 1 dF(x) < \frac{\varepsilon}{2}, \forall h > 0.$$

Apoi, pentru $0 < h < \frac{\varepsilon}{2a}$, avem

$$2 \int_{[-a, a]} \left| \sin \frac{hx}{2} \right| dF(x) \leq \int_{[-a, a]} h|x| dF(x) \leq ha \int_{-a}^a dF(x) = ha[F(a) - F(-a)] \leq ha < \frac{\varepsilon}{2}.$$

Din inegalitățile de mai sus, obținem:

$$|\varphi_X(t+h) - \varphi_X(t)| \leq 2 \int_{-\infty}^{\infty} \left| \sin \frac{hx}{2} \right| dF(x) < \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon, \forall t \in \mathbb{R}, \forall h \in \left(0, \frac{\varepsilon}{2a}\right).$$

Ca urmare, φ_X este uniform continuă pe \mathbb{R} , deci și continuă pe \mathbb{R} .

6. Derivata formală de ordinul n a funcției caracteristice este

$$\varphi_X^{(n)}(t) = \frac{d^n}{dt^n} \left(\int_{-\infty}^{\infty} e^{itx} dF(x) \right) = \int_{-\infty}^{\infty} \frac{\partial^n}{\partial t^n} (e^{itx}) dF(x) = i^n \int_{-\infty}^{\infty} x^n e^{itx} dF(x), t \in \mathbb{R}.$$

Rămâne de arătat că integrala $\int_{-\infty}^{\infty} x^n e^{itx} dF(x)$ este convergentă. Conform ipotezei,

$$\int_{-\infty}^{\infty} |x^n e^{itx}| dF(x) = \int_{-\infty}^{\infty} |x|^n |e^{itx}| dF(x) = \int_{-\infty}^{\infty} |x|^n dF(x) = \mathbb{E}(|X|^n) < \infty.$$

Din criteriul de convergență absolută, rezultă că integrala complexă $\int_{-\infty}^{\infty} x^n e^{itx} dF(x)$ este convergentă, deci formula de derivare este aplicabilă.

7. Conform formulei anterioare, avem

$$\varphi_X^{(n)}(0) = i^n \int_{-\infty}^{\infty} x^n e^0 dF(x) = i^n \mathbb{E}(X^n).$$

Atunci, dezvoltând în serie Taylor exponențiala complexă, obținem

$$\varphi_X(t) = \int_{-\infty}^{\infty} e^{itx} dF(x) = \int_{-\infty}^{\infty} \sum_{n=0}^{\infty} \frac{(itx)^n}{n!} dF(x) = \sum_{n=0}^{\infty} \frac{t^n}{n!} [i^n \mathbb{E}(X^n)] = \sum_{n=0}^{\infty} \frac{t^n}{n!} \varphi_X^{(n)}(0),$$

pentru oricare $t \in \mathbb{R}$. Reținem că dezvoltarea obținută poate fi exprimată alternativ prin

$$\varphi_X(t) = \sum_{n=0}^{\infty} \frac{(it)^n}{n!} \mathbb{E}(X^n), \quad t \in \mathbb{R}. \quad \square$$

Teorema 2.10.2. (*Teorema multiplicării*) Dacă X_1, X_2, \dots, X_n sunt variabile aleatoare independente, atunci

$$\varphi_{X_1+X_2+\dots+X_n} = \varphi_{X_1} \varphi_{X_2} \cdots \varphi_{X_n}.$$

Demonstrație. Media produsului unui număr finit de variabile aleatoare independente este egală cu produsul mediilor acestor variabile aleatoare. Atunci

$$\varphi_{\sum_{k=1}^n X_k}(t) = \mathbb{E} \left(e^{it \sum_{k=1}^n X_k} \right) = \mathbb{E} \left(\prod_{k=1}^n e^{itX_k} \right) = \prod_{k=1}^n \mathbb{E} (e^{itX_k}) = \prod_{k=1}^n \varphi_{X_k}(t), \quad t \in \mathbb{R}. \quad \square$$

Teorema 2.10.3. (*Teorema de unicitate*) Fie X o variabilă aleatoare cu funcția de repartiție F și funcția caracteristică φ_X . Atunci

$$1. \quad F(x_2) - F(x_1) = \mathbb{P}\{x_1 < X \leq x_2\} = \frac{1}{2\pi} \lim_{c \rightarrow \infty} \int_{-c}^c \frac{e^{-itx_1} - e^{-itx_2}}{it} \varphi_X(t) dt, \quad \forall x_1 < x_2;$$

$$2. \quad F(x) = \frac{1}{2\pi} \lim_{y \rightarrow -\infty} \lim_{c \rightarrow \infty} \int_{-c}^c \frac{e^{-ity} - e^{-itx}}{it} \varphi_X(t) dt, \quad \forall x \in \mathbb{R}.$$

3. Dacă X este de tip continuu, cu funcția de densitate f , atunci:

$$f(x) = \frac{1}{2\pi} \int_{-\infty}^{\infty} \varphi_X(t) e^{-itx} dt, \quad \forall x \in \mathbb{R}.$$

Demonstrație. Se aplică transformarea Fourier inversă. \square

2.10.2 Funcțiile caracteristice ale unor distribuții clasice.

1. Distribuția Bernoulli: $X \sim B(1, p) \Rightarrow \varphi_X(t) = q + pe^{it}$, $t \in \mathbb{R}$, $q = 1 - p$.

Demonstrație. $\varphi_X(t) = e^{it \cdot 0}q + e^{it \cdot 1}p = q + pe^{it}$, $t \in \mathbb{R}$.

Consecință. Prin dezvoltare în serie Taylor, obținem:

$$\varphi_X(t) = q + pe^{it} = 1 + \sum_{n=1}^{\infty} \frac{(it)^n}{n!} p, \quad t \in \mathbb{R},$$

deci $\mathbb{E}(X^n) = p$, $\forall n \in \mathbb{N}^*$.

2. Distribuția binomială: $X \sim B(n, p) \Rightarrow \varphi_X(t) = (q + pe^{it})^n$, $t \in \mathbb{R}$.

Demonstrație. Există n variabile aleatoare Bernoulli independente, de parametru p ,

X_1, \dots, X_n , astfel ca $X = \sum_{k=1}^n X_k$. Atunci

$$\varphi_X(t) = \varphi_{\sum_{k=1}^n X_k}(t) = \prod_{k=1}^n \varphi_{X_k}(t) = (q + pe^{it})^n, \quad t \in \mathbb{R}.$$

Observație. Prin dezvoltarea binomului, urmată de dezvoltarea în serie Taylor a exponențialei, obținem:

$$\varphi_X(t) = \sum_{k=0}^n C_n^k q^{n-k} (pe^{it})^k = \sum_{k=0}^n C_n^k q^{n-k} p^k \sum_{m=0}^{\infty} \frac{(itk)^m}{m!} = \sum_{m=0}^{\infty} \left(\sum_{k=0}^n k^m C_n^k q^{n-k} p^k \right) \frac{(it)^m}{m!},$$

$$\text{de unde deducem } \mathbb{E}(X^m) = \sum_{k=0}^n k^m C_n^k q^{n-k} p^k = \sum_{k=0}^n k^m \mathbb{P}\{X = k\}, \quad m \in \mathbb{N}^*.$$

Rezultatul poate fi obținut direct din definiția mediei de ordin superior a variabilei aleatoare binomiale X .

3. Distribuția Poisson: $X \sim P(\lambda) \Rightarrow \varphi_X(t) = e^{\lambda(e^{it}-1)}$, $t \in \mathbb{R}$.

Demonstrație. Pentru orice $t \in \mathbb{R}$, avem:

$$\varphi_X(t) = \sum_{n=0}^{\infty} e^{itn} \mathbb{P}\{X = n\} = e^{-\lambda} \sum_{n=0}^{\infty} \frac{\lambda^n}{n!} e^{itn} = e^{-\lambda} \sum_{n=0}^{\infty} \frac{(\lambda e^{it})^n}{n!} = e^{-\lambda} e^{\lambda e^{it}} = e^{\lambda(e^{it}-1)}.$$

4. Distribuția geometrică: $X \sim G(p) \Rightarrow \varphi_X(t) = \frac{pe^{it}}{1 - qe^{it}}$, $t \in \mathbb{R}$, $q = 1 - p$.

Demonstrație. Pentru orice $t \in \mathbb{R}$, avem:

$$\varphi_X(t) = \sum_{n=1}^{\infty} e^{itn} \mathbb{P}\{X = n\} = pe^{it} \sum_{n=1}^{\infty} e^{it(n-1)} q^{n-1} \stackrel{k=n-1}{=} pe^{it} \sum_{k=0}^{\infty} (qe^{it})^k = \frac{pe^{it}}{1 - qe^{it}}.$$

Aplicație. Derivând funcția caracteristică, găsim $\varphi'_X(t) = \frac{ipe^{it}}{(1-qe^{it})^2}$, $t \in \mathbb{R}$.

Aplicând Teorema 2.10.1, punctul 7, obținem $\mathbb{E}(X) = \frac{\varphi'_X(0)}{i} = \frac{p}{(1-q)^2} = \frac{1}{p}$.

Astfel, regăsim rezultatul obținut anterior prin calculul direct al mediei.

5. Distribuția normală: $X \sim N(\mu, \sigma^2) \Rightarrow \varphi_X(t) = e^{i\mu t - \frac{t^2\sigma^2}{2}}$, $t \in \mathbb{R}$.

Distribuția normală standard: $X \sim N(0, 1) \Rightarrow \varphi_X(t) = e^{-\frac{t^2}{2}}$, $t \in \mathbb{R}$.


Demonstrație. Vom trata doar cazul distribuției normale standard. Fie $X \sim N(0, 1)$. Pentru $t \in \mathbb{R}^*$, avem

$$\varphi_X(t) = \mathbb{E}(e^{itX}) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{itx} e^{-\frac{x^2}{2}} dx = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^{\infty} e^{-\frac{(x-it)^2}{2} - \frac{t^2}{2}} dx = \frac{e^{-\frac{t^2}{2}}}{\sqrt{2\pi}} \int_{\gamma} e^{-\frac{z^2}{2}} dz,$$

unde γ este dreapta de ecuație $z = x - it$, $x \in \mathbb{R}$ din planul complex. Rămâne să demonstrăm relația

$$\int_{\gamma} e^{-\frac{z^2}{2}} dz = \sqrt{2\pi}. \quad (2.3)$$

Fie $R > 0$. Considerăm în planul complex punctele $A(-R - it)$, $B(R - it)$, $A'(-R)$ și $B'(R)$. Definim curba închisă $C_R: A \rightarrow B \rightarrow B' \rightarrow A' \rightarrow A$, obținută prin juxtapunerea segmentelor orientate \overline{AB} , $\overline{BB'}$, $\overline{B'A'}$ și $\overline{A'A}$. Curba C_R este parcursă în sens pozitiv pentru $t > 0$, respectiv în sens negativ pentru $t < 0$.



Conform Teoremei lui Cauchy,

$$\int_{C_R} e^{-\frac{z^2}{2}} dz = 0.$$

Rezultă

$$\int_{\overline{AB}} e^{-\frac{z^2}{2}} dz + \int_{\overline{BB'}} e^{-\frac{z^2}{2}} dz + \int_{\overline{B'A'}} e^{-\frac{z^2}{2}} dz + \int_{\overline{A'A}} e^{-\frac{z^2}{2}} dz = 0,$$

sau

$$\int_{\overline{AB}} e^{-\frac{z^2}{2}} dz = - \int_{\overline{BB'}} e^{-\frac{z^2}{2}} dz + \int_{\overline{A'B'}} e^{-\frac{z^2}{2}} dz + \int_{\overline{AA'}} e^{-\frac{z^2}{2}} dz. \quad (2.4)$$

Au loc limitele de mai jos.

$$\lim_{R \rightarrow \infty} \int_{\overline{AB}} e^{-\frac{z^2}{2}} dz = \lim_{R \rightarrow \infty} \int_{-R}^R e^{-\frac{(x-it)^2}{2}} dx = \int_{-\infty}^{\infty} e^{-\frac{(x-it)^2}{2}} dx = \int_{\gamma} e^{-\frac{z^2}{2}} dz.$$

și

$$\lim_{R \rightarrow \infty} \int_{\overline{A'B'}} e^{-\frac{z^2}{2}} dz = \lim_{R \rightarrow \infty} \int_{-R}^R e^{-\frac{x^2}{2}} dx = \int_{-\infty}^{\infty} e^{-\frac{x^2}{2}} dx = \sqrt{2\pi}.$$

Segmentul orientat $\overline{BB'}$ admite parametrizarea $z = R + (y - t)i$, $y \in [0, t]$. Atunci

$$\begin{aligned} \left| \int_{\overline{BB'}} e^{-\frac{z^2}{2}} dz \right| &= \left| \int_0^t e^{-\frac{[R+(y-t)i]^2}{2}} i dy \right| \leq \\ &\leq \int_0^t \left| i e^{-\frac{R^2-(t-y)^2}{2}} [\cos R(t-y) + i \sin R(t-y)] \right| dy = e^{-\frac{R^2}{2}} \int_0^t e^{\frac{(t-y)^2}{2}} dy \leq \frac{te^{\frac{t^2}{2}}}{e^{\frac{R^2}{2}}}. \end{aligned}$$

Din $\lim_{R \rightarrow \infty} \frac{te^{\frac{t^2}{2}}}{e^{\frac{R^2}{2}}} = 0$ rezultă $\lim_{R \rightarrow \infty} \int_{\overline{BB'}} e^{-\frac{z^2}{2}} dz = 0$. Analog, $\lim_{R \rightarrow \infty} \int_{\overline{AA'}} e^{-\frac{z^2}{2}} dz = 0$.

Ca urmare, trecând la limită cu $R \rightarrow \infty$ în relația (2.4), obținem (2.3). Astfel, am demonstrat $\varphi_X(t) = e^{-\frac{t^2}{2}}$, $\forall t \in \mathbb{R}^*$. În plus, pentru $t = 0$, avem $\varphi_X(0) = 1 = e^{-\frac{0^2}{2}}$.
Aplicație. Din dezvoltarea

$$\varphi_X(t) = e^{-\frac{t^2}{2}} = \sum_{n=0}^{\infty} \frac{(-t^2/2)^n}{n!} = \sum_{n=0}^{\infty} \frac{(it)^{2n}}{n!2^n} = \sum_{n=0}^{\infty} \frac{(it)^{2n}}{(2n)!} \cdot \frac{(2n)!}{n!2^n}$$

rezultă

$$\mathbb{E}(X^k) = \begin{cases} 0, & k = 2n - 1 \\ \frac{(2n)!}{n!2^n}, & k = 2n \end{cases}, \quad n \in \mathbb{N}^*.$$

6. Distribuția exponențială: $X \sim \text{Exp}(a) \Rightarrow \varphi_X(t) = \frac{a}{a - it}$, $t \in \mathbb{R}$.

Demonstrație.

$$\varphi_X(t) = \int_0^{\infty} a e^{itx} e^{-ax} dx = a \int_0^{\infty} e^{x(it-a)} dx = \frac{a}{it-a} e^{x(it-a)} \Big|_0^{\infty} = \frac{a}{a - it}, \quad t \in \mathbb{R}.$$

2.11 Rezumat

Variabilele aleatoare se interpretează ca o "enumerare" a rezultatelor (măsurabile) potențiale ale unui anumit experiment. Fiecare din aceste rezultate posibile are o probabilitate de realizare.

Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate. O funcție măsurabilă reală $X : \Omega \rightarrow \mathbb{R}$ se numește *variabilă aleatoare*. Conform definiției, $\{X \in I\} \in \mathcal{F}$ pentru orice interval real I . În particular, $\{X \in (-\infty, a]\} = \{X \leq a\} \in \mathcal{F}$, $\forall a \in \mathbb{R}$.

O funcție $X : \Omega \rightarrow \mathbb{R}^d$, $(\mathcal{F}, \mathcal{B}_{\mathbb{R}^d})$ măsurabilă, se numește *vector aleator*. Fie X_i , $i = 1, 2, \dots, d$, componentele scalare ale funcției X , deci $X = (X_1, X_2, \dots, X_d)$. Atunci

$$\{X_1 \leq a_1, X_2 \leq a_2, \dots, X_d \leq a_d\} \in \mathcal{F}, \forall (a_1, a_2, \dots, a_d) \in \mathbb{R}^d.$$

Fie $X : \Omega \rightarrow \mathbb{R}$ o variabilă aleatoare. Funcția reală $F : \mathbb{R} \rightarrow [0, 1]$, definită prin

$$F(x) = \mathbb{P}\{X \leq x\} = \mathbb{P}(\{\omega \in \Omega | X(\omega) \leq x\}), \quad x \in \mathbb{R},$$

se numește *funcția de repartiție* a variabilei aleatoare X .

Funcția de repartiție are următoarele proprietăți:

1. F este monoton crescătoare pe \mathbb{R} ;
2. F este continuă la dreapta pe mulțimea \mathbb{R} ($F(x+0) := \lim_{t \downarrow x} F(t) = F(x)$, $\forall x \in \mathbb{R}$);
3. $\lim_{x \rightarrow -\infty} F(x) = 0$; $\lim_{x \rightarrow \infty} F(x) = 1$;
4. $F(x-0) := \lim_{t \uparrow x} F(t) = \mathbb{P}\{X < x\}$, $\forall x \in \mathbb{R}$;
5. $\mathbb{P}\{X = x\} = F(x) - F(x-0)$, $\forall x \in \mathbb{R}$;
6. $\mathbb{P}\{a < X \leq b\} = F(b) - F(a)$, $\forall a, b \in \mathbb{R}$, cu $a < b$;
7. $\mathbb{P}\{X > x\} = 1 - F(x)$, $\forall x \in \mathbb{R}$.

Variabilele aleatoare X_i , $i \in I$, se numesc independente dacă, pentru oricare oricare indici distincți i_1, i_2, \dots, i_n din mulțimea I și oricare $A_1, A_2, \dots, A_n \in \mathcal{B}_{\mathbb{R}}$ are loc

$$\mathbb{P}\{X_{i_1} \in A_1, X_{i_2} \in A_2, \dots, X_{i_n} \in A_n\} = \mathbb{P}\{X_{i_1} \in A_1\} \mathbb{P}\{X_{i_2} \in A_2\} \dots \mathbb{P}\{X_{i_n} \in A_n\}.$$

X se numește variabilă aleatoare discretă dacă mulțimea $X(\Omega)$ este cel mult numărabilă. Fie $X(\Omega) = \{x_i, i \in I\} \subset \mathbb{R}$, unde I este o mulțime de indici cel mult numărabilă. Notăm $p_i = \mathbb{P}\{X = x_i\}$, $i \in I$. Avem $p_i \geq 0$, $\forall i \in I$ și $\sum_{i \in I} p_i = 1$. Distribuția variabilei aleatoare X se reprezintă prin:

$$X : \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}.$$

Variabila aleatoare X se numește *de tip continuu* dacă există o funcție continuă $f : \mathbb{R} \rightarrow [0, \infty)$ cu proprietatea

$$F(x) = \int_{-\infty}^x f(t) dt, \quad \forall x \in \mathbb{R}.$$

Funcția f se numește *densitatea de probabilitate* a variabilei aleatoare X (sau *funcția de densitate* a v.a. X).

Densitatea de probabilitate are proprietățile:

1. F este de clasă \mathcal{C}^1 pe \mathbb{R} , cu $F'(x) = f(x)$, $\forall x \in \mathbb{R}$;
2. $\int_{\mathbb{R}} f(t) dt = 1$;
3. $\mathbb{P}\{X = x\} = 0$, $\forall x \in \mathbb{R}$;
4. $\mathbb{P}\{a \leq X \leq b\} = \int_a^b f(t) dt$, $\forall [a, b] \subset \mathbb{R}$.

Fie $X : \Omega \rightarrow \mathbb{R}$ o variabilă aleatoare având funcția de repartiție $F : \mathbb{R} \rightarrow [0, 1]$. Mărima:

$$\mathbb{E}(X) := \int_{-\infty}^{\infty} x dF(x)$$

se numește *media* lui X . Media este definită în ipoteza că integrala de tip Stieltjes-Riemann de mai sus este convergentă.

Calculul mediei:

1. pentru o variabilă aleatoare X de tip discret, care ia valorile x_i cu probabilitățile p_i , pentru $i \in I$:

$$\mathbb{E}(X) = \sum_{i \in I} x_i p_i;$$

2. pentru o variabilă aleatoare X de tip continuu, care admite densitatea de probabilitate $f : \mathbb{R} \rightarrow [0, \infty)$:

$$\mathbb{E}(X) := \int_{-\infty}^{\infty} x f(x) dx.$$

Media are următoarele proprietăți:

1. $\mathbb{E}(aX) = a\mathbb{E}(X)$, $\forall a \in \mathbb{R}$;
2. $\mathbb{E}(X + Y) = \mathbb{E}(X) + \mathbb{E}(Y)$;
3. dacă X și Y sunt independente, atunci $\mathbb{E}(XY) = \mathbb{E}(X)\mathbb{E}(Y)$.

Dacă X admite funcția de repartiție F , iar φ este o funcție reală măsurabilă, atunci

$$\mathbb{E}(\varphi(X)) = \int_{-\infty}^{\infty} \varphi(x) dF(x),$$

în ipoteza că integrala este convergentă.

Definim:

1. *media de ordin* $k \in \mathbb{N}^*$ a variabilei aleatoare X :

$$\mathbb{E}(X^k) = \int_{-\infty}^{\infty} x^k dx,$$

dacă integrala este convergentă.

2. *media absolută de ordin* $k \in \mathbb{N}^*$ a variabilei aleatoare X :

$$\mathbb{E}(|X|^k) = \int_{-\infty}^{\infty} |x|^k dx,$$

dacă integrala este convergentă. Notăm $L^k = L^k(\Omega)$ mulțimea variabilelor aleatoare (definite pe Ω) cu medie absolută finită de ordinul k .

- Mărimea:

$$V(X) = \int_{-\infty}^{\infty} (x - \mu)^2 dF(x) = \mathbb{E}(X - \mathbb{E}(X))^2 = \mathbb{E}(X^2) - \mathbb{E}^2(X)$$

se numește *dispersia* lui X .

- Mărimea

$$\sigma(X) = \sqrt{V(X)}$$

se numește *abaterea medie pătratică* a variabilei aleatoare X .

Dispersia are următoarele proprietăți:

1. $V(X) \geq 0$;
2. $V(X) = \mathbb{E}(X^2) - [\mathbb{E}(X)]^2$ (formula de calcul a dispersiei);
3. $V(aX) = a^2V(X)$, $\forall a \in \mathbb{R}$;
4. dacă X și Y sunt v.a. independente, atunci $V(X + Y) = V(X) + V(Y)$.

Corelația a două variabile aleatoare este un indicator al tipului de dependență al acestora. Astfel, *corelația* variabilelor aleatoare X și Y se definește prin:

$$\lambda(X, Y) = \mathbb{E}\{[X - \mathbb{E}(X)][Y - \mathbb{E}(Y)]\}.$$

Mărimea

$$\rho(X, Y) = \frac{\lambda(X, Y)}{\sigma(X)\sigma(Y)}$$

se numește *coeficientul de corelație* al variabilelor aleatoare X și Y . Formula de calcul a corelației $\lambda(X, Y) = \mathbb{E}(XY) - \mathbb{E}(X)\mathbb{E}(Y)$.

Dacă X și Y sunt v.a. independente, atunci $\lambda(X, Y) = 0$;

Avem $\rho(X, Y) \in [-1, 1]$.

Fie X o variabilă aleatoare având funcția de repartiție F . Funcția $\varphi_X : \mathbb{R} \rightarrow \mathbb{C}$, definită prin

$$\varphi_X(t) = \mathbb{E}(e^{itX}) = \int_{-\infty}^{\infty} e^{itx} dF(x), \quad t \in \mathbb{R},$$

se numește funcția caracteristică a variabilei aleatoare X .

Dacă X este o variabilă aleatoare de tip continuu, cu densitatea de probabilitate f , atunci

$$\varphi_X(t) = \int_{-\infty}^{\infty} e^{itx} f(x) dx, \quad t \in \mathbb{R}.$$

Dacă X este o variabilă aleatoare discretă, cu distribuția

$$X : \begin{pmatrix} x_k \\ p_k \end{pmatrix}_{k \in I},$$

atunci $\varphi_X(t) = \sum_{k \in I} e^{itx_k} p_k$.

2.12 Test

1. Definiți funcția de repartiție a unei variabile aleatoare și descrieți proprietățile acesteia. Discutați cazul variabilelor aleatoare independente.
2. Calculați media, dispersia și funcția caracteristică pentru o variabilă aleatoare:
 - (a) Poisson;
 - (b) exponențială;
 - (c) geometrică.
3. Variabila aleatoare X are distribuția discretă:

$$X : \begin{pmatrix} 1 & 2 & 3 \\ p_1 & p_2 & p_3 \end{pmatrix},$$

unde $p_1, p_2, p_3 > 0$, cu $p_1 + p_2 + p_3 = 1$. Știind că X are media $E(X) = \frac{7}{4}$ și dispersia $V(X) = \frac{11}{16}$, să se determine probabilitățile p_1, p_2, p_3 .

4. Să se determine constantele reale a și b astfel ca funcția $F(x) = a + b \arctg x$, $x \in \mathbb{R}$, să fie funcția de repartiție a unei variabile aleatoare X și apoi să se calculeze $E(X^2)$.
5. Fie funcția $f : \mathbb{R} \rightarrow \mathbb{R}$,

$$f(x) = \begin{cases} \frac{a}{\sqrt{1-x^2}}, & x \in (-1, 1) \\ 0, & x \in (-\infty, -1] \cup [1, \infty) \end{cases}.$$

- (a) Să se determine $a > 0$ astfel încât f să reprezinte densitatea de probabilitate a unei variabile aleatoare X .
 - (b) Să se determine media $E(X)$ și dispersia $V(X)$ a variabilei aleatoare X .
 - (c) Să se calculeze $\mathbb{P}\{|X| \leq \frac{1}{2}\}$.
6. Timpul de așteptare într-o stație de autobuz este o variabilă aleatoare cu funcția de repartiție

$$F(x) = \begin{cases} 0, & x < 0; \\ x/2, & 0 \leq x < 1; \\ 1/2, & 1 \leq x < 2; \\ x/4, & 2 \leq x < 4; \\ 1, & x \geq 4. \end{cases}$$

Să se determine:

- (a) probabilitatea ca o persoană să aștepte în stație mai mult de 3 minute;
 - (b) probabilitatea ca o persoană să mai aștepte în stație cel puțin de 2 minute, după ce a așteptat 1 minut.
7. Să se calculeze funcția caracteristică a variabilei aleatoare X cu densitatea de probabilitate:

$$f(x) = \begin{cases} 0, & |x| \geq 2; \\ \frac{1}{2} \left(1 - \frac{|x|}{2}\right), & |x| < 2 \end{cases}.$$

Capitolul 3

Convergența șirurilor de variabile aleatoare

3.1 Introducere

Studiul convergenței șirurilor de variabilelor aleatoare, în accepțiuni specifice teoriei probabilităților, evidențiază fenomene asimptotice utile. Un șir de variabile aleatoare poate converge la o variabilă aleatoare (distribuție limită) în sens "tare" sau în sens "slab". Convergența frecvenței de realizare a unui eveniment, într-un șir de experiențe identice și independente, la probabilitatea acelui eveniment este asigurată de *Legea numerelor mari*. Legea slabă a numerelor mari se deduce din inegalitatea lui Cebîșev. *Teorema limită centrală*, considerat cel mai important rezultat al teoriei probabilităților, stabilește convergența la legea normală a distribuției normalizate a sumelor parțiale ale unui șir de variabile aleatoare independente și identic distribuite. Rezultatele asimptotice menționate au o importanță majoră în *statistica matematică*.

3.2 Inegalități fundamentale în teoria probabilităților

Vom prezenta o serie de inegalități care joacă un rol important în teoria probabilităților.

Propoziția 3.2.1. Pentru $X \in L^n(\Omega)$, unde $n \in \mathbb{N}^*$, are loc inegalitatea:

$$|\mathbb{E}(X^n)| \leq \mathbb{E}(|X|^n).$$

Dacă n este număr par, atunci avem egalitate.

Demonstrație. Fie F funcția de repartiție a variabilei aleatoare $X \in L^n(\Omega)$. Pe baza unei proprietăți cunoscute a integralei Stieltjes-Riemann în raport cu o funcție crescătoare, obținem:

$$|\mathbb{E}(X^n)| = \left| \int_{-\infty}^{\infty} x^n dF(x) \right| \leq \int_{-\infty}^{\infty} |x|^n dF(x) = \mathbb{E}(|X|^n).$$

Dacă n este număr par, atunci

$$|\mathbb{E}(X^n)| = \mathbb{E}(X^n) = \mathbb{E}(|X|^n). \quad \square$$

Teorema 3.2.1. (Inegalitatea lui Markov) Fie $X \in L^n(\Omega)$, unde $n \in \mathbb{N}^*$. Atunci

$$\mathbb{P}\{|X| \geq a\} \leq \frac{\mathbb{E}(|X|^n)}{a^n}, \quad \forall a > 0.$$

Demonstrație. Fie F funcția de repartiție a variabilei aleatoare $X \in L^n(\Omega)$. Pentru $a > 0$, avem

$$\begin{aligned} \mathbb{E}(|X|^n) &= \int_{-\infty}^{\infty} |x|^n dF(x) = \int_{[-a,a]} |x|^n dF(x) + \int_{(-\infty,-a] \cup [a,\infty)} |x|^n dF(x) \geq \\ &\geq \int_{(-\infty,-a] \cup [a,\infty)} |x|^n dF(x) \geq a^n \int_{(-\infty,-a] \cup [a,\infty)} 1 dF(x) = a^n \left[\int_{-\infty}^{-a} 1 dF(x) + \int_a^{\infty} 1 dF(x) \right] = \\ &= a^n (\mathbb{P}\{X \leq -a\} + \mathbb{P}\{X \geq a\}) = a^n \mathbb{P}\{|X| \geq a\}, \end{aligned}$$

de unde obținem concluzia. \square

Teorema 3.2.2. (Inegalitatea lui Cebîșev (Chebyshev)) Fie $X \in L^2(\Omega)$, având media $\mathbb{E}(X) = \mu$ și dispersia $V(X) = \sigma^2$. Atunci

$$\mathbb{P}\{|X - \mu| \geq a\} \leq \frac{\sigma^2}{a^2}, \quad \forall a > 0.$$

Demonstrație. Aplicăm inegalitatea lui Markov variabilei aleatoare $Z = X - \mu$, pentru $n = 2$. Astfel, avem:

$$\mathbb{P}\{|X - \mu| \geq a\} = \mathbb{P}\{|Z| \geq a\} \leq \frac{\mathbb{E}(|Z|^2)}{a^2} = \frac{\mathbb{E}[(X - \mu)^2]}{a^2} = \frac{V(X)}{a^2} = \frac{\sigma^2}{a^2}. \quad \square$$

Inegalitatea lui Cebîșev se utilizează la demonstrarea *legii slabe a numerelor mari*.

Teorema 3.2.3. (Inegalitatea lui Hölder) Fie $p, q > 1$ astfel ca $\frac{1}{p} + \frac{1}{q} = 1$. Pentru două variabile aleatoare X și Y are loc inegalitatea

$$\mathbb{E}(|XY|) \leq [\mathbb{E}(|X|^p)]^{\frac{1}{p}} \cdot [\mathbb{E}(|Y|^q)]^{\frac{1}{q}}.$$

În particular, pentru $Y = 1$, avem

$$\mathbb{E}(|X|) \leq [\mathbb{E}(|X|^p)]^{\frac{1}{p}}, \quad \forall p > 1. \quad (3.1)$$

Pentru $p = 2$, obținem inegalitatea Cauchy-Buniakovski:

$$\mathbb{E}(|X|) \leq \sqrt{\mathbb{E}(X^2)}.$$

Inegalitatea Cauchy-Buniakovski se interpretează prin faptul că dispersia variabilei aleatoare $X \in L^2(\Omega)$, definită prin $V(X) = \mathbb{E}[(X - \mathbb{E}(X))^2] = \mathbb{E}(X^2) - \mathbb{E}^2(X)$, este pozitivă. Astfel, conform rezultatelor de mai sus, avem $|\mathbb{E}(X)| \leq \mathbb{E}(|X|) \leq \sqrt{\mathbb{E}(X^2)}$, de unde, prin ridicare la pătrat, obținem: $\mathbb{E}^2(X) \leq \mathbb{E}(X^2)$, deci $V(X) \geq 0$. Menționăm de asemenea că inegalitatea este expresia convexității funcției $f(x) = x^2$, $x \in \mathbb{R}$.

Teorema 3.2.4. (Inegalitatea lui Lyapunov) Fie X o variabilă aleatoare și $r, s \in \mathbb{N}^*$, cu $r < s$. Are loc inegalitatea

$$[\mathbb{E}(|X|^r)]^{\frac{1}{r}} \leq [\mathbb{E}(|X|^s)]^{\frac{1}{s}}.$$

Demonstrație. Fie $p = \frac{s}{r} > 1$ și $q = \frac{p}{p-1} > 1$. Avem $\frac{1}{p} + \frac{1}{q} = 1$. Atunci, conform inegalității (3.1), obținem

$$\mathbb{E}(|X|^r) \leq [\mathbb{E}(|X|^p)]^{\frac{1}{p}} = [\mathbb{E}(|X|^s)]^{\frac{r}{s}}.$$

Ridicând la puterea $\frac{1}{r}$ inegalitatea obținută mai sus, obținem concluzia. \square

Consecință.

$$L^{k+1}(\Omega) \subset L^k(\Omega), \forall k \in \mathbb{N}^*.$$

Astfel, dacă $X \in L^{k+1}(\Omega)$, atunci $\mathbb{E}(|X|^{k+1}) < \infty$. Din inegalitatea lui Lyapunov, rezultă

$$\mathbb{E}(|X|^k) \leq [\mathbb{E}(|X|^{k+1})]^{\frac{k}{k+1}} < \infty,$$

deci $X \in L^k(\Omega)$.

Enunțăm, fără demonstrație, următorul rezultat important.

Propoziția 3.2.2. Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate și k un număr natural nenul. Mulțimea

$$L^k(\Omega) = \{X : \Omega \rightarrow \mathbb{R} : X - \text{variabilă aleatoare}, \mathbb{E}(|X|^k) < \infty\}$$

este un spațiu vectorial normat, înzestrat cu norma $\|\cdot\|_k : L^k(\Omega) \rightarrow [0, \infty)$ definită prin

$$\|X\|_k = [\mathbb{E}(|X|^k)]^{\frac{1}{k}}, \quad X \in L^k(\Omega).$$

Notăm prin $(L^k(\Omega), \|\cdot\|_k)$ spațiul vectorial real normat al variabilelor aleatoare cu medie absolută de ordinul k finită.

Inegalitatea lui Lyapunov se interpretează prin:

$$\|X\|_r \leq \|X\|_s, \quad \forall X \in L^\infty(\Omega) := \bigcap_{k=1}^\infty L^k(\Omega), \quad \forall s, r \in \mathbb{N}^*, \quad r < s.$$

3.3 Tipuri de convergență. Relații

Vom defini *convergența șirurilor de variabile aleatoare*, în diverse accepțiuni. Studiul comportării asimptotice a șirurilor de variabile aleatoare reprezintă o preocupare majoră a teoriei probabilităților.

Definiția 3.3.1. Fie X o variabilă aleatoare și $(X_n)_{n \geq 1}$ un șir de variabile aleatoare definite pe spațiul de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$. Fie F funcția de repartiție a variabilei aleatoare X , iar F_n funcția de repartiție a variabilei aleatoare X_n , $n \geq 1$. Definim următoarele tipuri de convergență ale șirului $(X_n)_{n \geq 1}$ către limita X :

1. șirul $(X_n)_{n \geq 1}$ converge în distribuție (repartiție) la X , notat prin

$$X_n \xrightarrow{d} X,$$

dacă $\lim_{n \rightarrow \infty} F_n(x_0) = F(x_0)$, pentru orice punct de continuitate $x_0 \in \mathbb{R}$ al funcției F ;

2. șirul $(X_n)_{n \geq 1}$ converge în probabilitate la X , notat prin

$$X_n \xrightarrow{p} X,$$

dacă $\lim_{n \rightarrow \infty} \mathbb{P}\{|X_n - X| > \varepsilon\} = 0$, $\forall \varepsilon > 0$;

3. șirul $(X_n)_{n \geq 1}$ converge aproape sigur la X , notat prin

$$X_n \xrightarrow{a.s.} X,$$

dacă $\mathbb{P}\{X_n \rightarrow X\} = 1$;

4. șirul $(X_n)_{n \geq 1}$ converge în spațiul $L^k(\Omega)$ la X , unde $k \in \mathbb{N}^*$, notat prin

$$X_n \xrightarrow{L^k} X,$$

dacă $\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|^k) = 0$.

Convergențele ”în distribuție” și ”în probabilitate” sunt *convergențe slabe*, în timp ce convergențele ”aproape sigură” și ”în spațiul $L^k(\Omega)$ ” sunt *convergențe tari*. Această clasificare formală este susținută de următoarea teoremă de ierarhizare a tipurilor de convergență definite anterior.

Teorema 3.3.1. Fie X o variabilă aleatoare și $(X_n)_{n \geq 1}$ un șir de variabile aleatoare definite pe spațiul de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$. Au loc implicațiile

- 1.

$$X_n \xrightarrow{p} X \implies X_n \xrightarrow{d} X;$$

- 2.

$$X_n \xrightarrow{a.s.} X \implies X_n \xrightarrow{p} X;$$

- 3.

$$X_n \xrightarrow{L^k} X \implies X_n \xrightarrow{p} X.$$

Implicațiile reciproce sunt false.

Demonstrație.

1. Presupunem $X_n \xrightarrow{p} X$. Fie $x_0 \in \mathbb{R}$ un punct de continuitate al funcției F . Considerăm $\varepsilon > 0$, arbitrar. Deoarece, pentru $n \geq 1$,

$$\{|X_n - X| > \varepsilon\} = \{X - X_n < -\varepsilon\} \cup \{X - X_n > \varepsilon\} \supset \{X - X_n < -\varepsilon\} = \{X < X_n - \varepsilon\},$$

avem

$$\begin{aligned} \{X \leq x_0 - \varepsilon\} \setminus \{|X_n - X| > \varepsilon\} &\subset \{X \leq x_0 - \varepsilon\} \setminus \{X < X_n - \varepsilon\} = \\ &= \{X \leq x_0 - \varepsilon\} \cap \{X < X_n - \varepsilon\}^c = \{X \leq x_0 - \varepsilon\} \cap \{X_n - \varepsilon \leq X\} \subset \{X_n \leq x_0\}. \end{aligned}$$

Atunci, conform monotoniei probabilității, obținem

$$\begin{aligned} F(x_0 - \varepsilon) - \mathbb{P}\{|X_n - X| > \varepsilon\} &= \mathbb{P}\{X \leq x_0 - \varepsilon\} - \mathbb{P}\{|X_n - X| > \varepsilon\} \leq \\ &\leq \mathbb{P}(\{X \leq x_0 - \varepsilon\} \setminus \{|X_n - X| > \varepsilon\}) \leq \mathbb{P}\{X_n \leq x_0\} = F_n(x_0). \end{aligned}$$

Pe baza ipotezei, $\lim_{n \rightarrow \infty} \mathbb{P}\{|X_n - X| > \varepsilon\} = 0$. Astfel, prin trecere la limită în relația de mai sus, găsim:

$$F(x_0 - \varepsilon) \leq \liminf_{n \rightarrow \infty} F_n(x_0). \quad (3.2)$$

Cu un raționament similar, deducem

$$\{X_n \leq x_0\} \setminus \{|X_n - X| > \varepsilon\} \subset \{X_n \leq x_0\} \setminus \{X_n < X - \varepsilon\} \subset \{X \leq x_0 + \varepsilon\},$$

de unde

$$F_n(x_0) - \mathbb{P}\{|X_n - X| > \varepsilon\} \leq \mathbb{P}(\{X_n \leq x_0\} \setminus \{|X_n - X| > \varepsilon\}) \leq F(x_0 + \varepsilon).$$

Prin trecere la limită, rezultă

$$\limsup_{n \rightarrow \infty} F_n(x_0) \leq F(x_0 + \varepsilon). \quad (3.3)$$

Relațiile (3.2) și (3.3) conduc la inegalitățile:

$$F(x_0 - \varepsilon) \leq \liminf_{n \rightarrow \infty} F_n(x_0) \leq \limsup_{n \rightarrow \infty} F_n(x_0) \leq F(x_0 + \varepsilon), \quad \forall \varepsilon > 0. \quad (3.4)$$

Deoarece F este continuă în x_0 , avem

$$\lim_{\varepsilon \searrow 0} F(x_0 - \varepsilon) = \lim_{\varepsilon \searrow 0} F(x_0 + \varepsilon) = F(x_0).$$

Atunci, din (3.4) și criteriul clește, rezultă că șirul $(F_n(x_0))_{n \geq 1}$ este convergent, cu

$$\lim_{n \rightarrow \infty} F_n(x_0) = F(x_0).$$

Punctul x_0 de continuitate al funcției F fiind arbitrar, deducem că are loc convergența

$$X_n \xrightarrow{d} X.$$

2. Presupunem $X_n \xrightarrow{a.s.} X$. Avem

$$\omega \in \{X_n \rightarrow X\} \Leftrightarrow \forall \varepsilon > 0, \exists n \geq 1, \forall k \geq n : |X_k(\omega) - X(\omega)| < \varepsilon.$$

Atunci, pentru $\varepsilon > 0$, arbitrar, are loc incluziunea

$$\{X_n \rightarrow X\} \subset \bigcup_{n=1}^{\infty} \bigcap_{p=0}^{\infty} \{|X_{n+p} - X| < \varepsilon\}.$$

Conform ipotezei, rezultă

$$1 = \mathbb{P}\{X_n \rightarrow X\} \leq \mathbb{P}\left(\bigcup_{n=1}^{\infty} \bigcap_{p=0}^{\infty} \{|X_{n+p} - X| < \varepsilon\}\right) \leq 1, \forall \varepsilon > 0,$$

de unde

$$\mathbb{P}\left(\bigcup_{n=1}^{\infty} \bigcap_{p=0}^{\infty} \{|X_{n+p} - X| < \varepsilon\}\right) = 1, \forall \varepsilon > 0.$$

Șirul de evenimente $\left(\bigcap_{p=0}^{\infty} \{|X_{n+p} - X| < \varepsilon\}\right)_{n \geq 1}$ este monoton crescător, cu limita

$$\bigcup_{n=1}^{\infty} \bigcap_{p=0}^{\infty} \{|X_{n+p} - X| < \varepsilon\}.$$

Ca urmare,

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\bigcap_{p=0}^{\infty} \{|X_{n+p} - X| < \varepsilon\}\right) = \mathbb{P}\left(\bigcup_{n=1}^{\infty} \bigcap_{p=0}^{\infty} \{|X_{n+p} - X| < \varepsilon\}\right) = 1, \forall \varepsilon > 0.$$

Cum $\bigcap_{p=0}^{\infty} \{|X_{n+p} - X| < \varepsilon\} \subset \{|X_n - X| < \varepsilon\}$, $\forall n \in \mathbb{N}^*$, avem

$$\mathbb{P}\left(\bigcap_{p=0}^{\infty} \{|X_{n+p} - X| < \varepsilon\}\right) \leq \mathbb{P}(\{|X_n - X| < \varepsilon\}) \leq 1, \forall n \in \mathbb{N}^*.$$

Prin trecece la limită cu $n \rightarrow \infty$ și criteriul clește, rezultă

$$\lim_{n \rightarrow \infty} \mathbb{P}\{|X_n - X| < \varepsilon\} = 1, \forall \varepsilon > 0.$$

Trecând la evenimentele contrare, obținem

$$\lim_{n \rightarrow \infty} \mathbb{P}\{|X_n - X| \geq \varepsilon\} = \lim_{n \rightarrow \infty} [1 - \mathbb{P}\{|X_n - X| < \varepsilon\}] = 1 - 1 = 0, \forall \varepsilon > 0.$$

Rezultă $X_n \xrightarrow{p} X$.

3. Implicația rezultă din inegalitatea lui Markov. Astfel, pentru oricare $\varepsilon > 0$, avem

$$0 \leq \mathbb{P}\{|X_n - X| > \varepsilon\} \leq \mathbb{P}\{|X_n - X| \geq \varepsilon\} \leq \frac{\mathbb{E}(|X_n - X|^k)}{\varepsilon^k} \rightarrow 0, \text{ pentru } n \rightarrow \infty.$$

Aplicând criteriul clește, obținem $\lim_{n \rightarrow \infty} \mathbb{P}\{|X_n - X| > \varepsilon\} = 0$, $\forall \varepsilon > 0$. Ca urmare, $X_n \xrightarrow{p} X$.

Observație. Convergența $X_n \xrightarrow{L^k} X$ corespunde convergenței șirului $(X_n)_{n \geq 1}$ la X în spațiul normat $(L^k(\Omega), \|\cdot\|_k)$, echivalentă cu condiția:

$$\lim_{n \rightarrow \infty} \|X_n - X\|_k = 0.$$

Remarcăm de asemenea implicația:

$$X_n \xrightarrow{L^{k+1}} X \Rightarrow X_n \xrightarrow{L^k} X, \forall k \in \mathbb{N}^*,$$

dedusă din inegalitatea lui Lyapunov.

3.4 Legile numerelor mari

Legea numerelor mari reflectă următoare proprietate: *frecvența de apariție a unui eveniment într-un șir de experiențe identice, independente, tinde către probabilitatea teoretică de realizare a evenimentului în cadrul fiecărei experiențe*. Proprietatea a fost descrisă pentru prima dată la sfârșitul sec. al XVI-lea de matematicianul italian Gerolamo Cardano (1501-1576). Formalizarea matematică (pentru variabile aleatoare binare) ca o *lege a numerelor mari* i se datorează lui Jacob Bernoulli (publicată în lucrarea *Ars conjectandi*, 1713). În 1837, S.D. Poisson a descris-o sub numele de "la Loi des grands nombres". Contribuții importante la demonstrarea riguroasă și extinderea rezultatului sunt datorate lui Chebyshev (demonstrarea legii slabe a numerelor mari, 1837), Markov, Borel (demonstrarea legii tari a numerelor mari, 1909), Cantelli, Kolmogorov și Khinchin.

Formalizarea Bernoulli este următoarea. Presupunem că un eveniment A se poate produce în cadrul unei experiențe cu probabilitatea teoretică $p = \mathbb{P}(A) \in (0, 1)$. Realizăm un șir de experiențe consecutive, identice, independente. Asociem șirului de experiențe șirul $(X_n)_{n \geq 1}$ de variabile aleatoare Bernoulli, independente și identic distribuite (iid), cu distribuția comună

$$X_n : \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}, \quad n \in \mathbb{N}^*,$$

unde valoarea 1 indică realizarea evenimentului A , iar valoarea 0 indică nerealizarea evenimentului A , în cadrul experiențelor $1, 2, \dots$. Variabila aleatoare $S_n = X_1 + X_2 + \dots + X_n$ indică numărul de apariții (realizări) ale evenimentului A în primele n experiențe. Frecvența de realizare a evenimentului A în primele n experiențe este egală cu $\frac{S_n}{n}$. Fenomenul descris de legea numerelor mari este prin urmare

$$\frac{S_n}{n} \rightarrow p.$$

Trebuie însă dat un sens probabilistic precis convergenței descrisă anterior. Vom observa în primul rând că limita p este media comună a variabilelor aleatoare X_n , $n \geq 1$. *Legea numerelor mari* evidențiază această convergență în sensul unui tip de convergență slabă (*legea slabă a numerelor mari*) sau în sensul unui tip de convergență tare (*legea tare a numerelor mari*).

Teorema 3.4.1. (*Legea slabă a numerelor mari*)

Fie $(X_n)_{n \geq 1}$ un șir de variabile aleatoare independente și identic distribuite (iid), din spațiul $L^2(\Omega)$, cu $\mathbb{E}(X_1) = \mu$ și $V(X_1) = \sigma^2$. Notăm $S_n = X_1 + X_2 + \dots + X_n$, $n \in \mathbb{N}^*$. Are loc convergența în probabilitate

$$\frac{S_n}{n} \xrightarrow{p} \mu.$$

Demonstrație. Vom interpreta $\mu = \mathbb{E}(X_n)$, $n \in \mathbb{N}^*$, ca o variabilă aleatoare constantă. Avem $\mathbb{E}(S_n) = \sum_{k=1}^n \mathbb{E}(X_k) = n\mu$ și, pe baza independenței, $V(S_n) = \sum_{k=1}^n V(X_k) = n\sigma^2$. Fie $\varepsilon > 0$, arbitrar. Conform inegalității lui Chebyshev,

$$\mathbb{P} \left\{ \left| \frac{S_n}{n} - \mu \right| > \varepsilon \right\} = \mathbb{P} \{ |S_n - \mathbb{E}(S_n)| > n\varepsilon \} \leq \frac{V(S_n)}{n^2\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2}.$$

Din $\lim_{n \rightarrow \infty} \frac{\sigma^2}{n\varepsilon^2} = 0$, rezultă

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ \left| \frac{S_n}{n} - \mu \right| > \varepsilon \right\} = 0.$$

Cum $\varepsilon > 0$ este arbitrar, obținem concluzia. \square

Legea slabă a numerelor poate fi formulată pentru șiruri de variabile aleatoare independente cu medie comună și dispersii uniform marginite (Chebyshev), respectiv pentru șiruri de variabile aleatoare cu medie comună, având proprietatea $V(S_n)/n^2 \rightarrow 0$ (Markov). Prezentăm, fără demonstrație, o versiune a *legii tari a numerelor mari*.

Teorema 3.4.2. (*Legea tare a numerelor mari*)

Fie $(X_n)_{n \geq 1}$ un șir de variabile aleatoare independente și identic distribuite (iid), din spațiul $L^4(\Omega)$, cu media comună μ . Fie $S_n = X_1 + X_2 + \dots + X_n$, $n \in \mathbb{N}^*$. Atunci

$$\frac{S_n}{n} \xrightarrow{\text{a.s.}} \mu.$$

3.5 Teorema limită centrală

Teorema limită centrală, în versiunea clasică, stabilește că *sumele parțiale normalizate* ale unui șir de variabile aleatoare iid, cu dispersie finită, tind în distribuție către *legea normală standard* (denumită și *legea gaussiană*). Rezultatul admite numeroase extinderi, inclusiv la șiruri de vectori aleatori.

Prima versiune a acestei teoreme a fost formulată de Abraham de Moivre (1733) pentru variabile aleatoare de tip Bernoulli, cu $p = 1/2$. Pierre-Simon Laplace a generalizat rezultatul în lucrarea *Theorie Analytique des Probabilités* (1812), constatând apropierea distribuției binomiale de distribuția normală. În 1901, matematicianul rus Aleksandr Lyapunov a definit în termeni generali și a demonstrat riguros *Teorema limită centrală*. Teorema limită centrală este considerată rezultatul principal al teoriei probabilităților.

Prezentăm la început rezultatele datorate lui de Moivre și Laplace, care se referă la șiruri de variabile aleatoare Bernoulli, independente și identic distribuite.

Teorema 3.5.1. (*Teorema de Moivre-Laplace*) Fie $(X_n)_{n \geq 1}$ un șir de variabile aleatoare Bernoulli, independente și identic distribuite (iid), de parametru $p \in (0, 1)$, având media comună p și dispersia comună pq , unde $q=1-p$. Pentru $n \in \mathbb{N}^*$, notăm $S_n = \sum_{k=1}^n X_k$ și

$$I_n = \left\{ \frac{k - np}{\sqrt{npq}}, k = 0, 1, \dots, n \right\}.$$

Atunci, pentru oricare interval $[a, b] \subset \mathbb{R}$, are loc:

$$\lim_{n \rightarrow \infty} \left(\sup_{x \in I_n \cap [a, b]} \left| \sqrt{2\pi npq} \cdot \mathbb{P} \left\{ \frac{S_n - np}{\sqrt{npq}} = x \right\} - e^{-\frac{x^2}{2}} \right| \right) = 0$$

Demonstrație. Vom utiliza aproximarea factorialului prin

$$n! = \sqrt{2n\pi} \left(\frac{n}{e} \right)^n \theta_n, \quad (3.5)$$

unde $\lim_{n \rightarrow \infty} \theta_n = 1$. Abraham de Moivre a propus în 1733 aproximarea asimptotică a factorialului prin $n! \sim cn^{n+1/2}e^{-n}$, iar James Stirling a determinat ulterior constanta $c = \sqrt{2\pi}$. Relația (3.5) este cunoscută sub denumirea de *formula (aproximarea) lui Stirling*.

Fie $(X_n)_{n \geq 1}$ un șir de variabile aleatoare Bernoulli, independente și identic distribuite, cu distribuția comună

$$X_n : \begin{pmatrix} 0 & 1 \\ q & p \end{pmatrix}, \quad n \in \mathbb{N}^*.$$

Atunci $S_n := \sum_{k=1}^n X_k \sim B(n, p)$, deci S_n are distribuția

$$S_n : \begin{pmatrix} 0 & 1 & \cdots & k & \cdots & n \\ q^n & C_n^1 p q^{n-1} & \cdots & C_n^k p^k q^{n-k} & \cdots & p^n \end{pmatrix}, \quad n \in \mathbb{N}^*.$$

Considerăm variabilele aleatoare Z_n definite prin

$$Z_n = \frac{S_n - np}{\sqrt{npq}}, \quad n \geq 1.$$

Evidențiem caracteristicile variabilelor aleatoare Z_n , $n \geq 1$.

1. Media egală cu 0: $\mathbb{E}(Z_n) = \frac{1}{\sqrt{npq}} \mathbb{E}(S_n - np) = \frac{1}{\sqrt{npq}} [n\mathbb{E}(X_1) - np] = 0$.
2. Dispersia egală cu 1: $V(Z_n) = \left(\frac{1}{\sqrt{npq}} \right)^2 [V(S_n - np)] = \frac{1}{npq} V(S_n) = \frac{nV(X_1)}{npq} = 1$.

Spunem că variabila aleatoare Z_n s-a obținut prin *normalizarea variabilei aleatoare* S_n . Fie

$$I_n = \left\{ \frac{k - np}{\sqrt{npq}}, \quad k = 0, 1, \dots, n \right\}$$

mulțimea valorilor variabilei aleatoare Z_n . Pentru $n \in \mathbb{N}^*$, avem

$$a_n := \min I_n = \frac{-np}{\sqrt{npq}} = -\sqrt{\frac{np}{q}}$$

și

$$b_n := \max I_n = \frac{n - np}{\sqrt{npq}} = \sqrt{\frac{nq}{p}}$$

Constatăm că $\lim_{n \rightarrow \infty} a_n = -\infty$, iar $\lim_{n \rightarrow \infty} b_n = \infty$. Considerăm intervalul compact $[a, b]$, fixat.

Există $N \in \mathbb{N}$ astfel ca $a_n \leq a < b \leq b_n$ și $\frac{1}{\sqrt{npq}} < b - a$. Rezultă

$$A_n := I_n \cap [a, b] \neq \emptyset, \quad \forall n \in \mathbb{N}, \quad n \geq N.$$

Fie $n \geq N$. Pentru $x = \frac{k - np}{\sqrt{npq}} \in A_n$, notăm $p_n(x) = \mathbb{P}\{Z_n = x\}$. Avem

$$p_n(x) = \mathbb{P}\left\{ \frac{S_n - np}{\sqrt{npq}} = x \right\} = \mathbb{P}\{S_n = k\} = C_n^k p^k q^{n-k} = \frac{n!}{k!j!} p^k q^j,$$

unde $j = n - k$. Utilizând formula lui Stirling (3.5), obținem

$$p_n(x) = \frac{\sqrt{2n\pi} (n/e)^n \theta_n}{(\sqrt{2k\pi} (k/e)^k \theta_k)(\sqrt{2j\pi} (j/e)^j \theta_j)} p^k q^j = \frac{\theta_n}{\theta_k \theta_j \sqrt{2\pi}} \sqrt{\frac{n}{kj}} \left(\frac{np}{k}\right)^k \left(\frac{nq}{j}\right)^j.$$

Înmulțind relația cu $\sqrt{2\pi npq}$, obținem

$$p_n(x) \sqrt{2\pi npq} = \frac{\theta_n}{\theta_k \theta_j} \sqrt{\frac{n^2 pq}{kj}} \left(\frac{np}{k}\right)^k \left(\frac{nq}{j}\right)^j. \quad (3.6)$$

Definim numerele naturale $k_n = [np + a\sqrt{npq}]$ și $j_n = [nq - b\sqrt{npq}]$. Din $k = np + x\sqrt{npq}$ și $j = n - k = nq - x\sqrt{npq}$, cu $a \leq x \leq b$, rezultă $k \geq k_n$ și $j \geq j_n$.

Deoarece $\lim_{n \rightarrow \infty} k_n = \lim_{n \rightarrow \infty} j_n = \infty$, obținem $\lim_{n \rightarrow \infty} k = \lim_{n \rightarrow \infty} j = \infty$, de unde

$$\lim_{n \rightarrow \infty} \frac{\theta_n}{\theta_k \theta_j} = 1, \quad (3.7)$$

iar convergența de mai sus este uniformă pentru $x \in [a, b]$.

Cum $x \in [a, b]$, deducem $\lim_{n \rightarrow \infty} \frac{x}{\sqrt{n}} = 0$. Ca urmare, au loc limitele

$$\begin{aligned} \lim_{n \rightarrow \infty} \frac{np}{k} &= \lim_{n \rightarrow \infty} \frac{np}{np + x\sqrt{npq}} = \lim_{n \rightarrow \infty} \frac{p}{p + x\sqrt{pq}/\sqrt{n}} = 1; \\ \lim_{n \rightarrow \infty} \frac{nq}{j} &= \lim_{n \rightarrow \infty} \frac{nq}{n - np - x\sqrt{npq}} = \lim_{n \rightarrow \infty} \frac{q}{q - x\sqrt{pq}/\sqrt{n}} = 1; \\ \lim_{n \rightarrow \infty} \sqrt{\frac{n^2 pq}{kj}} &= \lim_{n \rightarrow \infty} \sqrt{\frac{np}{k}} \cdot \lim_{n \rightarrow \infty} \sqrt{\frac{nq}{j}} = 1, \end{aligned} \quad (3.8)$$

iar convergențele sunt uniforme pentru $x \in [a, b]$.

Aplicăm formula lui Taylor cu rest Lagrange funcției $f(t) = \ln(1+t)$, $t > -1$. Pentru $t > -1$, $t \neq 0$, există $\xi_t \in \mathbb{R}^*$, $|\xi_t| < |t|$, astfel ca

$$f(t) = f(0) + \frac{f'(0)}{1!}t + \frac{f''(0)}{2!}t^2 + \frac{f'''(\xi_t)}{3!}t^3,$$

de unde

$$\ln(1+t) = t - \frac{t^2}{2} + \alpha(t) \frac{t^3}{3}, \quad \text{cu } \lim_{t \rightarrow 0} \alpha(t) = 1. \quad (3.9)$$

Aplicând (3.9), obținem

$$\begin{aligned} \ln \left(\frac{np}{k}\right)^k &= k \ln \left(\frac{np}{k}\right) = (np + x\sqrt{npq}) \ln \left(1 - \frac{x\sqrt{npq}}{np + x\sqrt{npq}}\right) = \\ &= (np + x\sqrt{npq}) \left(-\frac{x\sqrt{npq}}{np + x\sqrt{npq}} - \frac{x^2 npq}{2(np + x\sqrt{npq})^2} - \alpha(n, x) \frac{x^3 (npq)^{3/2}}{(np + x\sqrt{npq})^3} \right) = \\ &= -x\sqrt{npq} - \frac{x^2 npq}{2(np + x\sqrt{npq})} - \alpha_1(n, x) \frac{x^3 (npq)^{3/2}}{3(np + x\sqrt{npq})^2}, \end{aligned}$$

cu $\lim_{n \rightarrow \infty} \alpha_1(n, x) = 1$. Analog obținem

$$\ln \left(\frac{nq}{j} \right)^j = x\sqrt{npq} - \frac{x^2 npq}{2(nq - x\sqrt{npq})} + \alpha_2(n, x) \frac{x^3 (npq)^{3/2}}{3(nq - x\sqrt{npq})^2},$$

cu $\lim_{n \rightarrow \infty} \alpha_2(n, x) = 1$. Prin adunarea relațiilor de mai sus, rezultă

$$\begin{aligned} \ln \left[\left(\frac{np}{k} \right)^k \left(\frac{nq}{j} \right)^j \right] &= -\frac{x^2}{2} \left(\frac{npq}{np + x\sqrt{npq}} + \frac{npq}{nq - x\sqrt{npq}} \right) + \\ &+ \frac{x^3}{3} \left[\alpha_2(n, x) \frac{(npq)^{3/2}}{(nq - x\sqrt{npq})^2} - \alpha_1(n, x) \frac{(npq)^{3/2}}{(np + x\sqrt{npq})^2} \right]. \end{aligned}$$

Atunci

$$\lim_{n \rightarrow \infty} \ln \left[\left(\frac{np}{k} \right)^k \left(\frac{nq}{j} \right)^j \right] = -\frac{x^2}{2} (q + p) = -\frac{x^2}{2},$$

de unde

$$\lim_{n \rightarrow \infty} \left[\left(\frac{np}{k} \right)^k \left(\frac{nq}{j} \right)^j \right] = e^{-x^2/2}. \quad (3.10)$$

În plus, convergența (3.10) este uniformă datorită condiției $x \in [a, b]$.

Din relațiile (3.6), (3.7), (3.8) și (3.10) rezultă convergența uniformă

$$p_n(x) \sqrt{2\pi npq} \xrightarrow{n \rightarrow \infty} e^{-\frac{x^2}{2}}, \quad \forall x \in A_n.$$

Atunci

$$\lim_{n \rightarrow \infty} \left(\sup_{x \in I_n \cap [a, b]} \left| \sqrt{2\pi npq} \cdot \mathbb{P} \left\{ \frac{S_n - np}{\sqrt{npq}} = x \right\} - e^{-\frac{x^2}{2}} \right| \right) = 0. \quad \square$$

Teorema de Moivre-Laplace conduce la versiunea binomială a *Teoremei limită centrală*.

Teorema 3.5.2. Fie $(X_n)_{n \geq 1}$ un șir de variabile aleatoare Bernoulli independente și identic distribuite, de parametru $p \in (0, 1)$. Notăm $S_n = \sum_{k=1}^n X_k$, $n \in \mathbb{N}^*$.

Pentru oricare interval $[a, b] \subset \mathbb{R}$, are loc limita:

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ a \leq \frac{S_n - np}{\sqrt{npq}} \leq b \right\} = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{x^2}{2}} dx.$$

Demonstrație. Fie $[a, b] \subset \mathbb{R}$. Fie $\varepsilon > 0$. Din Teorema de Moivre-Laplace, rezultă că există $n_\varepsilon \in \mathbb{N}^*$, astfel ca

$$\left| \sqrt{2\pi npq} \cdot \mathbb{P} \left\{ \frac{S_n - np}{\sqrt{npq}} = x \right\} - e^{-\frac{x^2}{2}} \right| < \varepsilon, \quad \forall x \in A_n, \quad \forall n \geq n_\varepsilon,$$

unde $A_n = \left\{ \frac{k - np}{\sqrt{npq}}, k = 0, 1, \dots, n \right\} \cap [a, b]$.

Fie $n \geq n_\varepsilon$. Notăm $m_n = |A_n|$. Reprezentăm mulțimea A_n prin $A_n = \{x_1, x_2, \dots, x_{m_n}\}$, unde $x_1 = \min A_n \in \left[a, a + \frac{1}{\sqrt{npq}}\right)$, $x_{m_n} = \max A_n \in \left(b - \frac{1}{\sqrt{npq}}, b\right]$, iar

$$x_{i+1} = x_i + \frac{1}{\sqrt{npq}}, \quad i = 1, \dots, m_n - 1.$$

Sumând inegalitățile

$$\frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi npq}} - \frac{\varepsilon}{\sqrt{2\pi npq}} < \mathbb{P} \left\{ \frac{S_n - np}{\sqrt{npq}} = x \right\} < \frac{e^{-\frac{x^2}{2}}}{\sqrt{2\pi npq}} + \frac{\varepsilon}{\sqrt{2\pi npq}}, \quad x \in A_n,$$

obținem

$$\frac{1}{\sqrt{2\pi}} \left(\sum_{x \in A_n} \frac{1}{\sqrt{npq}} e^{-\frac{x^2}{2}} - \frac{\varepsilon m_n}{\sqrt{npq}} \right) < P_n < \frac{1}{\sqrt{2\pi}} \left(\sum_{x \in A_n} \frac{1}{\sqrt{npq}} e^{-\frac{x^2}{2}} + \frac{\varepsilon m_n}{\sqrt{npq}} \right), \quad (3.11)$$

unde

$$P_n := \mathbb{P} \left\{ a \leq \frac{S_n - np}{\sqrt{npq}} \leq b \right\}.$$

Definim diviziunea $\Delta_n = (a, x_1, x_2, \dots, x_{m_n}, b)$ a intervalului $[a, b]$ și sistemul de puncte intermediare $\Lambda_n = (x_1, x_2, \dots, x_{m_n}, b)$ asociat lui Δ_n . Fie $f : [a, b] \rightarrow \mathbb{R}$, $f(x) = e^{-x^2/2}$. Suma Riemann a funcției f , asociată diviziunii Δ_n și sistemului de puncte intermediare Λ_n este

$$\begin{aligned} \sigma_{\Delta_n}(f, \Lambda_n) &= f(x_1)(x_1 - a) + \sum_{i=2}^{m_n} f(x_i)(x_i - x_{i-1}) + f(b)(b - x_{m_n}) = \\ &= \frac{1}{\sqrt{npq}} \sum_{x \in A_n} e^{-\frac{x^2}{2}} - e^{-\frac{x_1^2}{2}} \left(a + \frac{1}{\sqrt{npq}} - x_1 \right) + e^{-\frac{b^2}{2}} (b - x_{m_n}). \end{aligned}$$

Prin trecere la limită, rezultă

$$\int_a^b e^{-\frac{x^2}{2}} dx = \lim_{n \rightarrow \infty} \left(\frac{1}{\sqrt{npq}} \sum_{x \in A_n} e^{-\frac{x^2}{2}} \right), \quad (3.12)$$

deoarece

$$0 \leq e^{-\frac{x_1^2}{2}} \left(a + \frac{1}{\sqrt{npq}} - x_1 \right) < \frac{1}{\sqrt{npq}}$$

și

$$0 \leq e^{-\frac{b^2}{2}} (b - x_{m_n}) < \frac{1}{\sqrt{npq}},$$

ceea ce implică

$$\lim_{n \rightarrow \infty} \left[-e^{-\frac{x_1^2}{2}} \left(a + \frac{1}{\sqrt{npq}} - x_1 \right) + e^{-\frac{b^2}{2}} (b - x_{m_n}) \right] = 0.$$

Analog se arată

$$\lim_{n \rightarrow \infty} \frac{m_n}{\sqrt{npq}} = \int_a^b 1 \, dx = b - a. \quad (3.13)$$

Atunci, prin trecere la limită în (3.11), pe baza relațiilor (3.12) și (3.13), rezultă:

$$\frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{x^2}{2}} \, dx - \frac{\varepsilon(b-a)}{\sqrt{2\pi}} \leq \liminf_{n \rightarrow \infty} P_n \leq \limsup_{n \rightarrow \infty} P_n \leq \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{x^2}{2}} \, dx + \frac{\varepsilon(b-a)}{\sqrt{2\pi}}.$$

Cum $\varepsilon > 0$ este arbitrar, deducem că șirul $(P_n)_{n \geq 1}$ converge la $\frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{x^2}{2}} \, dx$, deci are loc limita

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ a \leq \frac{S_n - np}{\sqrt{npq}} \leq b \right\} = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{x^2}{2}} \, dx. \quad \square$$

Prezentăm în continuare forma generală a *Teoremei limită centrală*.

Teorema 3.5.3. (*Teorema limită centrală*) Fie $(X_n)_{n \geq 1}$ un șir de variabile aleatoare independente și identic distribuite (iid), cu $\mathbb{E}(X_1) = \mu$ și $V(X_1) = \sigma^2$. Considerăm șirul de variabile aleatoare $S_n = X_1 + X_2 + \dots + X_n$, $n \in \mathbb{N}^*$. Atunci:

1.

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ a \leq \frac{S_n - n\mu}{\sigma\sqrt{n}} \leq b \right\} = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{x^2}{2}} \, dx, \quad \forall a, b \in \mathbb{R}, \quad a < b;$$

2. (versiunea Lindeberg-Lévy) Are loc următoarea convergență în distribuție către o variabilă aleatoare gaussiană:

$$\frac{\sqrt{n}}{\sigma} \left(\frac{S_n}{n} - \mu \right) \xrightarrow{d} Z,$$

unde $Z \sim N(0, 1)$.

Demonstrație.

Fie $(\Omega, \mathcal{F}, \mathbb{P})$ un spațiu de probabilitate și $(X_n)_{n \geq 1}$ un șir de variabile aleatoare independente și identic distribuite din $L^2(\Omega)$, cu $\mathbb{E}(X_n) = \mu$ și $V(X_n) = \sigma^2$, pentru $n \geq 1$. Definim șirul de variabile aleatoare, independente și identic distribuite, $Z_n = \frac{X_n - \mu}{\sigma}$, $n \geq 1$, cu media $\mathbb{E}(Z_n) = \frac{1}{\sigma}(\mathbb{E}(X_n) - \mu) = 0$ și dispersia $V(Z_n) = \frac{1}{\sigma^2}V(X_n - \mu) = \frac{1}{\sigma^2}V(X_n) = 1$, pentru orice $n \in \mathbb{N}^*$. Fie $Z \sim N(0, 1)$ o variabilă aleatoare normală standard definită pe $(\Omega, \mathcal{F}, \mathbb{P})$. Atunci

$$\frac{\sqrt{n}}{\sigma} \left(\frac{S_n}{n} - \mu \right) = \frac{1}{\sqrt{n}} \sum_{k=1}^n \frac{X_k - \mu}{\sigma} = \frac{1}{\sqrt{n}} \sum_{k=1}^n Z_k.$$

Pentru versiunea Lindeberg-Lévi a teoremei, avem de demonstrat

$$\frac{1}{\sqrt{n}} \sum_{k=1}^n Z_k \xrightarrow{d} Z. \quad (3.14)$$

Datorită injectivității transformării Fourier, convergența în distribuție (3.14) este echivalentă cu convergența punctuală pe \mathbb{R} :

$$\varphi_{\frac{1}{\sqrt{n}} \sum_{k=1}^n Z_k} \rightarrow \varphi_Z, \quad n \rightarrow \infty. \quad (3.15)$$

Variabila aleatoare normală standard Z are funcția caracteristică:

$$\varphi_Z(t) = e^{-\frac{t^2}{2}}, \quad t \in \mathbb{R}. \quad (3.16)$$

Notăm $\varphi : \mathbb{R} \rightarrow \mathbb{C}$ funcția caracteristică comună a variabilelor aleatoare Z_n , $n \in \mathbb{N}^*$. Conform proprietăților funcției caracteristice (Teorema 2.9.1 și Teorema 2.9.2), avem

$$\varphi_{\frac{1}{\sqrt{n}} \sum_{k=1}^n Z_k}(t) = \varphi_{\sum_{k=1}^n Z_k}(t/\sqrt{n}) \stackrel{\text{indep.}}{=} \prod_{k=1}^n \varphi_{Z_k}(t/\sqrt{n}) = \varphi^n(t/\sqrt{n}), \quad t \in \mathbb{R}.$$

Astfel, convergența (3.15) se explicitează prin:

$$\lim_{n \rightarrow \infty} \varphi^n\left(\frac{t}{\sqrt{n}}\right) = e^{-\frac{t^2}{2}}, \quad \forall t \in \mathbb{R}. \quad (3.17)$$

Pentru $t = 0$, avem $\varphi^n(0/\sqrt{n}) = 1 = e^{-\frac{0^2}{2}}$, $n \geq 1$.

Fie $t \in \mathbb{R} \setminus \{0\}$. Arătăm:

$$\Delta_n := \left| \varphi^n\left(\frac{t}{\sqrt{n}}\right) - e^{-\frac{t^2}{2}} \right| \xrightarrow{n \rightarrow \infty} 0. \quad (3.18)$$

Pentru $n \geq 1$, avem

$$\Delta_n = \left| \varphi^n\left(\frac{t}{\sqrt{n}}\right) - \left(e^{-\frac{t^2}{2n}}\right)^n \right| = \left| \varphi\left(\frac{t}{\sqrt{n}}\right) - e^{-\frac{t^2}{2n}} \right| \cdot \left| \sum_{k=0}^{n-1} \varphi^k\left(\frac{t}{\sqrt{n}}\right) \left(e^{-\frac{t^2}{2n}}\right)^{n-1-k} \right|.$$

Deoarece $|\varphi(u)| \leq 1$, $\forall u \in \mathbb{R}$, iar $e^{-u} \in (0, 1]$, $\forall u \geq 0$, obținem

$$\left| \sum_{k=0}^{n-1} \varphi^k\left(\frac{t}{\sqrt{n}}\right) \left(e^{-\frac{t^2}{2n}}\right)^{n-1-k} \right| \leq \sum_{k=0}^{n-1} \left| \varphi^k\left(\frac{t}{\sqrt{n}}\right) \right| e^{-\frac{t^2(n-1-k)}{2n}} \leq n,$$

de unde

$$\Delta_n \leq n \left| \varphi\left(\frac{t}{\sqrt{n}}\right) - e^{-\frac{t^2}{2n}} \right| \leq n \left| \varphi\left(\frac{t}{\sqrt{n}}\right) - 1 + \frac{t^2}{2n} \right| + n \left| 1 - \frac{t^2}{2n} - e^{-\frac{t^2}{2n}} \right|. \quad (3.19)$$

Din formula lui Taylor cu rest Lagrange, rezultă

$$|e^{-u} - 1 + u| \leq \frac{u^2}{2}, \quad \forall u \geq 0. \quad (3.20)$$

De asemenea, se obțin inegalitățile complexe:

$$|e^{iu} - 1 - iu| \leq \frac{u^2}{2}, \quad \forall u \in \mathbb{R}; \quad (3.21)$$

$$\left| e^{iu} - 1 - iu - \frac{(iu)^2}{2} \right| \leq \frac{|u|^3}{6}, \quad \forall u \in \mathbb{R}. \quad (3.22)$$

Conform (3.20),

$$\left| 1 - \frac{t^2}{2n} - e^{-\frac{t^2}{2n}} \right| \leq \frac{1}{2} \left(\frac{t^2}{2n} \right)^2 = \frac{t^4}{8n^2}.$$

Atunci

$$n \left| 1 - \frac{t^2}{2n} - e^{-\frac{t^2}{2n}} \right| \leq \frac{t^4}{8n}, \quad \forall n \in \mathbb{N}^*,$$

de unde

$$\lim_{n \rightarrow \infty} n \left| 1 - \frac{t^2}{2n} - e^{-\frac{t^2}{2n}} \right| = 0. \quad (3.23)$$

Pe de altă parte, deoarece $\mathbb{E}(Z_1) = 0$ și $\mathbb{E}(Z_1^2) = V(Z_1) + \mathbb{E}^2(Z_1) = 1$, are loc formula:

$$n \left| \varphi \left(\frac{t}{\sqrt{n}} \right) - 1 + \frac{t^2}{2n} \right| = n \left| \mathbb{E} \left(e^{itZ_1/\sqrt{n}} - 1 - \frac{it}{\sqrt{n}} Z_1 - \frac{(it)^2}{2n} Z_1^2 \right) \right|.$$

Pentru o variabilă aleatoare V , avem $|\mathbb{E}(V)| \leq \mathbb{E}(|V|)$. Astfel, obținem:

$$n \left| \varphi \left(\frac{t}{\sqrt{n}} \right) - 1 + \frac{t^2}{2n} \right| \leq n \mathbb{E} \left(\left| e^{itZ_1/\sqrt{n}} - 1 - \frac{it}{\sqrt{n}} Z_1 - \frac{(it)^2}{2n} Z_1^2 \right| \right). \quad (3.24)$$

Fie $\varepsilon > 0$. Definim $\delta = \frac{3\varepsilon}{|t|^3}$ și evenimentul $A_n(\delta) = \{|Z_1| > \delta\sqrt{n}\}$. Considerăm variabila aleatoare $1_{A_n(\delta)}$ indicator a evenimentului $A_n(\delta)$, definită prin

$$1_{A_n(\delta)}(\omega) = \begin{cases} 1, & \omega \in A_n(\delta) \\ 0, & \omega \notin A_n(\delta) \end{cases}.$$

Pentru $\omega \in A_n(\delta)$, are loc majorarea

$$\begin{aligned} \left| e^{itZ_1(\omega)/\sqrt{n}} - 1 - \frac{it}{\sqrt{n}} Z_1(\omega) - \frac{(it)^2}{2n} Z_1^2(\omega) \right| &\leq \left| e^{itZ_1(\omega)/\sqrt{n}} - 1 - \frac{it}{\sqrt{n}} Z_1(\omega) \right| + \left| -\frac{(it)^2}{2n} Z_1^2(\omega) \right| \leq \\ &\stackrel{(3.21)}{\leq} \frac{t^2}{2n} Z_1^2(\omega) + \frac{t^2}{2n} Z_1^2(\omega) = \frac{t^2}{n} Z_1^2(\omega), \end{aligned}$$

iar pentru $\omega \in A_n^c(\delta)$, are loc majorarea

$$\left| e^{itZ_1(\omega)/\sqrt{n}} - 1 - \frac{it}{\sqrt{n}} Z_1(\omega) - \frac{(it)^2}{2n} Z_1^2(\omega) \right| \stackrel{(3.22)}{\leq} \frac{|t|^3}{6n\sqrt{n}} |Z_1(\omega)|^3.$$

Rezultă

$$\left| e^{itZ_1/\sqrt{n}} - 1 - \frac{it}{\sqrt{n}} Z_1 - \frac{(it)^2}{2n} Z_1^2 \right| \leq \frac{t^2}{2n} Z_1^2 \cdot 1_{A_n(\delta)} + \frac{|t|^3}{6n\sqrt{n}} |Z_1|^3 \cdot 1_{A_n^c(\delta)}.$$

Astfel,

$$n \mathbb{E} \left(\left| e^{itZ_1/\sqrt{n}} - 1 - \frac{it}{\sqrt{n}} Z_1 - \frac{(it)^2}{2n} Z_1^2 \right| \right) \leq \frac{t^2}{2} \mathbb{E} (Z_1^2 \cdot 1_{A_n(\delta)}) + \frac{|t|^3}{6\sqrt{n}} \mathbb{E} (|Z_1|^3 \cdot 1_{A_n^c(\delta)}).$$

Fie $F : \mathbb{R} \rightarrow [0, 1]$ funcția de repartiție a variabilei aleatoare Z_1 . Deoarece $\mathbb{E}(Z_1^2) = 1$, avem

$$\frac{t^2}{2} \mathbb{E} (Z_1^2 \cdot 1_{A_n(\delta)}) = \frac{t^2}{2} \int_{|x| > \delta\sqrt{n}} x^2 dF(x) \xrightarrow{n \rightarrow \infty} 0,$$

deci există $n_\varepsilon \in \mathbb{N}^*$ astfel ca $\frac{t^2}{2} \mathbb{E} (Z_1^2 \cdot 1_{A_n(\delta)}) < \frac{\varepsilon}{2}$, $\forall n \geq n_\varepsilon$.

Apoi,

$$\begin{aligned} \frac{|t|^3}{6\sqrt{n}} \mathbb{E} (|Z_1|^3 \cdot 1_{A_n^c(\delta)}) &= \frac{|t|^3}{6\sqrt{n}} \int_{|x| \leq \delta\sqrt{n}} |x|^3 dF(x) \leq \\ &\leq \frac{|t|^3\delta}{6} \int_{|x| \leq \delta\sqrt{n}} |x|^2 dF(x) \leq \frac{|t|^3\delta}{6} \int_{-\infty}^{\infty} |x|^2 dF(x) = \frac{|t|^3\delta}{6} \mathbb{E}(Z_1^2) = \frac{|t|^3\delta}{6} = \frac{\varepsilon}{2}. \end{aligned}$$

Prin urmare,

$$n \mathbb{E} \left(\left| e^{itZ_1/\sqrt{n}} - 1 - \frac{it}{\sqrt{n}} Z_1 - \frac{(it)^2}{2n} Z_1^2 \right| \right) < \frac{\varepsilon}{2} + \frac{\varepsilon}{2} = \varepsilon, \quad \forall n \geq n_\varepsilon.$$

Cum $\varepsilon > 0$ este arbitrar, rezultă $\lim_{n \rightarrow \infty} n \mathbb{E} \left(\left| e^{itZ_1/\sqrt{n}} - 1 - \frac{it}{\sqrt{n}} Z_1 - \frac{(it)^2}{2n} Z_1^2 \right| \right) = 0$. Atunci, din (3.24), obținem

$$\lim_{n \rightarrow \infty} n \left| \varphi \left(\frac{t}{\sqrt{n}} \right) - 1 + \frac{t^2}{2n} \right| = 0. \quad (3.25)$$

Din inegalitatea (3.19) și limitele (3.23) și (3.25), rezultă

$$\lim_{n \rightarrow \infty} \Delta_n = 0,$$

ceea ce încheie demonstrația versiunii Lindeberg-Lévi a teoremei.

Demonstrăm prima afirmație din enunțul teoremei. Fie $F_n : \mathbb{R} \rightarrow [0, 1]$ funcția de repartiție a variabilei aleatoare $\frac{S_n - n\mu}{\sigma\sqrt{n}}$, iar $\Phi : \mathbb{R} \rightarrow [0, 1]$ funcția de repartiție normală standard. Convergența în distribuție demonstrată înseamnă:

$$\lim_{n \rightarrow \infty} F_n(x) = \Phi(x), \quad \forall x \in \mathbb{R}.$$

Fie $[a, b] \subset \mathbb{R}$. Avem

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ a < \frac{S_n - n\mu}{\sigma\sqrt{n}} \leq b \right\} = \lim_{n \rightarrow \infty} [F_n(b) - F_n(a)] = \Phi(b) - \Phi(a) = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{x^2}{2}} dx.$$

Astfel, Teorema limită centrală este complet demonstrată. \square

Comentariu. În cazul binomial, $\sigma = \sqrt{pq}$, deci Teorema 3.5.2 reprezintă un caz particular al Teoremei 3.5.3.

3.6 Rezumat

Inegalitatea lui Markov Fie $X \in L^n(\Omega)$, unde $n \in \mathbb{N}^*$. Atunci

$$\mathbb{P}\{|X| > a\} \leq \frac{\mathbb{E}(|X|^n)}{a^n}, \quad \forall a > 0.$$

Inegalitatea lui Cebîșev (Chebyshev) Fie $X \in L^2(\Omega)$, având media $\mathbb{E}(X) = \mu$ și dispersia $V(X) = \sigma^2$. Atunci

$$\mathbb{P}\{|X - \mu| > a\} \leq \frac{\sigma^2}{a^2}, \quad \forall a > 0.$$

Definim următoarele tipuri de convergență ale șirului $(X_n)_{n \geq 1}$ către limita X :

1. șirul $(X_n)_{n \geq 1}$ converge în distribuție (repartiție) la X , notat prin

$$X_n \xrightarrow{d} X,$$

dacă $\lim_{n \rightarrow \infty} F_n(x_0) = F(x_0)$, pentru orice punct de continuitate $x_0 \in \mathbb{R}$ al funcției F ;

2. șirul $(X_n)_{n \geq 1}$ converge în probabilitate la X , notat prin

$$X_n \xrightarrow{p} X,$$

dacă $\lim_{n \rightarrow \infty} \mathbb{P}\{|X_n - X| > \varepsilon\} = 0, \quad \forall \varepsilon > 0$;

3. șirul $(X_n)_{n \geq 1}$ converge aproape sigur la X , notat prin

$$X_n \xrightarrow{a.s.} X,$$

dacă $\mathbb{P}\{X_n \rightarrow X\} = 1$;

4. șirul $(X_n)_{n \geq 1}$ converge în spațiul $L^k(\Omega)$ la X , unde $k \in \mathbb{N}^*$, notat prin

$$X_n \xrightarrow{L^k} X,$$

dacă $\lim_{n \rightarrow \infty} \mathbb{E}(|X_n - X|^k) = 0$.

Au loc implicațiile

- $X_n \xrightarrow{p} X \implies X_n \xrightarrow{d} X$;
- $X_n \xrightarrow{a.s.} X \implies X_n \xrightarrow{p} X$;
- $X_n \xrightarrow{L^k} X \implies X_n \xrightarrow{p} X$.

Implicațiile reciproce sunt false.

Legea slabă a numerelor mari Fie $(X_n)_{n \geq 1}$ un șir de variabile aleatoare independente și identic distribuite (iid), cu $\mathbb{E}(X_1) = \mu$ și $V(X_1) = \sigma^2$. Notăm $S_n = X_1 + X_2 + \dots + X_n$, $n \in \mathbb{N}^*$. Atunci are loc convergența în probabilitate

$$\frac{S_n}{n} \xrightarrow{p} \mu.$$

Legea tare a numerelor mari Fie $(X_n)_{n \geq 1}$ un șir de variabile aleatoare independente și identic distribuite (iid), din spațiul L^4 ($\mathbb{E}(|X_1|^4) < \infty$) cu $\mathbb{E}(X_1) = \mu$. Fie $S_n = X_1 + X_2 + \dots + X_n$, $n \in \mathbb{N}^*$. Atunci

$$\frac{S_n}{n} \xrightarrow{a.s.} \mu.$$

Teorema limită centrală Fie $(X_n)_{n \geq 1}$ un șir de variabile aleatoare independente și identic distribuite (iid), cu $\mathbb{E}(X_1) = \mu$ și $V(X_1) = \sigma^2$. Considerăm șirul de variabile aleatoare $S_n = X_1 + X_2 + \dots + X_n$, $n \in \mathbb{N}^*$. Atunci:

1.

$$\lim_{n \rightarrow \infty} \mathbb{P} \left\{ a \leq \frac{S_n - n\mu}{\sigma\sqrt{n}} \leq b \right\} = \frac{1}{\sqrt{2\pi}} \int_a^b e^{-\frac{x^2}{2}}, \quad \forall a, b \in \mathbb{R}, \quad a < b;$$

2. (versiunea Lindeberg-Lévy) Are loc următoarea convergență în distribuție către o variabilă aleatoare gaussiană:

$$\frac{\sqrt{n}}{\sigma} \left(\frac{S_n}{n} - \mu \right) \xrightarrow{d} X,$$

unde $X \sim N(0, 1)$.

3.7 Test

1. Să se enunțe și să se demonstreze Legea slabă a numerelor mari.
2. Să se enunțe Teorema limită centrală, adaptată pentru variabile aleatoare de tip geometric.
3. Să se determine funcția de repartiție a variabilei aleatoare X care admite funcția caracteristică

$$\varphi_X(t) = \frac{1}{4} (1 + e^{it})^2.$$

4. Inegalitatea lui Cebîșev aplicată variabilei aleatoare X , cu media $E(X) = 3$ și dispersia $V(X) = \sigma^2$, stabilește:

$$\mathbb{P}\{|X - 3| \geq 2\} \leq 0,16.$$

Să se determine σ .

5. La un concurs de biatlon, un sportiv nimereste ținta cu probabilitatea de $\frac{4}{5}$. Știind că sportivul execută în concurs 25 de trageri, să se arate că șansa ca acesta să nimerască ținta de cel puțin 15 ori este mai mare de 85%.
6. Probabilitatea ca un monitor de calculator să nu aibă rezoluția acceptabilă este de 0,1. S-au cumpărat 1000 de monitoare. Care este probabilitatea ca mai mult de 100 monitoare să nu fie acceptabile? (Notă: se va utiliza aproximarea oferită de Teorema limită centrală.)

Capitolul 4

Elemente de statistică matematică

4.1 Introducere

Statistica matematică este o ramură importantă a matematicii, care utilizează rezultatele oferite de teoria probabilităților. Progresul societății umane are adeseori la bază *experimentul*. Cercetătorul realizează o experiență și obține o serie de date, pe baza cărora generalizează rezultatele experienței la o clasă de experiențe similare. Acest tip de extindere se datorează unui raționament de tip *inductiv* (obținerea unor informații generale din analiza unor informații particulare). Statistica analizează date concrete, locale, obținute experimental, pentru a prognoza date cu caracter general, a descoperi legile care guvernează fenomenul aleator studiat. Verosimilitatea prognozei (încrederea pe care o putem avea rezultatele deduse din analiza datelor experimentale), este analizată cu instrumente matematice.

Statistica operează cu noțiuni specifice. Astfel, **populația statistică** reprezintă mulțimea tuturor elementelor avute în vedere în cadrul unui **studiu statistic**. De regulă, pentru o populație mare, studiul statistic se realizează prin **sondaj**. Sondajul constă în observarea (examinarea, chestionarea) unei părți a populației, numită **eșantion**. Numărul elementelor unui eșantion (obținut prin sondaj și examinat) se numește **volumul eșantionului**. De regulă, volumul eșantionului se stabilește (pe baza unor evaluări matematice) astfel încât să poată furniza date generale concludente. Scopul principal al unui studiu statistic îl reprezintă **estimarea** unei caracteristici a populației statistice, pe baza datelor înregistrate în urma sondajului efectuat pentru un eșantion reprezentativ al populației respective. Funcția matematică care realizează estimarea se numește **estimator**.

4.2 Noțiuni de statistică descriptivă

4.2.1 Concepte de bază

- **Statistica**, ramură a matematicii, studiază metodele de înregistrare, descriere și analiză a datelor experimentale referitoare la un anumit fenomen în scopul formulării unor previziuni.
- **Populația statistică** este mulțimea (în sens matematic) care face obiectul unui anumit **studiu statistic**.

- **Unitate statistică** (individ) este un element component al unei populații statistice.
- **Caracteristică statistică** este una din însușirile unității statistice.
O caracteristică cantitativă este *măsurabilă*, iar una calitativă este *atributivă*.
Un studiu statistic a vizează una sau mai multe caracteristici statistice ale indivizilor unei populații statistice.
- **Eșantionul** este o submulțime a populației statistice, obținută printr-o **selecție**, pentru care se realizează evaluarea caracteristicii statistice. Pentru unele studii statistice, eşantionul reprezintă întreaga populație statistică. Numărul de elemente al eşantionului se numește **volumul** (efectivul) eşantionului.
- **Sondajul** este acțiunea de prevalare și înregistrare a valorilor uneia sau mai multor caracteristici statistice ale indivizilor unui eşantion fixat.
- **Tabelul statistic** conține înregistrarea valorilor numerice (datelor experimentale), numite **valori observate** obținute prin măsurarea caracteristicii tuturor unităților statistice ale eşantionului selecționat.
- **Frecvența relativă** a unei valori a caracteristicii este raportul dintre numărul indivizilor eşantionului pentru care s-a înregistrat valoarea respectivă și volumul eşantionului.
- **Distribuția statistică empirică** reprezintă repartitia valorilor observate ale caracteristicii pentru eşantionul selecționat (înregistrate în tabelul statistic). Din punct de vedere matematic, distribuția statistică (empirică) este funcția care realizează corespondența între numerele reale, obținute ca valori observate ale caracteristicii, și **frecvența relativă** a înregistrării lor.
- **Distribuțiile (repartițiile) statistice teoretice** reprezintă modele matematice idealizate ale distribuțiilor empirice. Concret, o distribuție statistică teoretică este descrisă de o funcție $f : \mathbb{R} \rightarrow [0, \infty)$ cu proprietatea $\int_{-\infty}^{\infty} f(x) dx = 1$, numită **densitate de probabilitate**.
Pentru anumite fenomene analizate statistic, distribuția empirică **tinde** la o anumită distribuție teoretică, dacă volumul eşantionului tinde (ipotetic) la infinit.
- **Teoria probabilităților** operează cu noțiunile de *spațiu de probabilitate* și *variabilă aleatoare*. O variabilă aleatoare este o funcție X , definită pe un spațiu de probabilitate, cu valori reale, având proprietatea că pentru orice număr real x se poate evalua probabilitatea $F(x)$ ca X să ia valori în intervalul $(-\infty, x]$, și anume:

$$F(x) = \mathbb{P}\{X \leq x\} \in [0, 1].$$

Spunem că variabila aleatoare X are densitatea de probabilitate f dacă:

$$F(x) = \int_{-\infty}^x f(t) dt, \text{ pentru orice număr real } x$$

Media unei variabile aleatoare X cu densitatea de probabilitate f se calculează prin:

$$\mathbb{E}(X) = \int_{-\infty}^{\infty} x f(x) dx$$

Dispersia unei variabile aleatoare X cu densitatea de probabilitate f se calculează prin:

$$\sigma^2(X) = \int_{-\infty}^{\infty} (x - \mu)^2 f(x) dx, \quad \text{unde } \mu = \mathbb{E}(X)$$

Un caz particular îl constituie *variabilele aleatoare finite*. O astfel de variabilă aleatoare X ia un număr finit de valori reale $x_1 < x_2 < \dots < x_k$ cu probabilitățile $p_1, p_2, \dots, p_k \in [0, 1]$. Avem deci:

$$p_i = \mathbb{P}\{X = x_i\}, \quad i = 1, 2, \dots, k; \quad p_1 + p_2 + \dots + p_k = 1.$$

În acest caz, media și respectiv dispersia variabilei aleatoare X se calculează după următoarele formule:

$$\mu = \mathbb{E}(X) = x_1 p_1 + x_2 p_2 + \dots + x_k p_k = \sum_{i=1}^k x_i p_i$$

$$\sigma^2(X) = (x_1 - \mu)^2 p_1 + (x_2 - \mu)^2 p_2 + \dots + (x_k - \mu)^2 p_k = \sum_{i=1}^k (x_i - \mu)^2 p_i.$$

• **Exemple de distribuții (repartiții, legi) teoretice clasice:**

1. **Legea normală de medie** μ și **dispersie** σ^2 are densitatea de probabilitate:

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}, \quad x \in \mathbb{R}$$

Graficul lui f are forma unui clopot, cunoscut sub denumirea de *clopotul lui Gauss*. Legea normală (sau legea lui *Gauss-Laplace*) joacă un rol central în teoria probabilităților, fiind *legea limită a sumelor normalizate ale șirurilor de variabile aleatoare independente și identic distribuite*.

Valorile unei variabile aleatoare X cu distribuție normală de medie μ și dispersie σ^2 se "concentrează" cu o probabilitate de 95% în intervalul $[\mu - 2\sigma, \mu + 2\sigma]$, centrat în valoarea medie μ . Mai precis avem:

$$P\{\mu - 2\sigma \leq X \leq \mu + 2\sigma\} = 0,9544 \dots$$

unde $\sigma = \sqrt{\sigma^2}$ se numește **abaterea standard** a variabilei aleatoare X .

2. **Repartiția** χ^2 cu $m \in \mathbb{N}^*$ **grade de libertate** are densitatea de probabilitate:

$$f(x) = \frac{1}{2^{\frac{m}{2}} \Gamma(\frac{m}{2})} x^{\frac{m}{2}-1} e^{-\frac{x}{2}}, \quad x > 0$$

unde:

$$\Gamma\left(\frac{m}{2}\right) = \int_0^{\infty} x^{\frac{m}{2}-1} e^{-x} dx.$$

Dacă o variabilă aleatoare X are repartiția χ^2 cu m grade de libertate, atunci media și respectiv dispersia variabilei aleatoare sunt următoarele:

$$\mathbb{E}(X) = m$$

$$\sigma^2(X) = 2m$$

Repartiția χ^2 are un rol important în statistica matematică în verificarea *ipotezelor statistice*.

4.2.2 Tipuri de distribuții statistice empirice. Tabele statistice. Reprezentări grafice.

În cadrul unui studiu statistic, datele experimentale obținute prin măsurarea valorică a unei caracteristici a unui eșantion considerat sunt înregistrate într-un tabel statistic. Acesta evidențiază o anumită distribuție statistică. După natura repartiției valorilor înregistrate, distingem două tipuri de distribuții statistice empirice (experimentale).

1) **Tipul finit (sau discret)** de distribuție corespunde cazului în care, ipotetic, caracteristica măsurată poate lua un număr finit de valori.

Considerăm un eșantion fixat de volum n . Aceasta înseamnă că numărul de unități statistice pentru care se înregistrează valoarea caracteristicii este egal cu n .

Presupunem că valorile înregistrate ale caracteristicii sunt numerele reale

$$x_1 < x_2 < \dots < x_k$$

unde k este un număr natural mai mic decât n .

Fiecarei valori realizate (înregistrate) a caracteristicii îi determinăm "frecvența" de apariție.

- **Frecvența absolută a valorii** x_i este numărul n_i de subiecți pentru care valoarea caracteristicii este x_i . Din definiție rezultă $0 \leq n_i \leq n$ și $\sum_{i=1}^k n_i = n$.
- **Frecvența relativă a valorii** x_i este numărul $f_i = \frac{n_i}{n}$.
Au loc relațiile: $f_i \in [0, 1]$ și $\sum_{i=1}^k f_i = 1$.
- **Frecvența procentuală a valorii** x_i este numărul $p_i = 100 \cdot \frac{n_i}{n} = 100 \cdot f_i$.
Avem $p_i \in [0, 100]$ și $\sum_{i=1}^k p_i = 100$. Pentru a evidenția că p_i reprezintă o mărime procentuală, se folosește curent notația $p_i \%$.

Frecvențele determinate ale valorilor, indicând distribuția statistică empirică, pot fi centralizate în *tabelul frecvențelor* sau pot fi reprezentate grafic prin *diagrama de structură*, *histograma* și respectiv *poligonul frecvențelor*.

- **Diagrama de structură** ilustrează distribuția statistică empirică prin partiția unui disc în sectoare de cerc cu ariile proporționale cu frecvențele relative ale valorilor. Sectorul reprezentând valoarea x_i are unghiul de la centru de măsură $\alpha_i = f_i \cdot 360^\circ$.
- **Poligonul frecvențelor** se obține, într-un sistem de axe de coordonate, unind succesiv prin segmente punctele de coordonate $(x_1, f_1), (x_2, f_2), \dots, (x_k, f_k)$.
- **Histograma** ilustrează, într-un sistem de axe de coordonate, frecvențele relative (sau procentuale) ale valorilor x_i prin dreptunghiuri de înălțime f_i (respectiv p_i) dispuse cu baza pe axa absciselor, în dreptul absciselor x_i .

Exemplul 1 La o probă sportivă fiecare participant a efectuat 6 aruncări la coșul de baschet, realizând între 0 și 6 aruncări reușite. Rezultatele obținute de cei 40 de participanți sunt prezentate sintetic în tabelul următor:


numărul de aruncări reușite	0	1	2	3	4	5	6	
numărul de participanți	2	4	8	15	4	6	1	total 40

Volumul eșantionului considerat este $n = 40$ iar numărul de valori ale caracteristicii este $k = 7$. Prezentăm tabelul frecvențelor, diagrama de structură, histograma și respectiv poligonul frecvențelor asociate studiului statistic considerat.


A) Tabelul frecvențelor

valorile x_i	frecvențele		
	absolute (n_i)	relative (f_i)	procentuale (p_i %)
0	2	0,050	5,0 %
1	4	0,100	10,0 %
2	8	0,200	20,0 %
3	15	0,375	37,5 %
4	4	0,100	10,0 %
5	6	0,150	15,0 %
6	1	0,025	2,5 %
	$\sum_{i=1}^7 n_i = 40$	$\sum_{i=1}^7 f_i = 1$	$\sum_{i=1}^7 p_i = 100$


B) Diagrama de structură




C) Histograma



D) Poligonul frecvențelor



2) **Tipul continuu** de distribuție corespunde cazului când valorile caracteristicii sunt numere reale situate într-un anumit interval $[a, b]$. Pentru a grupa valorile caracteristicii, se fixează, ținând cont de specificul studiului statistic efectuat, un număr întreg $k > 1$ și se împarte intervalul $(a, b]$ în k subintervale de aceeași lungime $l = \frac{b-a}{k}$. Notăm, în ordine, aceste intervale I_1, I_2, \dots, I_k . Astfel, $I_i = (a + \frac{(i-1)(b-a)}{k}, a + \frac{i(b-a)}{k}]$, $i = 1, 2, \dots, k$. Fie un eșantion fixat de volum n cu $n > k$. Fiecărui interval I_i i se asociază "frecvența de apariție"; vom nota cu x_i valoarea "centrală" a intervalului, adică $x_i = a + \frac{(2i-1)(b-a)}{2k}$, obținută făcând media aritmetică a capetelor intervalului I_i (a se vedea figura următoare).



- **Frecvența absolută a intervalului I_i** este numărul n_i de subiecți pentru care valoarea caracteristicii aparține intervalului I_i .
- **Frecvența relativă a intervalului I_i** este numărul $f_i = \frac{n_i}{n}$.
- **Frecvența procentuală a intervalului I_i** este numărul $p_i = 100 \cdot f_i$.

Frecvențele determinate ale valorilor, indicând distribuția statistică empirică, pot fi centralizate în *tabelul frecvențelor* sau pot fi reprezentate grafic prin *diagrama de structură*, *histograma* și respectiv *poligonul frecvențelor* care nu diferă de cele descrise pentru distribuții finite.

Exemplul 2 La o probă contracronometru de ciclism au participat 148 de concurenți. După înregistrarea timpilor de parcurs, s-au grupat rezultatele în 6 intervale de câte 30" și s-au calculat frecvențele intervalelor, obținându-se următorul tabel:

Tabelul frecvențelor

intervalele I_i	valorile centrale x_i	frecvențele		
		absolute (n_i)	relative (f_i)	procentuale (p_i %)
$(48', 48'30"]$	48'15"	7	0,047	4,7 %
$(48'30", 49']$	48'45"	28	0,189	18,9 %
$(49', 49'30"]$	49'15"	53	0,358	35,8 %
$(49'30", 50']$	49'45"	42	0,283	28,3 %
$(50', 50'30"]$	50'15"	10	0,067	6,7 %
$(50'30", 51']$	50'45"	8	0,054	5,4 %
		$\sum_{i=1}^6 n_i = 148$	$\sum_{i=1}^6 f_i = 1$	$\sum_{i=1}^6 p_i = 100$

4.2.3 Indicatori statistici

Pentru o distribuție statistică empirică, consemnată în tabelul frecvențelor, determinăm o serie de **indicatori statistici** în scopul obținerii unor informații cu caracter general

privind repartizarea valorilor caracteristicii studiate. Cei mai importanți indicatori statistici sunt: media, mediana și respectiv dispersia distribuției. Media și dispersia indică, fiecare în parte, valoarea "așteptată" a distribuției respective, într-o accepțiune specifică fiecărei noțiuni. Dispersia și respectiv abaterea standard indică gradul de "împrăștiere" a valorilor față de valoarea "centrală" a distribuției. Coeficientul de variație, calculat prin raportarea abaterii standard la medie, oferă posibilitatea stabilirii gradului de omogenitate al eșantionului.

Considerăm o distribuție statistică empirică, asociată unei caracteristici X , denumită variabilă aleatoare empirică, care ia valorile $x_1 < x_2 < \dots < x_k$ cu frecvențele absolute n_1, n_2, \dots, n_k și frecvențele relative f_1, f_2, \dots, f_k .

- **Media** $\bar{x} = \mathbb{E}(X)$ a variabilei empirice X se calculează prin:

$$\bar{x} = x_1 f_1 + x_2 f_2 + \dots + x_k f_k,$$

sau, utilizând scrierea prescurtată, $\bar{x} = \mathbb{E}(X) = \sum_{i=1}^k x_i f_i$.

- **Mediana** $Med = Med(X)$ a variabilei X , corespunzând unui eșantion de volum n , se definește astfel: se ordonează crescător valorile caracteristicii tuturor subiecților eșantionului, obținându-se șirul de valori

$$v_1 \leq v_2 \leq \dots \leq v_n.$$

Distingem două situații:

1. dacă $n = 2p + 1$, cu p - număr natural (deci n este un număr natural impar), atunci $Med = v_{p+1}$;
2. dacă $n = 2p$, cu p - număr natural (deci n este un număr natural par), atunci $Med = \frac{v_p + v_{p+1}}{2}$.

Observăm că din definiția medianei reiese că aceasta este *valoarea care "împarte" eșantionul în două părți de volume egale*

Mediana se mai poate determina și utilizând frecvențele absolute n_1, n_2, \dots, n_k ale valorilor $x_1 < x_2 < \dots < x_k$, după cum urmează:

$$Med = \begin{cases} x_i, & \text{dacă } n_1 + n_2 + \dots + n_{i-1} < \frac{n}{2} < n_1 + n_2 + \dots + n_{i-1} + n_i \\ \frac{x_i + x_{i+1}}{2}, & \text{dacă } \frac{n}{2} = n_1 + n_2 + \dots + n_{i-1} + n_i \end{cases}$$

- **Amplitudinea** $W = W(X)$ a variabilei X se definește prin:

$$W = x_{max} - x_{min}$$

Astfel, dacă X are o distribuție de *tip finit* atunci $W = x_k - x_1$, iar dacă X are o distribuție de *tip continuu* cu valorile în intervalul $(a, b]$, atunci $W(X) = b - a$.

- **Dispersia** $\sigma^2 = \sigma^2(X)$ a variabilei X se definește prin:

$$\sigma^2 = \sum_{i=1}^k (x_i - \bar{x})^2 f_i,$$

unde $\bar{x} = \mathbb{E}(X)$ este media variabilei X .

- **Abaterea standard** $\sigma = \sigma(X)$ a variabilei X se definește prin:

$$\sigma = \sqrt{\sigma^2}$$

- **Coeficientul de variație** $C_v = C_v(X)$ al variabilei X , se definește, numai în cazul când toate valorile x_i ale distribuției X sunt pozitive, prin:

$$C_v = \frac{\sigma}{\bar{x}}$$

- **Expresia procentuală coeficientului de variație** $C_{v\%} = C_{v\%}(X)$ este:

$$C_{v\%} = 100 \cdot C_v \%$$

Tabelul următor prezintă interpretarea curentă a **omogenității eșantionului în raport cu variabila X** după valorile coeficientului de variație exprimat procentual:

Coeficientul de variație $C_{v\%}$	Omogenitatea
0-10%	omogenitate mare
10-20%	omogenitate medie
20-35%	omogenitate mică
peste 35%	eșantion neomogen

Să urmărim calculul indicatorilor statistici definiți anterior pentru distribuțiile din exemplele anterioare. Vom nota cu X variabila empirică cu distribuția prezentată în Exemplul 1 și respectiv cu Y variabila empirică cu distribuția descrisă în Exemplul 2.

4.2.4 Calculul indicatorilor statistici ai distribuției variabilei X (Exemplul 1).

Media:

$$\bar{x} = 0 \cdot 0,05 + 1 \cdot 0,1 + 2 \cdot 0,2 + 3 \cdot 0,375 + 4 \cdot 0,1 + 5 \cdot 0,15 + 6 \cdot 0,025 = 2,925$$

Rezultă că numărul mediu de reușite este:

$$\bar{x} = \mathbb{E}(X) \cong 3$$

Mediana:

Avem $n : 2 = 20$ și $n_1 + n_2 + n_3 = 14 < 20 < 29 = n_1 + n_2 + n_3 + n_4$, deci $Med(X) = x_4$, sau:

$$Med(X) = 3.$$

Amplitudinea:

$$W(X) = 6 - 0 = 6$$

Dispersia:

$\sigma^2(X) = (0 - 2,925)^2 \cdot 0,05 + (1 - 2,925)^2 \cdot 0,1 + (2 - 2,925)^2 \cdot 0,2 + (3 - 2,925)^2 \cdot 0,375 + (4 - 2,925)^2 \cdot 0,1 + (5 - 2,925)^2 \cdot 0,15 + (6 - 2,925)^2 \cdot 0,025 = 1,969 \dots$ Dispersia valorilor (abaterea medie pătratică) este deci:

$$\sigma^2(X) \cong 1,97$$

Abaterea standard:

$$\sigma(X) = \sqrt{1,969} \cong 1,403$$

Coeficientul de variație:

$$C_v(X) = \frac{1,403}{2,925} \cong 0,4797$$

Expresia procentuală a coeficientul de variație:

$$C_{v\%}(X) \cong 48\%$$

Interpretare: *eșantion neomogen*.

4.2.5 Calculul indicatorilor statistici ai distribuției variabilei Y (Exemplul 2).

Media

$\bar{x} = 48,25 \cdot 0,047 + 48,75 \cdot 0,189 + 49,25 \cdot 0,358 + 49,75 \cdot 0,283 + 50,25 \cdot 0,067 + 50,75 \cdot 0,054 = 49,29$.

Rezultă că timpul mediu înregistrat al probei este:

$$\mathbb{E}(Y) = \bar{x} = 49,29' \cong 49'18''.$$

Mediana:

Avem: $n : 2 = 74$ și $n_1 + n_2 = 35 < 74 < 88 = n_1 + n_2 + n_3$, deci $Med(Y) = x_3$, adică:

$$Med(Y) = 49'15''$$

Amplitudinea:

$$W(Y) = 51 - 48 = 3 \text{ (minute)}$$

Dispersia:

$\sigma^2(Y) = (48,25 - 49,29)^2 \cdot 0,047 + (48,75 - 49,29)^2 \cdot 0,189 + (49,25 - 49,29)^2 \cdot 0,358 + (49,75 - 49,29)^2 \cdot 0,283 + (50,25 - 49,29)^2 \cdot 0,067 + (50,75 - 49,29)^2 \cdot 0,054 = 0,34325 \dots$

$$\sigma^2(Y) \cong 0,343$$

Abaterea standard:

$$\sigma(Y) = \sqrt{0,343} \cong 0,586$$

Coeficientul de variație:

$$C_v(Y) = \frac{0,586}{49,29} \cong 0,012$$

Exprimarea procentuală a coeficientului de variație:

$$C_{v\%}(Y) \cong 1,2 \%$$

Interpretarea: *eșantion foarte omogen.*

4.2.6 Compararea a două distribuții empirice

Să presupunem că pentru un eșantion fixat de volum n se sondează în paralel două caracteristici (variabile empirice) X și Y și se pune problema existenței unei conexiuni între distribuțiile acestora. Pentru obținerea unei concluzii se recurge la calculul unor indici de corelație asociați perechii de variabile X și Y .

4.2.7 Corelația și coeficientul de corelație

Fie $\bar{x} = \mathbb{E}(X)$, $\bar{y} = \mathbb{E}(Y)$ mediile variabilelor X și Y , iar σ_X , σ_Y abaterea lor standard.

Presupunem că X ia valorile $x_1 < x_2 < \dots < x_k$ iar Y ia valorile $y_1 < y_2 < \dots < y_l$. Notăm $n_{i,j}$ numărul unităților statistice ale eșantionului pentru care caracteristica X ia valoarea x_i iar caracteristica Y ia valoarea y_j , unde $i = 1, 2, \dots, k$ și $j = 1, 2, \dots, l$. Fie $f_{i,j} = \frac{n_{i,j}}{n}$ frecvența relativă a perechii de valori (x_i, y_j) .

Corelația $c_{X,Y}$ a variabilelor X și Y se definește prin:

$$c_{X,Y} = \mathbb{E}((X - \bar{x})(Y - \bar{y})) = \sum_{\substack{i=\overline{1,k} \\ j=\overline{1,l}}} (x_i - \bar{x})(y_j - \bar{y})f_{i,j}$$

Coeficientul de corelație (Pearson) $r = r_{X,Y}$ al variabilelor X și Y al variabilelor X și Y se definește prin:

$$r = \frac{c_{X,Y}}{\sigma_X \cdot \sigma_Y}.$$

Pe baza unei inegalități matematice fundamentale (*inegalitatea lui Cauchy*) se demonstrează că, oricare ar fi distribuțiile variabilelor X și Y , avem:

$$-1 \leq r \leq 1.$$

Interpretarea valorii coeficientului de corelație r este următoarea:

1. dacă r este pozitiv, atunci variabilele X și Y sunt *corelate*, adică tendința este ca atunci când variabila X ia o "valoare mare" și variabila Y să ia tot o "valoare mare". Variabilele X și Y sunt cu atât mai puternic corelate cu cât coeficientul lor de corelație este mai apropiat de valoarea 1.
2. dacă r este negativ, atunci variabilele X și Y sunt *invers corelate*, adică tendința este ca atunci când variabila X ia o "valoare mare" variabila Y să ia o "valoare mică".
3. dacă r este apropiat de valoarea 0, atunci variabilele X și Y sunt *independente* sau cu o *dependență slabă*.

4.2.8 Metoda corerației rangurilor

Această metodă, datorată lui Spearman, se utilizează atunci când volumul eșantionului este mic (de regulă $n < 30$). Fiecărui individ $i \in \{1, 2, \dots, n\}$ al eșantionului i se asociază o pereche de **ranguri** $(r_i(X), r_i(Y))$, cu $r_i(X), r_i(Y) \in [1, n]$. Aceste ranguri se determină în urma realizării a câte unui "clasament" crescător al valorilor înregistrate pentru fiecare din caracteristicile (variabilele) X și Y . Rangurile $r_i(X)$ și respectiv $r_i(Y)$ exprimă "poziția" (eventual intermediară) a individului i în fiecare din cele două "clasamente" de valori crescătoare.

Notăm $d_i = r_i(X) - r_i(Y)$, $i = 1, 2, \dots, n$.

Coeficientul de corelație al rangurilor $\rho = \rho_{X,Y}$ **asociat variabilelor** X și Y se definește prin:

$$\rho = 1 - \frac{6 \sum_{i=1}^n d_i^2}{n(n^2 - 1)}$$

Se poate verifica prin calcul că, indiferent de distribuția rangurilor, avem:

$$0 \leq \rho \leq 1$$

Dacă ρ este apropiat de 1, atunci variabilele X și Y sunt *corelate* iar dacă ρ este apropiat de 0, atunci variabilele X și Y sunt *invers corelate*.

4.3 Statistica eșantioanelor Bernoulli

Cel mai simplu studiu statistic se referă la analiza cazului binar: fiecare individ (element) al populației statistice are valoarea 1 sau 0 (interpretare posibilă: *la un chestionar, fiecare unitate statistică optează pentru 0 sau 1*).

Ne interesează proporția indivizilor cu valoarea 1 în cadrul întregii populații statistice. Examinarea (chestionarea) prin sondaj a fiecărui individ al eșantionului selecționat ne va permite să determinăm numărul indivizilor care "valorează 1" dintr-un eșantion de volum n . Pe baza datelor obținute, dorim să apreciem care este probabilitatea ca un individ ales arbitrar din populația statistică să "valoreze 1".

Cazul unei populații de volum mic în raport cu eșantionul considerat

La o populație "mică", este logic să apelăm la modelul oferit de legea hipergeometrică, întrucât extragerea unui eșantion dintr-o populație mică afectează în mod cert proporția

valorii 1 în cadrul populației nesondate.

Fie a numărul de indivizi ai populației statistice cu caracteristica de valoare 1 și b numărul de indivizi ai populației statistice cu caracteristica de valoare 0. Astfel $N = a+b$ reprezintă volumul populației, iar

$$\theta = \frac{a}{a+b}$$

reprezintă probabilitatea ca un individ X , arbitrar, al populației statistice să valoreze 1. Avem deci

$$\theta = \mathbb{P}\{X = 1\} = \frac{a}{a+b}.$$

Să presupunem la un sondaj de volum $n < N$, se constată că $0 \leq i \leq n$ indivizi au valoarea caracteristicii egală cu 1.

Aproximarea $\theta \approx \frac{i}{n}$ este plauzibilă, dar trebuie privită cu precauție, deoarece probabilitatea ca exact i indivizi din n să valoreze 1 este dată de

$$p_{i/n} = \frac{C_a^i C_b^{n-i}}{C_N^n},$$

conform **schemei hipergeometrice**.

Cazul unei populații de volum mare în raport cu eșantionul considerat

Dacă volumul populației este "mare" în raport cu volumul eșantionului, atunci este rezonabil să considerăm că fiecare element al populației statistice se reprezintă printr-o variabilă aleatoare Bernoulli X , cu distribuția

$$X : \begin{pmatrix} 0 & 1 \\ 1-\theta & \theta \end{pmatrix},$$

unde parametrul θ (necunoscut) reprezintă proporția valorii 1 în populația statistică.

Astfel, $\mathbb{P}\{X = 1\} = \theta$ reprezintă probabilitatea (șansa) ca unitatea statistică X să aibă valoarea 1. Evident, $\mathbb{P}\{X = 0\} = 1 - \theta$ reprezintă probabilitatea (șansa) ca X să ia valoarea 0.

Obiectul studiului statistic întreprins constă în **estimarea** parametrului θ , din observarea unui eșantion de volum n .

Eșantionul poate fi reprezentat prin vectorul aleator (X_1, X_2, \dots, X_n) , cu componentele variabile aleatoare iid, de tip $B(1, \theta)$.

Distribuția eșantionului, care ia valori în mulțimea $\{0, 1\}^n$, este determinată de distribuția (comună) a variabilelor aleatoare X_1, X_2, \dots, X_n .

O **statistică** (sau un **estimator**) se definește ca o funcție a variabilelor aleatoare "observabile" (cele ale n-eșantionului), deci care nu depinde de parametrii necunoscuți.

Pentru evaluarea apriorică a parametrului necunoscut θ se propune estimatorul **media empirică**, definit prin:

$$\overline{X}_n = \frac{S_n}{n}, \text{ unde } S_n = X_1 + X_2 + \dots + X_n.$$

În fapt, media empirică exprimă frecvența de apariție a valorii 1, deci, intuitiv, pare a oferi o bună evaluare a parametrului θ . Descriem în continuare proprietățile principale ale mediei empirice \overline{X}_n , ca estimator a lui θ .

4.3.1 Proprietățile estimatorului \overline{X}_n

1. \overline{X}_n este un **estimator fără abatere** a lui θ , adică:

$$\mathbb{E}_\theta(\overline{X}_n) = \theta, \quad \forall \theta \in (0, 1).$$

Demonstrație. Pentru orice $\theta \in (0, 1)$ avem:

$$\mathbb{E}_\theta(\overline{X}_n) = \left[\sum_{k=1}^n \mathbb{E}_\theta(X_k) \right] / n = (n\theta) / n = \theta.$$

2. \overline{X}_n este **unicul estimator fără abatere** a lui θ , care depinde de S_n .

Demonstrație. Fie $g : \{0, 1, 2, \dots, n\} \rightarrow \mathbb{R}$ o funcție cu proprietatea că $\tilde{X} = g(S_n)$ este un estimator fără abatere a parametrului θ , adică:

$$\mathbb{E}_\theta(\tilde{X}) = \mathbb{E}_\theta[g(S_n)] = \theta, \quad \forall \theta \in (0, 1).$$

Deoarece $S_n \sim B(n, \theta)$, avem

$$\mathbb{E}_\theta[g(S_n)] = \sum_{k=0}^n g(k) \mathbb{P}\{S_n = k\} = \sum_{k=0}^n g(k) C_n^k \theta^k (1 - \theta)^{n-k},$$

iar pe de altă parte

$$\theta = \mathbb{E}_\theta(\overline{X}_n) = \mathbb{E}_\theta\left(\frac{S_n}{n}\right) = \sum_{k=0}^n \frac{k}{n} \mathbb{P}\{S_n = k\} = \sum_{k=0}^n \frac{k}{n} C_n^k \theta^k (1 - \theta)^{n-k}.$$

Astfel, $\sum_{k=0}^n g(k) C_n^k \theta^k (1 - \theta)^{n-k} = \theta = \sum_{k=0}^n \frac{k}{n} C_n^k \theta^k (1 - \theta)^{n-k}$, $\forall \theta \in (0, 1)$, de unde obținem

$$\sum_{k=0}^n \left(g(k) - \frac{k}{n}\right) C_n^k \left(\frac{\theta}{1 - \theta}\right)^k = 0, \quad \forall \theta \in (0, 1).$$

Rezultă că polinomul $f(X) = \sum_{k=0}^n \left(g(k) - \frac{k}{n}\right) C_n^k X^k$ are o infinitate de rădăcini, deci este polinomul identic nul.

Prin urmare $g(k) = k/n$, $k = 0, 1, \dots, n$, deci

$$\tilde{X} = g(S_n) = \frac{S_n}{n} = \overline{X}_n.$$

3. \overline{X}_n este **estimatorul de maximă verosimilitate** a lui θ .

Demonstrație.

Să presupunem că, în urma sodajului, au fost observate valorile $(x_1, x_2, \dots, x_n) \in \{0, 1\}^n$. Notăm $s_n = \sum_{k=1}^n x_k$. Astfel, s_n indică numărul de componente egale cu 1 ale vectorului (x_1, x_2, \dots, x_n) .

Datorită independenței variabilelor aleatoare X_1, X_2, \dots, X_n , probabilitatea de a observa secvență de valori (x_1, x_2, \dots, x_n) este

$$\mathbb{P}\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\} = \prod_{i=1}^n \mathbb{P}\{X_i = x_i\} = \theta^{s_n} (1 - \theta)^{n-s_n}.$$

Atunci, cea mai *verosimilă* valoare a parametrului θ este cea care maximizează funcția

$$L : (0, 1) \rightarrow (0, 1), \quad L(x) = x^{s_n} (1 - x)^{n-s_n}.$$

Evident, $0 \leq s_n \leq n$. Avem

$$\begin{aligned} L'(x) &= s_n x^{s_n-1} (1-x)^{n-s_n} - (n-s_n) x^{s_n} (1-x)^{n-s_n-1} = \\ &= x^{s_n-1} (1-x)^{n-s_n-1} [s_n(1-x) - (n-s_n)x] = x^{s_n-1} (1-x)^{n-s_n-1} (s_n - nx). \end{aligned}$$

1) Dacă $s_n \in (1, n)$, atunci $\frac{s_n}{n} \in (0, 1)$. Deducem că L' admite rădăcina unică $\bar{x} = \frac{s_n}{n}$, este strict pozitivă pe intervalul $(0, \bar{x})$ și strict negativă pe intervalul $(\bar{x}, 1)$. Ca urmare, L își atinge maximul în punctul $\bar{x} = \frac{s_n}{n}$.

2) Dacă $s_n = 0$, atunci funcția L este strict descrescătoare pe $(0, 1)$ și vom alege, în mod firesc, $\bar{x} = 0 = \frac{s_n}{n}$.

3) Dacă $s_n = n$, atunci funcția L este strict crescătoare pe $(0, 1)$ și alegem $\bar{x} = 1 = \frac{s_n}{n}$.

Rezultă că

$$\bar{X}_n = \frac{S_n}{n}$$

reprezintă estimatorul de maximă verosimilitate a lui θ .

4. Când talia eșantionului tinde la infinit, \overline{X}_n converge la θ cu o rată exponențială.

Pe baza inegalității lui Cebîșev, se demonstrează convergența în probabilitate stabilită de **Legea slabă numerelor mari**:

$$\overline{X}_n = \frac{S_n}{n} \xrightarrow{p} \theta.$$

Ca urmare, are loc și convergența în distribuție

$$\overline{X}_n = \frac{S_n}{n} \xrightarrow{d} \theta$$

Faptul că rata convergenței este exponențială se deduce din *Teorema marilor deviații*, pe care nu o vom include în această prezentare.

5. Când volumul eșantionului tinde la infinit, **riscul pătratic mediu al estimatorului** \overline{X}_n a lui θ **converge la 0**.

Demonstrație. Riscul pătratic mediu al estimatorului \overline{X}_n este definit prin $\mathbb{E}_\theta (\overline{X}_n - \theta)^2$. Avem

$$\begin{aligned} \mathbb{E}_\theta (\overline{X}_n - \theta)^2 &= \mathbb{E}_\theta \left(\frac{S_n}{n} - \theta \right)^2 = \frac{1}{n^2} \mathbb{E}_\theta (S_n - n\theta)^2 = \frac{V(S_n)}{n} = \\ &= \frac{nV(X_1)}{n^2} = \frac{\theta(1-\theta)}{n} \leq \frac{1}{4n}, \end{aligned}$$

de unde

$$\mathbb{E}_\theta (\overline{X}_n - \theta)^2 \xrightarrow{n \rightarrow \infty} 0.$$

6. Abaterea lui \overline{X}_n față de θ poate fi evaluată prin *Teorema limită centrală*.

Demonstrație. Conform **Teoremei limită centrală**,

$$\sqrt{\frac{n}{\theta(1-\theta)}} (\overline{X}_n - \theta) = \frac{S_n - n\theta}{\sqrt{n\theta(1-\theta)}} \xrightarrow{d} Z,$$

unde $Z \sim N(0, 1)$.

Fie $a > 0$. Pentru $n \geq \frac{4\theta(1-\theta)}{a^2}$, avem $\frac{a\sqrt{n}}{\sqrt{\theta(1-\theta)}} \geq 2$, de unde

$$\begin{aligned} \mathbb{P}_\theta \{ |\overline{X}_n - \theta| \geq a \} &= \mathbb{P} \left\{ \left| \frac{S_n - n\theta}{\sqrt{n\theta(1-\theta)}} \right| \geq \frac{a\sqrt{n}}{\sqrt{\theta(1-\theta)}} \right\} \\ &\leq \mathbb{P} \left\{ \left| \frac{S_n - n\theta}{\sqrt{n\theta(1-\theta)}} \right| \geq 2 \right\} \approx \frac{1}{\sqrt{2\pi}} \int_{|x| \geq 2} e^{-\frac{x^2}{2}} dx < 0,05. \end{aligned}$$

4.3.2 Estimare bayesiană

Media empirică \bar{X}_n este o estimare judicioasă a parametrului θ în absența oricăror informații suplimentare. Dar problema se modifică în cazul unor informații apriorice despre θ . Dacă aceste informații există, mai precis, dacă se cunoaște o măsură de probabilitate pe $[0, 1]$ reprezentând distribuția valorilor posibile ale lui θ , atunci se va cerceta estimatorul $g(S_n)$ a lui θ care minimizează riscul pătratic mediu, ținând cont de această distribuție.

Fie D o mulțime numărabilă din $[0, 1]$, iar $\rho : D \rightarrow [0, 1]$ o măsură de probabilitate pe D , cu $\sum_{x \in D} \rho(x) = 1$. Pentru o funcție g definită pe $\{0, 1, \dots, n\}$ cu valori în $[0, 1]$, riscul pătratic mediu al estimatorului $g(S_n)$ este

$$\begin{aligned} \sum_{\theta \in D} \rho(\theta) \mathbb{E}_{\theta} [g(S_n) - \theta]^2 &= \sum_{\theta \in D} \rho(\theta) \sum_{k=0}^n (g(k) - \theta)^2 C_n^k \theta^k (1 - \theta)^{n-k} \\ &= \sum_{k=0}^n C_n^k \left(\sum_{\theta \in D} \rho(\theta) (g(k) - \theta)^2 \theta^k (1 - \theta)^{n-k} \right). \end{aligned}$$

Pentru $k \in \{0, 1, \dots, n\}$, considerăm funcția $\psi_k : [0, 1] \rightarrow [0, \infty)$, definită prin

$$\psi_k(x) = \sum_{\theta \in D} \rho(\theta) \theta^k (1 - \theta)^{n-k} (x - \theta)^2, \quad x \in [0, 1].$$

Avem

$$\psi'_k(x) = 2 \sum_{\theta \in D} \rho(\theta) \theta^k (1 - \theta)^{n-k} (x - \theta), \quad x \in [0, 1].$$

Studiind semnul derivatei, deducem că ψ_k atinge minimumul în punctul

$$x_k = \frac{\sum_{\theta \in D} \rho(\theta) \theta^{k+1} (1 - \theta)^{n-k}}{\sum_{\theta \in D} \rho(\theta) \theta^k (1 - \theta)^{n-k}} \in [0, 1].$$

Vom defini deci *estimatorul bayesian* a lui θ de risc pătratic mediu minim:

$$g(S_n) = \frac{\sum_{\theta \in D} \rho(\theta) \theta^{S_n+1} (1 - \theta)^{n-S_n}}{\sum_{\theta \in D} \rho(\theta) \theta^{S_n} (1 - \theta)^{n-S_n}}.$$

Similar, dacă se cunoaște "a priori" densitatea de probabilitate f a lui θ pe intervalul $[0, 1]$, atunci *estimatorul bayesian* a lui θ , dependent de S_n , având *riscul pătratic minim*, va fi

$$g(S_n) = \frac{\int_0^1 \theta^{S_n+1} (1 - \theta)^{n-S_n} f(\theta) d\theta}{\int_0^1 \theta^{S_n} (1 - \theta)^{n-S_n} f(\theta) d\theta}.$$

4.4 Statistici, estimatori

Am urmărit anterior exemplul concret al estimării parametrului unei distribuții Bernoulli. Vom defini acum, în cadrul general, noțiunile de **statistică** și **estimator**.

În cele ce urmează, X desemnează o caracteristică statistică cantitativă (măsurabilă) a unei populații statistice P . Caracteristica X se interpretează din punct de vedere teoretic ca o variabilă aleatoare. Concret, vom presupune că $X : \Omega \rightarrow \mathbb{R}$ este o variabilă aleatoare definită pe un spațiu de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$, de regulă neexplicitat.

Considerăm **variabilele aleatoare de selecție** X_1, X_2, \dots, X_n , reprezentând valorile măsurate ale caracteristicii pentru indivizii i_1, i_2, \dots, i_n selecționați prin sondaj din populația statistică P .

Teoretic, considerăm un șir de variabile aleatoare independente și identic distribuite (i.i.d), având distribuția variabilei aleatoare X . Astfel, X_1, X_2, \dots reprezintă "replici" independente ale variabilei aleatoare X .

În rezumat, formalizarea teoretică este realizată în felul următor. Fie

$$\Omega^\infty = \{\bar{\omega} = (\omega_i)_{i \in \mathbb{N}^*} : \omega_i \in \Omega, \forall i \in \mathbb{N}^*\}$$

mulțimea șirurilor cu termenii în mulțimea Ω . Pentru fiecare $n \in \mathbb{N}^*$, variabila aleatoare de selecție X_n se definește prin:

$$X_n : \Omega^\infty \rightarrow \mathbb{R}, X_n(\bar{\omega}) = X(\omega_n), \bar{\omega} \in \Omega^\infty,$$

unde ω_n este termenul de rang n al șirului $\bar{\omega} \in \Omega^\infty$.

Se construiește spațiul de probabilitate $(\Omega^\infty, \mathcal{F}^\infty, \mathbb{P}^\infty)$ (nu dăm detalii), astfel încât, pentru oricare număr natural nenul n , să avem

$$\mathbb{P}^\infty\{X_n \in A\} = \mathbb{P}\{X \in A\}, \forall A \in \mathcal{B}_{\mathbb{R}},$$

iar

$$\mathbb{P}^\infty\{X_i \in A_i, i = \overline{1, n}\} = \prod_{i=1}^n \mathbb{P}^\infty\{X_i \in A_i\} = \prod_{i=1}^n \mathbb{P}\{X \in A_i\}, \forall A_i \in \mathcal{B}_{\mathbb{R}}, \overline{1, n}.$$

Enunțăm definițiile conceptelor de **estimator** și **statistică**.

Definiția 4.4.1. Considerăm o variabilă aleatoare X definită pe spațiul de probabilitate $(\Omega, \mathcal{F}, \mathbb{P})$ și un șir de variabile aleatoare de selecție $(X_n)_{n \geq 1}$. Fie $A \in \mathbb{R}$ o caracteristică numerică a distribuției lui X , iar $(g_n)_{n \geq 1}$ un șir de funcții, $g_n : \mathbb{R}^n \rightarrow \mathbb{R}$, $n \in \mathbb{N}^*$.

1. Șirul de variabile aleatoare $(g_n(X_1, X_2, \dots, X_n))_{n \geq 1}$, unde

$$g_n(X_1, X_2, \dots, X_n) : \Omega^\infty \rightarrow \mathbb{R}, n \in \mathbb{N}^*,$$

se numește **statistică** (asociată șirurilor $(g_n)_{n \geq 1}$ și $(X_n)_{n \geq 1}$).

2. Statistica $(g_n(X_1, X_2, \dots, X_n))_{n \geq 1}$ se numește:

(a) **corectă relativ la** A dacă

$$(i) \lim_{n \rightarrow \infty} \mathbb{E}[g_n(X_1, X_2, \dots, X_n)] = A;$$

$$(ii) \lim_{n \rightarrow \infty} V[g_n(X_1, X_2, \dots, X_n)] = 0.$$

(b) **fără abatere (absolut corectă/nedeplasată) relativ la** A dacă

$$(i) \mathbb{E}[g_n(X_1, X_2, \dots, X_n)] = A, \forall n \in \mathbb{N}^*;$$

$$(ii) \lim_{n \rightarrow \infty} V[g_n(X_1, X_2, \dots, X_n)] = 0.$$

(c) *estimator pentru A dacă*

$$\lim_{n \rightarrow \infty} \mathbb{P}^\infty \{|g_n(X_1, X_2, \dots, X_n) - A| > \varepsilon\} = 0, \quad \forall \varepsilon > 0.$$

Evident, o statistică fără abatere relativ la A este o statistică corectă relativ la A . Are loc următorul rezultat fundamental.

Teorema 4.4.1. *O statistică corectă relativ la o caracteristică numerică a unei distribuții este un estimator pentru acea caracteristică.*

Demonstrație.

Fie $(g_n(X_1, X_2, \dots, X_n))_{n \geq 1}$ o statistică corectă relativ la A . Atunci sunt satisfăcute condițiile:

- (i) $\lim_{n \rightarrow \infty} \mathbb{E}[g_n(X_1, X_2, \dots, X_n)] = A;$
- (ii) $\lim_{n \rightarrow \infty} V[g_n(X_1, X_2, \dots, X_n)] = 0.$

Fie $\varepsilon > 0$, arbitrar.

Din (i) rezultă că există $N \in \mathbb{N}^*$ astfel încât

$$|\mathbb{E}[g_n(X_1, X_2, \dots, X_n)] - A| < \frac{\varepsilon}{2}, \quad \forall n \geq N,$$

de unde

$$\varepsilon - |\mathbb{E}[g_n(X_1, X_2, \dots, X_n)] - A| > \frac{\varepsilon}{2}, \quad \forall n \geq N.$$

Considerăm în continuare $n \in \mathbb{N}^*$, $n \geq N$. Din inegalitatea

$$|g_n(X_1, \dots, X_n) - A| \leq |g_n(X_1, \dots, X_n) - \mathbb{E}[g_n(X_1, \dots, X_n)]| + |\mathbb{E}[g_n(X_1, \dots, X_n)] - A|,$$

obținem

$$\begin{aligned} & \{|g_n(X_1, \dots, X_n) - A| > \varepsilon\} \subset \\ & \subset \{|g_n(X_1, \dots, X_n) - \mathbb{E}[g_n(X_1, \dots, X_n)]| + |\mathbb{E}[g_n(X_1, \dots, X_n)] - A| > \varepsilon\} = \\ & = \{|g_n(X_1, \dots, X_n) - \mathbb{E}[g_n(X_1, \dots, X_n)]| > \varepsilon - |\mathbb{E}[g_n(X_1, \dots, X_n)] - A|\} \subset \\ & \subset \left\{ |g_n(X_1, \dots, X_n) - \mathbb{E}[g_n(X_1, \dots, X_n)]| > \frac{\varepsilon}{2} \right\}. \end{aligned}$$

Probabilitatea este o funcție monoton crescătoare, deci

$$\mathbb{P}^\infty \{|g_n(X_1, \dots, X_n) - A| > \varepsilon\} \leq \mathbb{P}^\infty \left\{ |g_n(X_1, \dots, X_n) - \mathbb{E}[g_n(X_1, \dots, X_n)]| > \frac{\varepsilon}{2} \right\}, \quad \forall n \geq N.$$

Conform inegalității lui Cebîșev, avem

$$\mathbb{P}^\infty \left\{ |g_n(X_1, \dots, X_n) - \mathbb{E}[g_n(X_1, \dots, X_n)]| > \frac{\varepsilon}{2} \right\} \leq \frac{V[g_n(X_1, X_2, \dots, X_n)]}{(\varepsilon/2)^2},$$

de unde

$$\mathbb{P}^\infty \{|g_n(X_1, \dots, X_n) - A| > \varepsilon\} \leq \frac{4V[g_n(X_1, X_2, \dots, X_n)]}{\varepsilon^2}, \quad \forall n \geq N.$$

Din condiția (ii) și criteriul majorării, obținem

$$\lim_{n \rightarrow \infty} \mathbb{P}^\infty \{|g_n(X_1, \dots, X_n) - A| > \varepsilon\} = 0.$$

Rezultă că statistica $(g_n(X_1, X_2, \dots, X_n))_{n \geq 1}$ este un estimator pentru A . \square

Observația 4.4.1. *O statistică fără abatere relativ la o caracteristică numerică a unei distribuții este de asemenea un estimator pentru acea caracteristică. În acest caz, estimatorul se va numi fără abatere.*

Definiția 4.4.2. *Pentru șirul de variabile aleatoare de selecție $(X_n)_{n \geq 1}$ definim:*

1. *media empirică (media de selecție) prin*

$$\bar{X}_n = \frac{1}{n}(X_1 + X_2 + \dots + X_n), \quad n \in \mathbb{N}^*.$$

2. *dispersia empirică (dispersia de selecție) prin*

$$\bar{V}_n = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2, \quad n \in \mathbb{N}^*.$$

3. *dispersia empirică modificată (dispersia de selecție modificată) prin*

$$\bar{S}_n = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2, \quad n \in \mathbb{N}^*, \quad n \geq 2.$$

Teorema 4.4.2. *Fie $X \in \mathcal{L}^2(\Omega)$. Statistica $(g_n(X_1, X_2, \dots, X_n))_{n \geq 1}$ definită prin*

$$g_n(X_1, X_2, \dots, X_n) = \bar{X}_n, \quad \forall n \in \mathbb{N}^*,$$

este fără abatere (absolut corectă/nedeplasată) relativ la $A = \mathbb{E}(X)$.

Demonstrație.

Trebuie să demonstrăm relațiile:

$$(i) \quad \mathbb{E}[g_n(X_1, X_2, \dots, X_n)] = A, \quad \forall n \in \mathbb{N}^*;$$

$$(ii) \quad \lim_{n \rightarrow \infty} V[g_n(X_1, X_2, \dots, X_n)] = 0.$$

Avem

$$\mathbb{E}[g_n(X_1, X_2, \dots, X_n)] = \mathbb{E}(\bar{X}_n) = \frac{1}{n} \mathbb{E} \left(\sum_{i=1}^n X_i \right) = \frac{\sum_{i=1}^n \mathbb{E}(X_i)}{n} = \frac{nA}{n} = A, \quad \forall n \in \mathbb{N}^*.$$

Apoi

$$V[g_n(X_1, X_2, \dots, X_n)] = V(\bar{X}_n) = \frac{1}{n^2} V \left(\sum_{i=1}^n X_i \right) \stackrel{\text{indep.}}{=} \frac{\sum_{i=1}^n V(X_i)}{n^2} = \frac{nV(X)}{n^2} = \frac{V(X)}{n} \xrightarrow{n \rightarrow \infty} 0.$$

Deci $(\bar{X}_n)_{n \geq 1}$ este o statistică fără abatere relativ la medie. \square

Prim urmare, media empirică este și un estimator fără abatere pentru medie, fapt demonstrat anterior pentru cazul particular al eșantioanelor Bernoulli.

Teorema 4.4.3. Fie $X \in \mathcal{L}^4(\Omega)$.

1. Statistica $(g_n(X_1, X_2, \dots, X_n))_{n \geq 1}$ definită prin

$$g_n(X_1, X_2, \dots, X_n) = \bar{V}_n, \quad \forall n \in \mathbb{N}^*,$$

este corectă relativ la $A = V(X)$.

2. Statistica $(g_n(X_1, X_2, \dots, X_n))_{n \geq 1}$ definită prin

$$g_n(X_1, X_2, \dots, X_n) = \bar{S}_n, \quad \forall n \in \mathbb{N}^*,$$

este absolut corectă (fără abatere) relativ la $A = V(X)$.

Demonstrație.

Demonstrăm la început relațiile

$$\lim_{n \rightarrow \infty} \mathbb{E}(\bar{V}_n) = V(X), \quad (4.1)$$

$$\mathbb{E}(\bar{S}_n) = V(X), \quad \forall n \in \mathbb{N}^*. \quad (4.2)$$

Avem

$$\mathbb{E}(\bar{V}_n) = \mathbb{E}\left[\frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{n}\right] = \frac{\sum_{i=1}^n \mathbb{E}[(X_i - \bar{X}_n)^2]}{n}. \quad (4.3)$$

Pentru $i \in \{1, 2, \dots, n\}$, obținem

$$\begin{aligned} \mathbb{E}[(X_i - \bar{X}_n)^2] &= \frac{1}{n^2} \mathbb{E}\left[\left(nX_i - \sum_{k=1}^n X_k\right)^2\right] = \frac{1}{n^2} \mathbb{E}\left[\left((n-1)X_i - \sum_{k \neq i} X_k\right)^2\right] = \\ &= \frac{\mathbb{E}\left[(n-1)^2 X_i^2 - 2(n-1) \sum_{k \neq i} X_i X_k + \sum_{k \neq i} X_k^2 + \sum_{k, j \neq i, k \neq j} X_k X_j\right]}{n^2} = \\ &= \frac{(n-1)^2 \mathbb{E}(X_i^2) - 2(n-1) \sum_{k \neq i} \mathbb{E}(X_i X_k) + \sum_{k \neq i} \mathbb{E}(X_k^2) + \sum_{k, j \neq i, k \neq j} \mathbb{E}(X_k X_j)}{n^2}. \end{aligned}$$

Datorită faptului că variabilele aleatoare X_1, X_2, \dots, X_n sunt independente, cu distribuția variabilei aleatoare X , rezultă

$$\mathbb{E}(X_i^2) = \mathbb{E}(X_k^2) = \mathbb{E}(X^2), \quad \mathbb{E}(X_i X_k) = \mathbb{E}(X_i) \mathbb{E}(X_k) = \mathbb{E}^2(X) \text{ și } \mathbb{E}(X_k X_j) = \mathbb{E}(X_k) \mathbb{E}(X_j) = \mathbb{E}^2(X).$$

Atunci

$$\begin{aligned} \mathbb{E}[(X_i - \bar{X}_n)^2] &= \frac{(n-1)^2 \mathbb{E}(X^2) - 2(n-1)^2 \mathbb{E}^2(X) + (n-1) \mathbb{E}(X^2) + (n-1)(n-2) \mathbb{E}^2(X)}{n^2} = \\ &= \frac{n(n-1) \mathbb{E}(X^2) - n(n-1) \mathbb{E}^2(X)}{n^2} = \frac{n-1}{n} V(X), \quad \forall i \in \{1, 2, \dots, n\}. \end{aligned}$$

Înlocuind în (4.3) obținem:

$$\mathbb{E}(\bar{V}_n) = \frac{n-1}{n} V(X) \xrightarrow{n \rightarrow \infty} V(X), \quad (4.4)$$

deci relația (4.1) este demonstrată. Relația (4.2) rezultă astfel:

$$\mathbb{E}(\bar{S}_n) = \mathbb{E}\left(\frac{n}{n-1}\bar{V}_n\right) = \frac{n}{n-1}\mathbb{E}(\bar{V}_n) \stackrel{(4)}{=} \frac{n}{n-1} \cdot \frac{n-1}{n} \cdot V(X) = V(X), \quad \forall n \in \mathbb{N}^*.$$

Demonstrăm acum relațiile

$$\lim_{n \rightarrow \infty} V(\bar{S}_n) = 0, \quad (4.5)$$

$$\lim_{n \rightarrow \infty} V(\bar{V}_n) = 0. \quad (4.6)$$

Pentru $n \geq 2$, avem

$$V(\bar{S}_n) = \mathbb{E}(\bar{S}_n^2) - \mathbb{E}^2(\bar{S}_n) \stackrel{(4.2)}{=} \mathbb{E}(\bar{S}_n^2) - V^2(X). \quad (4.7)$$

Explicităm \bar{S}_n și \bar{S}_n^2 . Avem:

$$\begin{aligned} \bar{S}_n &= \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{n-1} = \frac{\sum_{i=1}^n (X_i^2 - 2X_i\bar{X}_n + \bar{X}_n^2)}{n-1} = \\ &= \frac{\sum_{i=1}^n X_i^2 - 2n\bar{X}_n^2 + n\bar{X}_n^2}{n-1} = \frac{\sum_{i=1}^n X_i^2 - n\bar{X}_n^2}{n-1} \end{aligned}$$

și

$$\bar{S}_n^2 = \frac{(\sum_{i=1}^n X_i^2)^2 - 2n\bar{X}_n^2(\sum_{i=1}^n X_i^2) + n^2\bar{X}_n^4}{(n-1)^2}.$$

Avem:

$$\begin{aligned} \mathbb{E}\left[\left(\sum_{i=1}^n X_i^2\right)^2\right] &= \mathbb{E}\left[\sum_{i=1}^n X_i^4 + \sum_{i \neq j} X_i^2 X_j^2\right] = \\ &= \sum_{i=1}^n \mathbb{E}(X_i^4) + \sum_{i \neq j} \mathbb{E}(X_i^2 X_j^2) = n\mathbb{E}(X^4) + n(n-1)\mathbb{E}^2(X^2). \end{aligned}$$

Procedând analog pentru ceilalți termeni, obținem în final

$$\mathbb{E}(\bar{S}_n^2) = \frac{1}{n}\mathbb{E}(X^4) + \frac{n^2 - 2n + 3}{n(n-1)}V^2(X).$$

Înlocuind $\mathbb{E}(\bar{S}_n^2)$ în relația (4.7) găsim:

$$V(\bar{S}_n) = \frac{1}{n}\left[\mathbb{E}(X^4) - \frac{n-3}{n-1}V^2(X)\right] \xrightarrow{n \rightarrow \infty} 0.$$

În sfârșit,

$$V(\bar{V}_n) = V\left(\frac{n-1}{n}\bar{S}_n\right) = \frac{(n-1)^2}{n^2}V(\bar{S}_n) \xrightarrow{n \rightarrow \infty} 0,$$

ceea ce încheie demonstrația. \square

4.5 Intervale de încredere

Considerăm o caracteristică cantitativă a unei populații P , modelată prin variabila aleatoare X . Fie A un parametru (o caracteristică numerică) a variabilei aleatoare X .

Definiția 4.5.1. Presupunem că $g' = (g'_n(X_1, X_2, \dots, X_n))_{n \in \mathbb{N}}$ și $g'' = (g''_n(X_1, X_2, \dots, X_n))_{n \in \mathbb{N}}$ reprezintă două statistici pentru parametrul A , cu proprietatea

$$g'_n(x_1, \dots, x_n) < g''_n(x_1, \dots, x_n), \quad \forall x_1, \dots, x_n \in \mathbb{R}, \quad \forall n \in \mathbb{N}^*.$$

Spunem că $[g', g'']$ este un interval de încredere de nivel $\alpha \in (0, 1)$ pentru parametrul A dacă

$$\mathbb{P}\{g' \leq A \leq g''\} \geq \alpha.$$

Explicit,

$$\mathbb{P}\{g'_n(X_1, \dots, X_n) \leq A \leq g''_n(X_1, \dots, X_n)\} \geq \alpha, \quad \forall n \in \mathbb{N}^*.$$

Numărul $\varepsilon = 1 - \alpha \in (0, 1)$ se numește prag de încredere pentru intervalul $[g', g'']$.

Observația 4.5.1. De regulă, se consideră $0,9 < \alpha < 1$, deci $0 < \varepsilon < \frac{1}{10}$.

Definiția poate fi înțeleasă astfel. Pentru un număr natural arbitrar $n > 1$, considerăm N selecții (x_1, \dots, x_n) de volum n din populația P , privitoare la caracteristica măsurată X . Notăm K_N numărul de selecții pentru care $g'_n(x_1, \dots, x_n) \leq A \leq g''_n(x_1, \dots, x_n)$. Atunci $\frac{K_N}{N} > \alpha$, pentru N "mare".

Un interval de încredere pentru un parametru A poate fi construit pe modelul

$$[g_n(X_1, \dots, X_n) - a_n, g_n(X_1, \dots, X_n) + a_n],$$

unde $g = (g_n(X_1, \dots, X_n))_{n \in \mathbb{N}^*}$ este o statistică corectă relativ la A , iar $(a_n)_{n \in \mathbb{N}}$ este un șir pozitiv convergent la 0.

4.5.1 Exemplu: intervale de încredere pentru medie

Vom exemplifica noțiunea de interval de încredere. Presupunem că o caracteristică X a populației P are o distribuție normală de dispersie cunoscută σ^2 și medie necunoscută μ . Ne propunem să definim intervale de încredere pentru μ . Ne vom servi de următorul rezultat.

Propoziția 4.5.1. Dacă X_1, X_2, \dots, X_n sunt variabile aleatoare normale independente, de medie comună μ și dispersie comună σ^2 , atunci variabila aleatoare

$$\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n}$$

are o distribuție normală de medie μ și dispersie σ^2/n , iar variabila aleatoare $\bar{Z}_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}$ are o distribuție normală standard.

Demonstrație. Variabilele aleatoare X_k au funcția caracteristică comună

$$\varphi(t) = e^{i\mu t - \frac{t^2 \sigma^2}{2}}, \quad t \in \mathbb{R}.$$

Atunci variabila aleatoare \bar{X}_n are funcția caracteristică

$$\begin{aligned} \varphi_{\bar{X}_n}(t) &= \varphi_{(X_1 + \dots + X_n)/n}(t) = \varphi_{X_1 + \dots + X_n}(t/n) = \prod_{k=1}^n \varphi_{X_k}(t/n) = \varphi^n(t/n) = \\ &= \left(e^{i\mu \frac{t}{n} - \frac{t^2 \sigma^2}{2n^2}} \right)^n = e^{i\mu t - \frac{t^2 \sigma^2}{2n}}, \quad t \in \mathbb{R}. \end{aligned}$$

Din teorema de inversiune rezultă că variabila aleatoare \bar{X}_n are distribuția normală de medie μ și dispersie σ^2/n .

Apoi

$$\begin{aligned} \varphi_{\bar{Z}_n}(t) &= \mathbb{E} \left(e^{it \cdot \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}} \right) = e^{-\frac{it\mu\sqrt{n}}{\sigma}} \mathbb{E} \left(e^{i \left(\frac{t\sqrt{n}}{\sigma} \right) \bar{X}_n} \right) = e^{-\frac{it\mu\sqrt{n}}{\sigma}} \varphi_{\bar{X}_n} \left(\frac{t\sqrt{n}}{\sigma} \right) = \\ &= e^{-\frac{it\mu\sqrt{n}}{\sigma}} \cdot e^{i\mu \left(\frac{t\sqrt{n}}{\sigma} \right) - \frac{\left(\frac{t\sqrt{n}}{\sigma} \right)^2 \sigma^2}{2n}} = e^{-\frac{t^2}{2}}, \quad t \in \mathbb{R}. \end{aligned}$$

Din teorema de inversiune rezultă că variabila aleatoare \bar{Z}_n are distribuția normală standard. \square

Pentru variabilele aleatoare de selecție X_1, X_2, \dots, X_n , definim variabila aleatoare

$$\bar{Z}_n = \frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}.$$

Din Propoziția 4.5.1 deducem că $\bar{Z}_n \sim N(0, 1)$. Fie $\alpha \in (0, 1)$, fixat. Ne propunem să determinăm un interval de încredere de nivel α pentru parametrul necunoscut μ . Notăm

$$\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_0^x e^{-\frac{t^2}{2}} dt, \quad x > 0.$$

Determinăm (din tabele sau cu ajutorul unui soft statistic) *cuantila* $a > 0$ astfel ca

$$2\Phi(a) = \alpha.$$

Avem

$$\mathbb{P}\{|\bar{Z}_n| \leq a\} = \frac{1}{\sqrt{2\pi}} \int_{-a}^a e^{-\frac{t^2}{2}} dt = 2\Phi(a) = \alpha.$$

Pe de altă parte,

$$\begin{aligned} \{|\bar{Z}_n| \leq a\} &= \left\{ -a \leq \frac{\sqrt{n}(\bar{X}_n - \mu)}{\sigma} \leq a \right\} = \left\{ -\frac{a\sigma}{\sqrt{n}} \leq \bar{X}_n - \mu \leq \frac{a\sigma}{\sqrt{n}} \right\} = \\ &= \left\{ \bar{X}_n - \frac{a\sigma}{\sqrt{n}} \leq \mu \leq \bar{X}_n + \frac{a\sigma}{\sqrt{n}} \right\}. \end{aligned}$$

Prin urmare,

$$\mathbb{P} \left\{ \mu \in \left[\bar{X}_n - \frac{a\sigma}{\sqrt{n}}, \bar{X}_n + \frac{a\sigma}{\sqrt{n}} \right] \right\} = \alpha,$$

deci $\left[\bar{X}_n - \frac{a\sigma}{\sqrt{n}}, \bar{X}_n + \frac{a\sigma}{\sqrt{n}} \right]$ este un interval de încredere de nivel α pentru parametrul necunoscut μ .

4.6 Ipoteze statistice. Teste statistice

Pentru o populație P , analizăm statistic o caracteristică cantitativă (numerică) X .
Avem două alternative.

1. Presupunem, din anumite rațiuni, că variabila empirică X are distribuție (lege) teoretică cunoscută. Frecvent, considerăm că X are o distribuție Bernoulli, normală sau Poisson.
2. Nu avem argumente să încadrăm distribuția lui X într-o familie de distribuții teoretice cunoscute.

În primul caz, vom formula și analiza statistic "ipoteze" privind valoarea parametru-lui/parametrilor (necunoscuți) de care depinde distribuția teoretică a caracteristicii X . Pentru studiul statistic întreprins, ne vom servi de rezultatele privind estimarea parametru-lui/parametrilor de care depinde distribuția teoretică (presupusă) a caracteristicii X . De exemplu, estimăm media unei distribuții normale cu dispersie cunoscută.

4.6.1 Descrierea tipurilor de ipoteze statistice

O **ipoteză statistică** reprezintă o presupunere făcută asupra uneia sau mai multor "însușiri" ale populației P , adică asupra tipului de distribuție a caracteristicii X a populației. În cazul când presupunem aprioric ca X este guvernată de o lege teoretică cunoscută, vom face presupuneri asupra valorilor parametrilor de care depinde distribuția respectivă. Prezentăm și exemplificăm principalele tipuri de ipoteze statistice.

a) Ipoteza statistică se numește **simplă** dacă include întreaga informație care determină distribuția caracteristicii X .

Exemple.

1. Ipoteza statistică simplă H :
Caracteristica X urmează o lege Bernoulli, de parametru $p = 0,4$.
2. Ipoteza statistică simplă H :
Caracteristica X urmează o lege normală, de medie $\mu = 5$ și dispersie $\sigma^2 = 4$.

b) Ipoteza statistică se numește **compusă** dacă se referă doar la o parte din informațiile care determină distribuția caracteristicii X .

Exemple.

1. Ipoteza statistică compusă H :
Caracteristica X urmează o lege Poisson.
2. Ipoteza statistică compusă H :
Caracteristica X urmează o lege normală, de medie $\mu = 20$.

În cazul ipotezelor compuse, parametrii neprecizați, care împreună cu cei precizați în ipoteza statistică determină complet distribuția lui X , se estimează prin examinarea unui eșantion al populației, obținut în urma unui proces de selecție.

c) Ipoteza statistică se numește **exactă** dacă indică tipul distribuției teoretice a lui X și o valoare precisă a unuia sau mai multor parametri ai distribuției respective.

Exemplu.

Ipoteza statistică exactă H :

Caracteristica X urmează o lege Poisson de parametru $a = 2$.

d) Ipoteza statistică se numește **inexactă** dacă nu oferă valori precise.

Exemplu.

Ipoteza statistică inexactă H :

Caracteristica X are media $m \in [6, 8]$.

În statistică se operează simultan cu o pereche de ipoteze statistice alternative: ipoteza H_0 și ipoteza alternativă H_1 . Ipoteza alternativă H_1 nu reprezintă întotdeauna negația logică a ipotezei H_0 .

Exemplu.

Ipoteza H_0 : *media lui X este $m = 8,33$.*

Ipoteza H_1 : *media lui X este $m < 8,33$.*

Ipoteza H_0 ocupă locul central. Se testează **valabilitatea ipotezei H_0 împotriva valabilității ipotezei alternative H_1** , astfel încât, la finalul testării, să fie acceptată ipoteza H_0 , sau să fie respinsă ipoteza H_0 în favoarea ipotezei H_1 .

Noțiuni generale despre teste statistice

Testul statistic reprezintă operația de comparare a două ipoteze statistice alternative pe baza informațiilor furnizate de sondaj (selecție).

Un test statistic se numește:

1. **parametric**, dacă se presupune că X urmează o lege teoretică cunoscută, iar ipotezele statistice se referă la estimarea parametrilor legii (distribuției) respective;
2. **neparametric**, dacă ipotezele statistice se referă la estimarea distribuției variabilei empirice X sau a unor caracteristici numerice ale acesteia (medie, dispersie etc), în absența unei informații privind legea teoretică urmată de X .

Un test statistic presupune definirea unei **statistici de selecție**, adică a unui șir de variabile aleatoare $g_n(X_1, X_2, \dots, X_n)$, $n \in \mathbb{N}^*$, unde $g = (g_n)_{n \geq 1}$ este un șir de funcții reale, iar $X_1, X_2, \dots, X_n, \dots$ sunt variabilele de selecție, considerate independente și identic distribuite. Anumite valori ale statisticii conduc la acceptarea ipotezei H_0 , iar alte valori ale statisticii conduc la respingerea acestei ipoteze. Vom vorbi deci despre un **domeniu de respingere** (de neacceptare). Regula de decizie este dictată de specificarea domeniului de respingere al ipotezei H_0 . Domeniul complementar domeniului de respingere reprezintă **domeniul de acceptare pentru ipoteza H_0** .

Ipoteza H_0 , numită **ipoteza nulă**, se consideră **acceptabilă** dacă, în urma unei selecții concrete $X_1 = x_1, X_2 = x_2, \dots, X_n = x_n$, valoarea numerică rezultată $g_n(x_1, x_2, \dots, x_n)$ a statisticii g aparține domeniului de acceptare. Domeniul de acceptare este o mulțime

$A \subset \mathbb{R}$ stabilită teoretic prin luarea în considerare a ipotezei nule H_0 . Astfel, dacă presupunem că ipoteza nulă H_0 (considerată ipoteză simplă) este valabilă, atunci distribuția variabilei aleatoare $g_n(X_1, X_2, \dots, X_n)$, unde X_1, X_2, \dots, X_n devin variabile aleatoare i.i.d., cu distribuția comună cunoscută, este complet determinată.

Fie o constantă $\varepsilon \in (0, 1)$ care va fi denumită în continuare **prag de semnificație** pentru statistica g . **Domeniul de acceptare de prag ε** este mulțimea $A_\varepsilon \subset \mathbb{R}$ definită prin condiția:

$$\mathbb{P}\{g_n(X_1, X_2, \dots, X_n) \in \mathbb{R} \setminus A_\varepsilon\} = \varepsilon,$$

sau, echivalent,

$$\mathbb{P}\{g_n(X_1, X_2, \dots, X_n) \in A_\varepsilon\} = 1 - \varepsilon.$$

Mulțimea A_ε se interpretează ca o "zonă de o mare probabilitate teoretică". Domeniul de acceptare A_ε depinde de distribuția variabilelor X_i (presupusă cunoscută), statistica g (definită), precum și de parametrul ε (pragul de semnificație).

Etapele studiului.

1. Definirea ipotezei nule H_0 și a ipotezei alternative H_1 .
2. Definirea statisticii $g_n(X_1, \dots, X_n)$ de estimare a unui parametru al distribuției comune a variabilelor aleatoare X_i .
3. Determinarea distribuției variabilei aleatoare $g_n(X_1, \dots, X_n)$. Dacă variabila aleatoare $g_n(X_1, \dots, X_n)$ este de tip continuu, se determină funcția sa de densitate. Astfel, în ipoteza simplă H_0 , statistica g este astfel o variabilă aleatoare cu distribuție unic determinată.
4. Stabilirea pragului de semnificație ε pentru variabila aleatoare $g_n(X_1, \dots, X_n)$.
5. Determinarea domeniului de acceptare A_ε și a domeniului de respingere $\mathbb{R} \setminus A_\varepsilon$ a ipotezei nule H_0 . Adeseori aceste domenii se reprezintă grafic.
6. Calculul valorii numerice $g_n(x_1, x_2, \dots, x_n)$ a statisticii g pentru o selecție efectivă. Validarea ipotezei H_0 (cu pragul de semnificație ε) are loc dacă

$$g_n(x_1, x_2, \dots, x_n) \in A_\varepsilon,$$

respectiv validarea ipotezei alternative H_1 are loc dacă

$$g_n(x_1, x_2, \dots, x_n) \in \mathbb{R} \setminus A_\varepsilon.$$

Prezentăm detaliat și exemplificăm două teste statistice importante: testul Z (parametric) și testul χ^2 (neparametric).

4.6.2 Testul Z

Testul Z este un test parametric care se referă la estimarea mediei unei caracteristici X a unei populații P . Se presupune că X are o distribuție normală, cu dispersia σ^2 cunoscută.

Presupunem aprioric că o caracteristică X a populației P are o distribuție normală, de medie μ (necunoscută) și dispersie σ^2 (cunoscută). Considerăm variabilele aleatoare de selecție X_1, X_2, \dots, X_n . Notăm $\bar{X}_n = \frac{X_1 + X_2 + \dots + X_n}{n}$.

1. Ne propunem să testăm ipoteza $H_0: \mu = \mu_0$, unde numărul μ_0 este specificat. Definim ipoteza alternativă $H_1: \mu \neq \mu_0$
2. Considerăm statistica $Z = (Z_n)_{n \geq 1}$ definită prin

$$Z_n = g_n(X_1, \dots, X_n) = \frac{\sqrt{n}(\bar{X}_n - \mu_0)}{\sigma}, \quad n \in \mathbb{N}^*.$$

Conform Propoziției 4.5.1, Z_n este o variabilă aleatoare normală standard.

3. Stabilim pragul de semnificație ε , unde $0 < \varepsilon < 0, 1$.
4. Determinăm domeniul de acceptare A_ε , astfel încât

$$\mathbb{P}\{Z_n \in A_\varepsilon\} = \mathbb{P}\{g_n(X_1, X_2, \dots, X_n) \in A_\varepsilon\} = 1 - \varepsilon.$$

Astfel, notăm $\Phi(x) = \frac{1}{\sqrt{2\pi}} \int_0^x e^{-t^2/2} dt$, $x \in \mathbb{R}$.

Stabilim (din tabelul valorilor funcției Φ) **cuantila** $a_\varepsilon > 0$ astfel ca $\Phi(a_\varepsilon) = \frac{1 - \varepsilon}{2}$. Atunci domeniul de acceptare este $A_\varepsilon = [-a_\varepsilon, a_\varepsilon]$, deoarece

$$\mathbb{P}\{Z \in A_\varepsilon\} = \frac{1}{\sqrt{2\pi}} \int_{-a_\varepsilon}^{a_\varepsilon} e^{-t^2/2} dt = 2\Phi(a_\varepsilon) = 2 \cdot \frac{1 - \varepsilon}{2} = 1 - \varepsilon.$$

Cuantila a_ε poate fi obținută utilizând un soft de statistică (de ex. *Scilab*) din condiția

$$\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{a_\varepsilon} e^{-t^2/2} dt = 1 - \frac{\varepsilon}{2}.$$

5. Calculăm valoarea numerică $Z_n(\bar{x}) = \frac{\sqrt{n}(\bar{x} - \mu_0)}{\sigma}$ pentru selecția (experimentală) x_1, \dots, x_n , cu $\bar{x} = \frac{x_1 + \dots + x_n}{n}$. Decidem că ipoteza H_0 este acceptată, cu pragul de semnificație ε , dacă $Z_n(\bar{x}) \in A_\varepsilon$, respectiv respinsă în favoarea ipotezei H_1 dacă $Z_n(\bar{x}) \in \mathbb{R} \setminus A_\varepsilon$.

Exemplu.

Fie populația P alcătuită din studenții unui an care au transmis rezolvările la un test. Volumul populației P este $N = 144$. Fie X caracteristica numerică: nota obținută la test.

Presupunem aprioric că X are o distribuție normală, de medie μ (necunoscută) și dispersie $\sigma^2 = 2.1833014$ (cunoscută).

Valoarea atribuită dispersiei a fost obținută prin calculul dispersiei empirice a caracteristicii X pentru întreaga populație P :

$$\sigma^2(X) = \frac{1}{N} \sum_{i=1}^N \left(x_i - \frac{\sum_{j=1}^N x_j}{N} \right)^2 = 2,1833014,$$

pentru setul de date reprezentând notele obținute la test, prezentat mai jos:

Catalog note=

7.75, 6, 6.75, 7, 7.5, 4.25, 5.75, 3, 7.75, 8, 9, 8.75, 3.25, 7.25, 7.5, 6.75, 8.25, 3.5, 5.5, 4.5, 7.5, 4, 5.75, 7.5, 7.75, 5.75, 6.5, 6.75, 8.5, 7.75, 8.25, 7.5, 7.25, 5.25, 6.5, 8, 8, 4, 7.5, 6.75, 8.5, 6.75, 7.75, 7.5, 3.5, 5.5, 6.75, 4.75, 7, 7.75, 6, 7.25, 5.75, 5, 5.75, 9, 7.25, 5.5, 5.25, 5.5, 4.5, 4.75, 8, 8.5, 4.25, 6.75, 5, 3, 6.25, 6.75, 4, 7.25, 6.25, 6.75, 8.5, 8, 8.5, 6, 6.25, 7.75, 6, 4.5, 9, 7, 8.75, 5.5, 6, 4.75, 4.75, 5.5, 6.75, 6, 8.25, 6.5, 6.75, 5.5, 7.25, 6.75, 5.5, 8, 8.75, 8.5, 7, 5.5, 5.25, 5.5, 8.5, 6.25, 8.25, 8, 7, 5.75, 7, 7.25, 6, 4, 5.5, 7, 5, 7.75, 4, 5, 7, 6.75, 8, 8.75, 8.25, 8.75, 7.75, 6, 4.75, 5.75, 7, 6.25, 6, 8.75, 3.5, 7.75, 5.25, 5.75, 8.25, 7.75, 5.5, 8.75.

Astfel, avem $\sigma = \sqrt{2.1833014} = 1.4775999$.

1. Utilizând **testul Z**, ne propunem să testăm ipoteza $H_0: \mu = 6.55$.

Definim ipoteza alternativă $H_1: \mu \neq 6.55$

2. Considerăm statistica $Z = (Z_n)_{n \geq 1}$ definită prin

$$Z_n = g_n(X_1, \dots, X_n) = \frac{\sqrt{n}(\bar{X}_n - 6.55)}{1.4775999} \sim N(0, 1).$$

3. Stabilim pragul de semnificație $\varepsilon = 0.02$.

4. Determinăm domeniul de acceptare A_ε , astfel încât

$$\mathbb{P}\{Z_n \in A_\varepsilon\} = \mathbb{P}\{g_n(X_1, X_2, \dots, X_n) \in A_\varepsilon\} = 1 - \varepsilon.$$

Utilizând softul Scilab, determinăm cuantila a_ε din condiția

$$\frac{1}{\sqrt{2\pi}} \int_{-\infty}^{a_\varepsilon} e^{-t^2/2} dt = 1 - \frac{\varepsilon}{2} = 0.99.$$

Găsim $a_\varepsilon = 2.3263479$. Ca urmare, domeniul de acceptare al ipotezei nule este:

$$A_\varepsilon = [-2.3263479, 2.3263479].$$

5. Fie selecția de volum $n = 31$ formată din primele 31 de note din catalog.

Calculăm valoarea numerică $Z_{31}(\bar{x}) = \frac{\sqrt{31}(\bar{x} - 6.55)}{1.4775999}$ pentru selecția x_1, \dots, x_{31} ,


având media empirică $\bar{x} = \frac{x_1 + \dots + x_{31}}{31} = 6.5806452$. Obținem

$$Z_{31}(\bar{x}) = 0.1154745 \in A_\varepsilon.$$

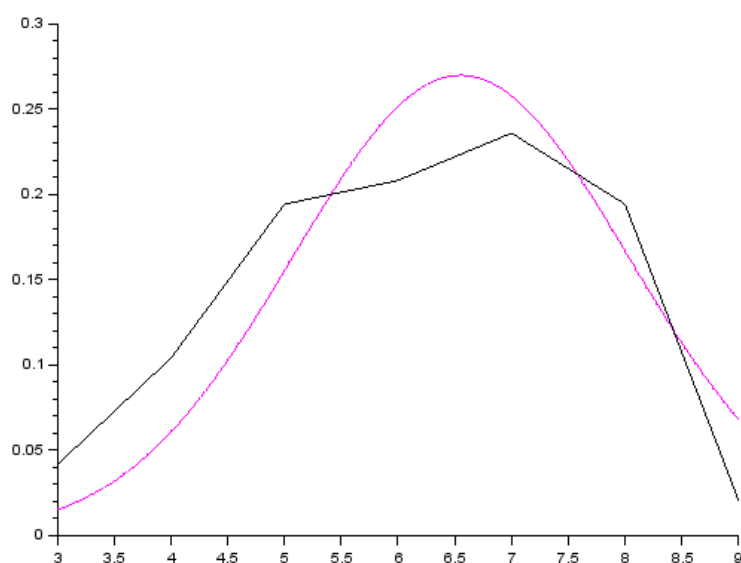
Decidem că ipoteza H_0 este acceptată, cu pragul de semnificație $\varepsilon = 0.02$.

Ilustrări grafice.

1. Aproximarea normală $N(6.55, 2, 1833014)$ a frecvenței relative a notelor selecției.



2. Aproximarea normală $N(6.5538194, 2, 1833014)$ a frecvenței relative a notelor populației.



4.6.3 Testul χ^2

Presupunem că o caracteristică X a unei populații P ia valori în mulțimea $\{v_1, v_2, \dots, v_k\}$.

Testul χ^2 a lui Pearson este un test neparametric care validează sau invalidează ipoteza nulă H_0 :

$$\text{caracteristica } X \text{ are distribuția } X : \begin{pmatrix} v_1 & v_2 & \cdots & v_k \\ p_1 & p_2 & \cdots & p_k \end{pmatrix},$$

unde $p_j = \mathbb{P}\{X = v_j\} > 0$, $j = 1, 2, \dots, k$, cu $\sum_{j=1}^k p_j = 1$.

Rezultate teoretice

O variabilă aleatoare Z are distribuția χ^2 cu k grade de libertate, unde $k \in \mathbb{N}^*$, dacă este pozitivă și admite funcția de densitate:

$$f_Z(x) = \frac{1}{2^{\frac{k}{2}} \Gamma\left(\frac{k}{2}\right)} x^{\frac{k}{2}-1} e^{-\frac{x}{2}}, \quad x > 0.$$

Astfel, Z are o distribuție de tip Γ de parametri $n = \frac{k}{2}$ și $a = \frac{1}{2}$, notat prin $Z \in \Gamma\left(\frac{k}{2}, \frac{1}{2}\right)$.

Testul χ^2 se bazează pe următoarele rezultate teoretice.

Teorema 4.6.1. *Dacă Y_1, Y_2, \dots, Y_k sunt k variabile aleatoare independente, cu distribuție normală standard (deci $Y_i \sim N(0, 1)$, $i = 1, 2, \dots, k$), atunci variabila aleatoare*

$$Z = \sum_{i=1}^k Y_i^2$$

are o distribuție χ^2 cu k grade de libertate.

Demonstrație. Fie $Y \sim N(0, 1)$ a variabilă aleatoare normală standard. Determinăm funcția de densitate f a variabilei aleatoare Y^2 . Variabila aleatoare Y^2 este pozitivă și are funcția de repartiție:

$$F(t) = \mathbb{P}\{Y^2 \leq t\} = \mathbb{P}\{-\sqrt{t} \leq Y \leq \sqrt{t}\} = \frac{1}{\sqrt{2\pi}} \int_{-\sqrt{t}}^{\sqrt{t}} e^{-\frac{x^2}{2}} dx = \sqrt{\frac{2}{\pi}} \int_0^{\sqrt{t}} e^{-\frac{x^2}{2}} dx, \quad \forall t \geq 0.$$

Atunci

$$f(t) = F'(t) = \sqrt{\frac{2}{\pi}} e^{-\frac{(\sqrt{t})^2}{2}} (\sqrt{t})' = \frac{1}{\sqrt{2\pi t}} e^{-\frac{t}{2}} = \frac{1}{2^{\frac{1}{2}} \Gamma\left(\frac{1}{2}\right)} t^{\frac{1}{2}-1} e^{-\frac{t}{2}}, \quad \forall t > 0.$$

Rezultă $Y^2 \in \Gamma\left(\frac{1}{2}, \frac{1}{2}\right)$, deci Y^2 are o distribuție χ^2 cu 1 grad de libertate.

Conform Propoziției 2.4.1, dacă variabilele aleatoare U și V sunt independente, având funcțiile de repartiție F și respectiv G , atunci funcția de repartiție a variabilei aleatoare $U + V$, notată $F * G$ și denumită convoluția funcțiilor de repartiție F și G , este dată de:

$$(F * G)(t) = \int_{-\infty}^{\infty} F(t-x) dG(x) = \int_{-\infty}^{\infty} G(t-x) dF(x) = (G * F)(t), \quad \forall t \in \mathbb{R}.$$

Dacă U și V sunt variabile aleatoare de tip continuu, cu funcțiile de densitate $f = F'$ și $g = G'$, atunci variabila aleatoare $U + V$ are funcția de densitate $f * g = (F * G)'$, obținută astfel:

$$(f * g)(t) = \frac{d}{dt} \int_{-\infty}^{\infty} F(t-x) dG(x) = \int_{-\infty}^{\infty} \frac{\partial}{\partial t} [F(t-x) g(x)] dx = \int_{-\infty}^{\infty} f(t-x) g(x) dx.$$

În particular, dacă U și V sunt variabile aleatoare pozitive, atunci $U + V$ este de asemenea o variabilă aleatoare pozitivă. Pentru oricare $t > 0$, din condiția $f(x) = g(x) = 0, \forall x < 0$, obținem

$$(f * g)(t) = \int_{-\infty}^0 f(t-x)g(x) dx + \int_0^t f(t-x)g(x) dx + \int_t^{\infty} f(t-x)g(x) dx = \int_0^t f(t-x)g(x) dx.$$

Fie $(Y_k)_{k \geq 1}$ un șir de variabile aleatoare normale standard, independente. Demonstrăm prin inducție după $k \in \mathbb{N}^*$ că $\sum_{i=1}^k Y_i^2 \in \Gamma\left(\frac{k}{2}, \frac{1}{2}\right)$. Proprietatea a fost demonstrată pentru

$k = 1$. Presupunem că, pentru un număr natural nenul k avem $\sum_{i=1}^k Y_i^2 \in \Gamma\left(\frac{k}{2}, \frac{1}{2}\right)$. Notăm

f_k funcția de densitate a variabilei aleatoare $\sum_{i=1}^k Y_i^2$. Variabila aleatoare Y_{k+1}^2 are funcția de densitate f , descrisă anterior. Atunci, datorită independenței variabilelor aleatoare pozitive $\sum_{i=1}^k Y_i^2$ și Y_{k+1}^2 , variabila aleatoare $\sum_{i=1}^{k+1} Y_i^2$ are funcția de densitate $f_{k+1} = f * f_k$. Avem

$$\begin{aligned} f_{k+1}(t) &= (f * f_k)(t) = \int_0^t f(t-x)f_k(x) dx = \int_0^t \left[\frac{1}{\sqrt{2\pi(t-x)}} e^{-\frac{t-x}{2}} \right] \cdot \left[\frac{1}{2^{\frac{k}{2}} \Gamma\left(\frac{k}{2}\right)} x^{\frac{k}{2}-1} e^{-\frac{x}{2}} \right] dx = \\ &= \frac{e^{-\frac{t}{2}}}{2^{\frac{k+1}{2}} \Gamma\left(\frac{k}{2}\right) \sqrt{\pi}} \int_0^t x^{\frac{k}{2}-1} (t-x)^{\frac{1}{2}-1} dx \stackrel{x=ty}{=} \frac{e^{-\frac{t}{2}}}{2^{\frac{k+1}{2}} \Gamma\left(\frac{k}{2}\right) \sqrt{\pi}} \int_0^1 t^{\frac{k+1}{2}-1} y^{\frac{k}{2}-1} (1-y)^{\frac{1}{2}-1} dy = \\ &= \frac{t^{\frac{k+1}{2}-1} e^{-\frac{t}{2}}}{2^{\frac{k+1}{2}} \Gamma\left(\frac{k}{2}\right) \sqrt{\pi}} \beta\left(\frac{k}{2}, \frac{1}{2}\right) = \frac{t^{\frac{k+1}{2}-1} e^{-\frac{t}{2}}}{2^{\frac{k+1}{2}} \Gamma\left(\frac{k}{2}\right) \sqrt{\pi}} \frac{\Gamma\left(\frac{k}{2}\right) \Gamma\left(\frac{1}{2}\right)}{\Gamma\left(\frac{k+1}{2}\right)} = \frac{t^{\frac{k+1}{2}-1} e^{-\frac{t}{2}}}{2^{\frac{k+1}{2}} \Gamma\left(\frac{k+1}{2}\right)}, \forall t > 0. \end{aligned}$$

Rezultă că $\sum_{i=1}^{k+1} Y_i^2$ are distribuția χ^2 cu $k+1$ grade de libertate, adică $\sum_{i=1}^{k+1} Y_i^2 \in \Gamma\left(\frac{k+1}{2}, \frac{1}{2}\right)$.

Astfel, teorema este demonstrată. \square

Definiția 4.6.1. Matricea de covarianță asociată unui vector aleator $\mathbf{X} = (X_1, X_2, \dots, X_k)$ se definește prin

$$\Sigma = (\lambda_{i,j})_{i,j=1,\dots,k} = \begin{pmatrix} \lambda_{1,1} & \lambda_{1,2} & \cdots & \lambda_{1,k} \\ \lambda_{2,1} & \lambda_{2,2} & \cdots & \lambda_{2,k} \\ \dots & \dots & \dots & \dots \\ \lambda_{k,1} & \lambda_{k,1} & \cdots & \lambda_{k,k} \end{pmatrix} \in \mathcal{M}_k(\mathbb{R}),$$

unde $\lambda_{i,j} = \lambda(X_i, X_j) = \mathbb{E}(X_i X_j) - \mathbb{E}(X_i) \mathbb{E}(X_j)$ este corelația variabilelor aleatoare X_i și X_j , pentru $i, j \in \{1, 2, \dots, k\}$.

Matricea de covarianță asociată vectorului aleator $\mathbf{X} = (X_1, \dots, X_k)$ este simetrică și semipozitiv definită, adică toți minorii săi principali sunt pozitivi. Pe diagonala principală se află dispersiile componentelor vectorului X :

$$\lambda_{i,i} = \lambda(X_i, X_i) = \mathbb{E}(X_i^2) - \mathbb{E}^2(X_i) = V(X_i), \quad i = 1, 2, \dots, k.$$

Definiția 4.6.2. Un vector aleator $\mathbf{Z} = (Z_1, Z_2, \dots, Z_k)$, cu media $\boldsymbol{\mu} = (\mu_1, \mu_2, \dots, \mu_k)$, unde $\mu_i = \mathbb{E}(Z_i)$, având matricea de covarianță Σ pozitiv definită, adică toți minorii săi principali sunt strict pozitivi, are o distribuție multivariată normală dacă admite funcția de densitate

$$f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^k \det(\Sigma)}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})\Sigma^{-1}(\mathbf{x}-\boldsymbol{\mu})^T}, \quad \forall \mathbf{x} = (x_1, x_2, \dots, x_k) \in \mathbb{R}^k.$$

Notăm $\mathbf{Z} \sim N_k(\boldsymbol{\mu}, \Sigma)$.

În particular, dacă $\Sigma = I_k$ (matricea unitate de ordinul k) și $\boldsymbol{\mu} = \mathbf{0}$, atunci

$$f(\mathbf{x}) = \frac{1}{\sqrt{(2\pi)^k}} e^{-\frac{1}{2}\mathbf{x}\mathbf{x}^T} = \frac{1}{\sqrt{(2\pi)^k}} e^{-\frac{1}{2}\sum_{i=1}^k x_i^2} = \prod_{i=1}^k \left(\frac{1}{\sqrt{2\pi}} e^{-\frac{x_i^2}{2}} \right), \quad \forall \mathbf{x} = (x_1, \dots, x_k) \in \mathbb{R}^k.$$

Notăm $\mathbf{Z} \sim N_k(\mathbf{0}, I_k)$ și spunem ca vectorul aleator \mathbf{Z} are o distribuție multivariată normală standard.

Dacă $\Sigma^* = (a_{i,j})_{i,j=1,\overline{k}}$ este adjuncta matricei de corelație Σ , atunci avem

$$\begin{aligned} (\mathbf{x} - \boldsymbol{\mu})\Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})^T &= \frac{1}{\det(\Sigma)} (\mathbf{x} - \boldsymbol{\mu})\Sigma^*(\mathbf{x} - \boldsymbol{\mu})^T = \\ &= \frac{1}{\det(\Sigma)} \left[\sum_{i=1}^k a_{i,i}(x_i - \mu_i)^2 + 2 \sum_{1 \leq i < j \leq k} a_{i,j}(x_i - \mu_i)(x_j - \mu_j) \right]. \end{aligned}$$

Dacă $\Sigma = I_k$, atunci variabilele aleatoare Z_1, Z_2, \dots, Z_k sunt necorelate și au o distribuție normală standard.

Teorema 4.6.2 (Teorema limită centrală multidimensională). Fie $(\mathbf{X}_n)_{n \geq 1}$ un șir de vectori aleatori $\mathbf{X}_n = (X_{n,1}, X_{n,2}, \dots, X_{n,k})$ de dimensiune k , independenți și identic distribuiți, cu media comună $\boldsymbol{\mu} = (\mu_1, \mu_2, \dots, \mu_k)$ și matricea de covarianță comună Σ . Presupunem că Σ este pozitiv definită și considerăm matricea simetrică $\sqrt{\Sigma^{-1}} \in \mathcal{M}_k(\mathbb{R})$ cu proprietățile $\det(\sqrt{\Sigma^{-1}}) > 0$ și $(\sqrt{\Sigma^{-1}})^2 = \Sigma^{-1}$. Fie $\bar{\mathbf{X}}_n = \frac{1}{n} \sum_{i=1}^n \mathbf{X}_i$, $n \in \mathbb{N}^*$. Atunci

$$\sqrt{n}(\bar{\mathbf{X}}_n - \boldsymbol{\mu})\sqrt{\Sigma^{-1}} \xrightarrow{d} \mathbf{Z},$$

unde $\mathbf{Z} \sim N_k(\mathbf{0}, I_k)$ este un vector aleator cu o distribuție multivariată normală standard.

Teorema 4.6.3 (Formula Sherman-Morrison). Fie $k \in \mathbb{N}$, $k \geq 2$, $A \in \mathcal{M}_k(\mathbb{R})$ o matrice invertibilă, iar $u, v \in \mathcal{M}_{1,k}$ două matrice linie. Atunci matricea $B = A - u^T v$ din $\mathcal{M}_k(\mathbb{R})$ este invertibilă dacă și numai dacă $vA^{-1}u^T \neq 1$. În caz afirmativ,

$$B^{-1} = A^{-1} + \frac{1}{1 - vA^{-1}u^T} A^{-1}u^T v A^{-1}.$$

Demonstrație. Avem

$$(A - u^T v) \left(A^{-1} + \frac{1}{1 - vA^{-1}u^T} A^{-1}u^T v A^{-1} \right) =$$

$$\begin{aligned}
&= I_k - u^T v A^{-1} + \frac{1}{1 - v A^{-1} u^T} (u^T v A^{-1}) - \frac{1}{1 - v A^{-1} u^T} (u^T v A^{-1} u^T v A^{-1}) = \\
&= I_k + \frac{1}{1 - v A^{-1} u^T} [-u^T v A^{-1} + (v A^{-1} u^T) u^T v A^{-1} + u^T v A^{-1} - u^T (v A^{-1} u^T) v A^{-1}] = \\
&= I_k + \frac{v A^{-1} u^T}{1 - v A^{-1} u^T} (u^T v A^{-1} - u^T v A^{-1}) = I_k. \quad \square
\end{aligned}$$

Teorema 4.6.4 (Baza teoretică al testului χ^2). Fie $\mathbf{X} = (X_1, X_2, \dots, X_k)$ un vector aleator care ia valorile $\underbrace{(1, 0, 0, \dots, 0)}_k, \underbrace{(0, 1, 0, \dots, 0)}_k, \dots, \underbrace{(0, 0, 0, \dots, 1)}_k$ cu probabilitățile

strict pozitive p_1, p_2, \dots, p_k , astfel ca $\sum_{i=1}^k p_i = 1$. Prin urmare, variabila aleatoare X_i ia

valori în mulțimea $\{0, 1\}$, pentru $i = 1, 2, \dots, k$, astfel ca $\sum_{i=1}^k X_i = 1$. Avem

$$\mathbb{P}\{X_i = 1\} = \mathbb{P}\left\{\mathbf{X} = \underbrace{(0, \dots, \overset{i}{1}, \dots, 0)}_k\right\} = p_i > 0, \quad i = 1, 2, \dots, k.$$

Considerăm un șir $(\mathbf{X}_n)_{n \geq 1}$ de vectori aleatori, independenți și identic distribuiți, având distribuția lui \mathbf{X} . Fie $\mathbf{X}_n = (X_{n,1}, X_{n,2}, \dots, X_{n,k})$, $n \in \mathbb{N}^*$. Notăm

$$S_{n,i} = \sum_{m=1}^n X_{m,i}, \quad i = 1, 2, \dots, k, \quad n \in \mathbb{N}^*.$$

Definim șirul de variabile aleatoare

$$\Phi_n = \frac{(S_{n,1} - np_1)^2}{np_1} + \frac{(S_{n,2} - np_2)^2}{np_2} + \dots + \frac{(S_{n,k} - np_k)^2}{np_k}, \quad n \in \mathbb{N}^*.$$

Atunci are loc convergența în distribuție $\Phi_n \xrightarrow{d} Z$, unde Z este o variabilă aleatoare cu distribuția χ^2 cu $k - 1$ grade de libertate.

Demonstrație. Determinăm matricea de covarianță $\Sigma \in \mathcal{M}_k(\mathbb{R})$ a vectorului aleator $\mathbf{X} = (X_1, X_2, \dots, X_k)$. Variabilele X_i au o distribuție Bernoulli. Astfel

$$X_i : \begin{pmatrix} 0 & 1 \\ 1 - p_i & p_i \end{pmatrix}, \quad i = 1, \dots, k.$$

Atunci $V(X_i) = \mathbb{E}(X_i^2) - \mathbb{E}^2(X_i) = p_i - p_i^2$, $i = 1, \dots, k$. Corelația variabilelor X_i și X_j , unde $i \neq j$, este $\lambda(X_i, X_j) = \mathbb{E}(X_i X_j) - \mathbb{E}(X_i)\mathbb{E}(X_j) = -p_i p_j$, deoarece $X_i X_j = 0$. Rezultă

$$\Sigma = \begin{pmatrix} p_1 - p_1^2 & -p_1 p_2 & \cdots & -p_1 p_k \\ -p_2 p_1 & p_2 - p_2^2 & \cdots & -p_2 p_k \\ \cdots & \cdots & \cdots & \cdots \\ -p_k p_1 & -p_k p_2 & \cdots & p_k - p_k^2 \end{pmatrix}.$$

Considerăm matricea $\Sigma^{(1)}$ formată din primele $k - 1$ linii și coloane ale matricei Σ :

$$\Sigma^{(1)} = \begin{pmatrix} p_1 - p_1^2 & -p_1 p_2 & \cdots & -p_1 p_{k-1} \\ -p_2 p_1 & p_2 - p_2^2 & \cdots & -p_2 p_{k-1} \\ \cdots & \cdots & \cdots & \cdots \\ -p_{k-1} p_1 & -p_{k-1} p_2 & \cdots & p_{k-1} - p_{k-1}^2 \end{pmatrix}.$$

$\Sigma^{(1)}$ reprezintă matricea de covarianță a vectorului aleator $\mathbf{X}^{(1)} = (X_1, X_2, \dots, X_{k-1})$, cu media $\mathbf{p}^{(1)} = (p_1, p_2, \dots, p_{k-1})$. Matricea $\Sigma^{(1)} \in \mathcal{M}_{k-1}(\mathbb{R})$ se poate rescrie

$$\Sigma^{(1)} = \begin{pmatrix} p_1 & 0 & \cdots & 0 \\ 0 & p_2 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & \cdots & p_{k-1} \end{pmatrix} - \begin{pmatrix} p_1 \\ p_2 \\ \cdots \\ p_{k-1} \end{pmatrix} \begin{pmatrix} p_1 & p_2 & \cdots & p_{k-1} \end{pmatrix}.$$

Fie $A = \begin{pmatrix} p_1 & 0 & \cdots & 0 \\ 0 & p_2 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & \cdots & p_{k-1} \end{pmatrix}$ și $u = \begin{pmatrix} p_1 & p_2 & \cdots & p_{k-1} \end{pmatrix}$. Astfel, $\Sigma^{(1)} = A - u^T u$.

Matricea A este invertibilă, cu inversa $A^{-1} = \begin{pmatrix} 1/p_1 & 0 & \cdots & 0 \\ 0 & 1/p_2 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & \cdots & 1/p_{k-1} \end{pmatrix}$. Avem

$$\begin{aligned} u A^{-1} u^T &= \begin{pmatrix} p_1 & p_2 & \cdots & p_{k-1} \end{pmatrix} \begin{pmatrix} 1/p_1 & 0 & \cdots & 0 \\ 0 & 1/p_2 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & \cdots & 1/p_{k-1} \end{pmatrix} \begin{pmatrix} p_1 \\ p_2 \\ \cdots \\ p_{k-1} \end{pmatrix} = \\ &= \begin{pmatrix} 1 & 1 & \cdots & 1 \end{pmatrix} \begin{pmatrix} p_1 \\ p_2 \\ \cdots \\ p_{k-1} \end{pmatrix} = \sum_{i=1}^{k-1} p_i = 1 - p_k \neq 1. \end{aligned}$$

Atunci, pe baza Teoremei Sherman-Morrison, matricea $\Sigma^{(1)}$ este invertibilă (și pozitiv definită), cu inversa

$$\begin{aligned} (\Sigma^{(1)})^{-1} &= A^{-1} + \frac{1}{1 - u A^{-1} u^T} A^{-1} u^T u A^{-1} = A^{-1} + \frac{1}{1 - u A^{-1} u^T} (A^{-1} u^T) (u A^{-1}) = \\ &= \begin{pmatrix} 1/p_1 & 0 & \cdots & 0 \\ 0 & 1/p_2 & \cdots & 0 \\ \cdots & \cdots & \cdots & \cdots \\ 0 & 0 & \cdots & 1/p_{k-1} \end{pmatrix} + \frac{1}{p_k} \begin{pmatrix} 1 \\ 1 \\ \cdots \\ 1 \end{pmatrix} \begin{pmatrix} 1 & 1 & \cdots & 1 \end{pmatrix} = \\ &= \begin{pmatrix} 1/p_1 + 1/p_k & 1/p_k & \cdots & 1/p_k \\ 1/p_k & 1/p_2 + 1/p_k & \cdots & 1/p_k \\ \cdots & \cdots & \cdots & \cdots \\ 1/p_k & 1/p_k & \cdots & 1/p_{k-1} + 1/p_k \end{pmatrix}. \end{aligned}$$

Pe de altă parte, din relația $X_k = 1 - \sum_{i=1}^{k-1} X_i$ obținem $S_{n,k} = n - \sum_{i=1}^{k-1} S_{n,i}$. Apoi avem

$$np_k = n \left(1 - \sum_{i=1}^{k-1} p_i \right) = n - \sum_{i=1}^{k-1} np_i. \text{ Atunci}$$

$$\begin{aligned} \Phi_n &= \sum_{i=1}^k \frac{(S_{n,i} - np_i)^2}{np_i} = \sum_{i=1}^{k-1} \frac{(S_{n,i} - np_i)^2}{np_i} + \frac{\left[\sum_{i=1}^{k-1} (np_i - S_{n,i}) \right]^2}{np_k} = \\ &= n \left\{ \sum_{i=1}^{k-1} \frac{(S_{n,i}/n - p_i)^2}{p_i} + \frac{\left[\sum_{i=1}^{k-1} (S_{n,i}/n - p_i) \right]^2}{p_k} \right\} = \\ &= n \left[\sum_{i=1}^{k-1} \left(\frac{S_{n,i}}{n} - p_i \right)^2 \left(\frac{1}{p_i} + \frac{1}{p_k} \right) + 2 \sum_{1 \leq i < j \leq k-1} \left(\frac{S_{n,i}}{n} - p_i \right) \left(\frac{S_{n,j}}{n} - p_j \right) \frac{1}{p_k} \right]. \end{aligned}$$

Asociem șirului $\mathbf{X}_n = (X_{n,1}, X_{n,2}, \dots, X_{n,k})$ șirul $\mathbf{X}_n^{(1)} = (X_{n,1}, X_{n,2}, \dots, X_{n,k-1})$, $n \in \mathbb{N}^*$, de vectori independenți, cu distribuția vectorului aleator $\mathbf{X}^{(1)} = (X_1, \dots, X_{k-1})$. Fie

$$\bar{\mathbf{X}}_n^{(1)} = \frac{1}{n} \sum_{m=1}^n \mathbf{X}_m^{(1)} = \left(\frac{S_{n,1}}{n}, \frac{S_{n,2}}{n}, \dots, \frac{S_{n,k-1}}{n} \right), \quad n \in \mathbb{N}^*.$$

Avem

$$\bar{\mathbf{X}}_n^{(1)} - \mathbf{p}^{(1)} = \left(\frac{S_{n,1}}{n} - p_1, \frac{S_{n,2}}{n} - p_2, \dots, \frac{S_{n,k-1}}{n} - p_{k-1} \right), \quad n \in \mathbb{N}^*.$$

Din expresiile lui $(\Sigma^{(1)})^{-1}$ și Φ_n , rezultă următoarea reprezentare matriceală a variabilei aleatoare Φ_n :

$$\begin{aligned} \Phi_n &= n \left(\bar{\mathbf{X}}_n^{(1)} - \mathbf{p}^{(1)} \right) (\Sigma^{(1)})^{-1} \left(\bar{\mathbf{X}}_n^{(1)} - \mathbf{p}^{(1)} \right)^T = \\ &= \left[\sqrt{n} \left(\bar{\mathbf{X}}_n^{(1)} - \mathbf{p}^{(1)} \right) \sqrt{(\Sigma^{(1)})^{-1}} \right] \left[\sqrt{n} \left(\bar{\mathbf{X}}_n^{(1)} - \mathbf{p}^{(1)} \right) \sqrt{(\Sigma^{(1)})^{-1}} \right]^T, \end{aligned}$$

unde s-a utilizat proprietatea $\sqrt{(\Sigma^{(1)})^{-1}} = \left(\sqrt{(\Sigma^{(1)})^{-1}} \right)^T$, care decurge din relația de simetrie $(\Sigma^{(1)})^{-1} = \left((\Sigma^{(1)})^{-1} \right)^T$. Conform Teoremei limită centrală multidimensională,

$$\sqrt{n} \left(\bar{\mathbf{X}}_n^{(1)} - \mathbf{p}^{(1)} \right) \sqrt{(\Sigma^{(1)})^{-1}} \xrightarrow{d} (Z_1, Z_2, \dots, Z_{k-1}),$$

unde $(Z_1, Z_2, \dots, Z_{k-1}) \sim N_{k-1}(\mathbf{0}, I_{k-1})$. Rezultă

$$\Phi_n \xrightarrow{d} (Z_1, Z_2, \dots, Z_{k-1}) \begin{pmatrix} Z_1 \\ Z_2 \\ \vdots \\ Z_{k-1} \end{pmatrix} = \sum_{i=1}^{k-1} Z_i^2.$$

Cum Z_1, Z_2, \dots, Z_{k-1} sunt variabile aleatoare normale standard, necorelate, variabila aleatoare $Z = \sum_{i=1}^{k-1} Z_i^2$ are o distribuție χ^2 cu $k-1$ grade de libertate (Teorema 4.6.1).

Astfel, teorema este demonstrată. \square

Descrierea testului χ^2

O caracteristică X a unei populații P poate lua una din valorile v_1, v_2, \dots, v_k . Fie numerele strict pozitive p_1, p_2, \dots, p_k , cu $\sum_{i=1}^k p_i = 1$.

1. Testăm ipoteza nulă H_0 : *caracteristica X are distribuția* $\begin{pmatrix} v_1 & v_2 & \cdots & v_k \\ p_1 & p_2 & \cdots & p_k \end{pmatrix}$.
2. Fie variabilele de selecție X_1, X_2, \dots, X_n . Definim statistica

$$\Phi_n = g_n(X_1, X_2, \dots, X_n) = \sum_{i=1}^k \frac{(S_{n,i} - np_i)^2}{np_i},$$

unde $S_{n,i} = |\{m \in \{1, \dots, n\} : X_m = v_i\}|$, pentru $i = 1, 2, \dots, k$.

Conform Teoremei 4.6.4, dacă ipoteza H_0 este adevărată, atunci are loc convergența în distribuție: $g_n(X_1, X_2, \dots, X_n) = \Phi_n \xrightarrow{d} Z$, unde Z este o variabilă aleatoare cu distribuția χ^2 cu $k - 1$ grade de libertate.

3. Stabilim pragul de semnificație $\varepsilon \in (0, 1/10)$.
4. Fie F funcția de repartiție a variabilei aleatoare Z . Determinăm domeniul de acceptare $A_\varepsilon = [0, a_\varepsilon]$ astfel ca $\mathbb{P}\{Z \in A_\varepsilon\} = \mathbb{P}\{Z \leq a_\varepsilon\} = F(a_\varepsilon) = 1 - \varepsilon$.
Pentru numărul gradelor de libertate $k-1 = d \in \{1, 2, \dots, 20\}$ și $\varepsilon \in \{0.05, 0.01, 0.001\}$, cuantila a_ε se citește pe linia d și coloana ε în tabelul de mai jos.

Critical values of the Chi-square distribution with d degrees of freedom							
d	Probability of exceeding the critical value			d			
	0.05	0.01	0.001		0.05	0.01	0.001
1	3.841	6.635	10.828	11	19.675	24.725	31.264
2	5.991	9.210	13.816	12	21.026	26.217	32.910
3	7.815	11.345	16.266	13	22.362	27.688	34.528
4	9.488	13.277	18.467	14	23.685	29.141	36.123
5	11.070	15.086	20.515	15	24.996	30.578	37.697
6	12.592	16.812	22.458	16	26.296	32.000	39.252
7	14.067	18.475	24.322	17	27.587	33.409	40.790
8	15.507	20.090	26.125	18	28.869	34.805	42.312
9	16.919	21.666	27.877	19	30.144	36.191	43.820
10	18.307	23.209	29.588	20	31.410	37.566	45.315

INTRODUCTION TO POPULATION GENETICS, Table D.1
© 2013 Sinauer Associates, Inc.

Pentru alte valori ale lui ε se poate utiliza un soft statistic. Reținem că, pentru n "mare", are loc aproximarea:

$$\mathbb{P}\{g_n(X_1, X_2, \dots, X_n) \in A_\varepsilon\} \approx \mathbb{P}\{Z \in A_\varepsilon\} = F(a_\varepsilon) = 1 - \varepsilon,$$

5. Dacă valoarea numerică a lui Φ_n calculată pentru datele concrete ale eșantionului X_1, X_2, \dots, X_n aparține mulțimii $A_\varepsilon = [0, a_\varepsilon]$, atunci H_0 este acceptată cu pragul de semnificație ε . În caz contrar, ipoteza H_0 este respinsă.

Exemplu

Examenul de *Teoria probabilităților și statistică matematică* din sesiunea de vară 2020, susținut de 204 studenți de la programele de studii *Electronică, Calculatoare și Tehnologia informației* a avut următoarea distribuție a rezultatelor

$$\left(\begin{array}{cccc} v_1 : \text{abs sau neprom.} & v_2 : \text{nota 5 sau 6} & v_3 : \text{nota 7 sau 8} & v_4 : \text{nota 9 sau 10} \\ p_1 = 0.17 & p_2 = 0.20 & p_3 = 0.44 & p_4 = 0.19 \end{array} \right).$$

În aceeași sesiune, la examenul de *Probabilități și statistică*, susținut de 73 de studenți de la programul *Informatică* s-a înregistrat următoarea situație: 5 studenți au fost absenți (valoarea v_1), 14 studenți au luat notele 5-6 (valoarea v_2), 31 studenți au luat notele 7-8 (valoarea v_3) și 23 de studenți au luat notele 9-10 (valoarea v_4). Utilizând testul χ^2 ne propunem să stabilim valabilitatea ipotezei H_0 :

rezultatele înregistrate la examenul de *Probabilități și statistică* au aceeași distribuție cu cele înregistrate la examenul de *Teoria probabilităților și statistică matematică*.

Volumul eșantionului este $n = 73$, iar $k = 4$. Alegem pragul de semnificație $\varepsilon = 0.01$. Fie Z o variabilă aleatoare χ^2 cu $k - 1 = 3$ grade de libertate. Conform tabelului de mai sus, obținem cuantila $a_\varepsilon = 11.345$, deci domeniul de acceptare a ipotezei nule este $A_\varepsilon = [0, 11.345]$. Pentru datele menționate, avem

$$\Phi_{73} = \frac{(5 - 73 \cdot p_1)^2}{73 \cdot p_1} + \frac{(14 - 73 \cdot p_2)^2}{73 \cdot p_2} + \frac{(31 - 73 \cdot p_3)^2}{73 \cdot p_3} + \frac{(23 - 73 \cdot p_4)^2}{73 \cdot p_4} = 10.498086.$$

Ca urmare, ipoteza H_0 este acceptată (la limită!) cu pragul de semnificație $\varepsilon = 0.01$.

4.7 Test

1. Definiți media empirică și descrieți proprietățile acestui estimator în cazul eșantioanelor Bernoulli.
2. Determinați estimatorul bayesian al unui eșantion Bernoulli asociat unei distribuții $\beta(a, b)$ a parametrului de estimat θ .
3. Se observă două variabile aleatoare Bernoulli independente X_1 și X_2 , de parametru $\theta \in (0, 1)$. Să se arate că nu se poate găsi un estimator a fără abatere a lui $\frac{\theta}{1 - \theta}$ care să depindă de X_1 și X_2 .
4. Cu ajutorul unui n -eșantion Bernoulli de parametru θ se caută estimarea dispersiei $\theta(1 - \theta)$. Să se arate că estimatorul $T = \bar{X}_n(1 - \bar{X}_n)$ nu este fără abatere, dar există un multiplu al său având această proprietate.

4.8 Rezumat

Statistica matematica utilizează rezultatele oferite de teoria probabilităților pentru a generaliza rezultatele unei experiențe la o clasă de experiențe similare. Acest tip de extindere se datorează unui raționament de tip *inductiv* (obținerea unor informații generale din analiza unor informații particulare). Statistica analizează date concrete, locale, obținute experimental, pentru a prognoza date cu caracter general, a descoperi legile care guvernează fenomenul studiat.

Noțiuni specifice:

- **populația statistică** reprezintă mulțimea tuturor elementelor avute în vedere în cadrul unui **studiu statistic**;
- **sondajul** reprezintă examinarea (chestionarea) unei părți a populației statistice, numită **eșantion**;
- numărul elementelor unui eşantion (obținut prin sondaj și examinat) se numește **volumul eşantionului**;
- scopul unui studiu statistic este **estimarea** unei proprietăți/particularități a populației statistice. Funcția matematică care realizează estimarea se numește **estimator**;
- o **statistică** (sau un **estimator** se definește ca o funcție de variabilelor aleatoare observabile (cele ale n -eșantionului) și nu depinde de parametrii necunoscuți.

Statistica eşantioanelor Bernoulli.

Modelare: fiecare element al populației statistice se reprezintă printr-o variabilă aleatoare Bernoulli X , cu distribuția

$$X : \begin{pmatrix} 0 & 1 \\ 1 - \theta & \theta \end{pmatrix},$$

Pentru evaluarea apriorică a parametrului necunoscut θ se propune estimatorul **media empirică**, definit prin:

$$\bar{X}_n = \frac{S_n}{n}, \text{ unde } S_n = X_1 + X_2 + \dots + X_n.$$

Media empirică exprimă frecvența de apariție a valorii 1, deci oferă o evaluare a parametrului θ . Proprietățile principale ale mediei empirice \bar{X}_n , ca estimator a lui θ .

1. \bar{X}_n este un estimator fără abatere a lui θ : $\mathbb{E}_\theta(\bar{X}_n) = \theta$, $\forall \theta \in (0, 1)$.
2. \bar{X}_n este unicul estimator fără abatere a lui θ , care depinde de S_n .
3. \bar{X}_n este estimatorul lui θ de maximă verosimilitate
4. Când talia eşantionului tinde la infinit, \bar{X}_n converge la θ cu o rată exponențială.
5. Riscul pătratic mediu al estimatorului \bar{X} a lui θ converge la 0.
6. Abaterea lui \bar{X}_n față de θ poate fi evaluată prin Teorema limită centrală.

Definim estimatorul bayesian a lui θ , de risc pătratic mediu minim:

$$g(S_n) = \frac{\sum_{\theta \in D} \rho(\theta) \theta^{S_n+1} (1-\theta)^{n-S_n}}{\sum_{\theta \in D} \rho(\theta) \theta^{S_n} (1-\theta)^{n-S_n}}.$$

Dacă θ admite densitatea de probabilitate f pe $[0, 1]$, atunci estimatorul bayesian a lui θ este

$$g(S_n) = \frac{\int_0^1 \theta^{S_n+1} (1-\theta)^{n-S_n} f(\theta) d\theta}{\int_0^1 \theta^{S_n} (1-\theta)^{n-S_n} f(\theta) d\theta}.$$

Referințe bibliografice

- [1] G. Ciucu, C. Tudor, *Probabilități și procese stochastice*, Ed. Academiei Române, 1979 (vol 1-2).
- [2] I. Cuculescu, *Teoria probabilităților*, Ed. All, 1998.
- [3] D. Dacunha-Castelle, M. Duflo, *Probabilités et statistique*, Masson, 1994 (vol 1).
- [4] W. Feller, *Introduction to probability theory and its applications*, Wiley, New York, 1968.
- [5] P.G. Hoel, *Introduction to mathematical statistics*, Wiley, 1984.
- [6] M. Iosifescu, Gh. Mihoc, R. Theodorescu, *Teoria probabilităților și statistică matematică*, Ed. Tehnică, 1966.
- [7] O. Onicescu, Gh. Mihoc, C. Ionescu-Tulcea, *Calculul probabilităților și aplicații*, Ed. Academiei Române, 1965.